

《机器学习综合实践》

项目选题与实践指南

宫秀军

gongxj@tju.edu.cn

Contents

1 项目池总览	2
1.1 Track 概览	2
1.2 项目索引	3
1.3 随机与协商选题	4
1.4 数据获取	4
2 Track 1: GV (气囊蛋白)	5
2.1 GV-T01: 蛋白识别与功能预测	5
2.1.1 GV01-01: Gvp 蛋白类型识别与跨物种泛化	5
2.1.2 GV01-02: Gvp 蛋白序列模式发现与表示分析	9
2.1.3 GV01-03: GvpA 功能预测与关键位点归因	12
2.2 GV-T02: Gvp 蛋白序列设计与优化	15
2.2.1 GV02-01: 蓝藻 GvpA 序列生成	15
2.2.2 GV02-02: Gvp 蛋白目标性质预测与设计反馈	17
2.2.3 GV02-03: 多目标候选评价	20
2.2.4 GV02-04: 定向序列优化	22
2.2.5 GV02-05: 跨物种序列生成	24
2.2.6 GV02-06: 主动学习驱动的迭代设计	27
2.3 GV-T03: 气囊基因线路建模与设计	29
2.3.1 GV03-01: Gvp 启动子强度预测与跨物种迁移	29
2.3.2 GV03-02: gvp 操纵子调控模式发现	32
2.3.3 GV03-03: gvp 基因簇多基因协同表达优化	34
3 Track 2: Promoter (启动子)	37
3.1 PR-T01: 启动子识别与跨物种表征	37
3.1.1 PR01-01: 启动子识别与跨物种泛化	37
3.1.2 PR01-02: 启动子调控模式发现	40
3.1.3 PR01-03: 启动子识别与调控模式发现 (混合)	42
3.2 PR-T02: 启动子强度预测与可解释分析	44
3.2.1 PR02-01: 启动子强度预测与关键位点归因	44
3.2.2 PR02-02: 启动子强度预测的跨物种迁移与解释	47
3.3 PR-T03: 启动子序列生成与闭环验证	49

3.3.1	PR03-01: 条件启动子生成	49
3.3.2	PR03-02: 启动子序列优化与闭环验证	51
3.3.3	PR03-03: 启动子设计的模式发现与特征反馈	53
4	Track 3: XAI (可解释人工智能)	55
4.1	XAI-T01: 特征归因方法选择与评价	56
4.1.1	XAI01-01: 梯度类归因方法比较与优化	56
4.1.2	XAI01-02: 扰动类与博弈论类归因方法比较	58
4.1.3	XAI01-03: 归因结果的跨模型与跨数据集一致性分析	61
4.1.4	XAI01-04: 归因方法模式发现——什么条件下什么方法最优	63
4.2	XAI-T02: 先验信息融合的解释生成	65
4.2.1	XAI02-01: 反事实解释的设计与评价	65
4.2.2	XAI02-02: 先验融合机制比较——从像素 Mask 到概念约束	67
4.2.3	XAI02-03: 测试时训练驱动的自适应解释生成	70
5	Track 4: Challenges (开放竞赛)	72
5.1	CH-T01: 语言模型应用与智能体	72
5.1.1	CH01-01: Amazon Shopping MMLU (KDD Cup 2024)	72
5.1.2	CH01-02: Meta CRAG Challenge (KDD Cup 2024)	75
5.1.3	CH01-03: Deep Research Agent 开发赛 (天池 2026)	77
5.2	CH-T02: 多模态感知与领域智能	79
5.2.1	CH02-01: Meta CRAG-MM Challenge (KDD Cup 2025)	79
5.2.2	CH02-02: Ariel Data Challenge 2025 (Kaggle)	81
5.2.3	CH02-03: 出院用药推荐 (天池/CHIP2025)	83

1 项目池总览

本文档是《机器学习综合实践》课程的项目选题与实践指南，涵盖四个 Track 共 33 个项目。每个项目均包含动机、研究问题、任务目标与阶段任务、实施方案（建议）、实验设计与评价、交付物与里程碑，并区分必做、选做与探索项。

1.1 Track 概览

Track 1: GV (气囊蛋白) —12 个项目

生物气囊是原核生物合成的蛋白质纳米结构，具有超声成像、药物递送等应用价值。本 Track 围绕 Gvp 蛋白家族，从序列识别 (T01)、序列设计 (T02) 到基因线路建模 (T03)，构建“识别 → 生成 → 系统设计”的递进链条。核心计算问题包括生物序列-结构-功能关联建模、跨物种泛化、生成式序列设计和多基因协同表达优化。

- **GV-T01: 蛋白识别与功能预测** (3 个项目) —Gvp 蛋白类型识别与跨物种泛化、序列模式发现与表示分析、功能预测与关键位点归因
- **GV-T02: Gvp 蛋白序列设计与优化** (6 个项目) —序列生成、目标性质预测与设计反馈、多目标评价、定向优化、跨物种生成、主动学习迭代设计
- **GV-T03: 气囊基因线路建模与设计** (3 个项目) —启动子强度预测、操纵子调控模式发现、多基因协同表达优化

Track 2: Promoter (启动子) —8 个项目

启动子是基因表达调控的核心元件，其序列特征直接决定转录效率。本 Track 聚焦原核生物启动子，从识别 (T01)、强度预测 (T02) 到序列生成与闭环验证 (T03)，覆盖“特征发现 → 量化预测 → 理性设计”的完整链路。核心计算问题包括启动子序列模式挖掘、强度回归预测、条件序列生成和设计-验证闭环。

- **PR-T01: 启动子识别与跨物种表征** (3 个项目) —启动子识别与跨物种泛化、调控模式发现、识别与模式发现混合
- **PR-T02: 启动子强度预测与可解释分析** (2 个项目) —强度预测与关键位点归因、跨物种迁移与解释
- **PR-T03: 启动子序列生成与闭环验证** (3 个项目) —条件启动子生成、序列优化与闭环验证、设计模式发现与特征反馈

Track 3: XAI (可解释人工智能) —7 个项目

可解释性是机器学习走向可信应用的关键。本 Track 的主线不是复现前沿论文，而是给定一个已有深度模型和具体问题，学生选择合适的解释方法，并针对解释目标进行设计、优化和评价。T01 聚焦特征归因方法的选择与比较（梯度类、扰动类、博弈论类），T02 聚焦先验信息融合的解释生成（反事实解释、概念约束）。前沿论文方法（FourierShap、MA-GIG、LeapFactual、CCR 等）作为方法候选和选做扩展，而非必须实现的主体任务。核心能力培养：方法选择依据、归因质量评价和解释局限性分析。

- **XAI-T01: 特征归因方法选择与评价** (4 个项目) —梯度类归因方法比较与优化、扰动类与博弈论类归因方法比较、归因结果的跨模型与跨数据集一致性分析、归因方法模式发现
- **XAI-T02: 先验信息融合的解释生成** (3 个项目) —反事实解释的设计与评价、先验融合机制比较、测试时训练自适应解释

Track 4: Challenges (开放竞赛) —6 个项目

本 Track 汇编 2024–2026 年国际竞赛真题，涵盖大语言模型应用与智能体（T01）和多模态感知与领域智能（T02）。项目保留竞赛原始要求，方法空间完全开放，使用官方竞赛指标加课程评价指标。核心价值在于接触真实工业级问题和大规模数据。

- **CH-T01: 语言模型应用与智能体** (3 个项目) —Amazon Shopping MMLU (KDD Cup 2024)、Meta CRAG Challenge (KDD Cup 2024)、Deep Research Agent (天池 2026)
- **CH-T02: 多模态感知与领域智能** (3 个项目) —Meta CRAG-MM (KDD Cup 2025)、Ariel Data Challenge 2025 (Kaggle)、出院用药推荐 (天池/CHIP2025)

1.2 项目索引

GV Track

- GV01-01: Gvp 蛋白类型识别与跨物种泛化—监督预测
- GV01-02: Gvp 蛋白序列模式发现与表示分析—模式发现
- GV01-03: GvpA 功能预测与关键位点归因—混合
- GV02-01: 蓝藻 GvpA 序列生成—生成
- GV02-02: Gvp 蛋白目标性质预测与设计反馈—设计反馈
- GV02-03: 多目标候选评价—评价器设计
- GV02-04: 定向序列优化—优化
- GV02-05: 跨物种序列生成—生成 + 迁移
- GV02-06: 主动学习驱动的迭代设计—主动学习
- GV03-01: Gvp 启动子强度预测与跨物种迁移—监督预测
- GV03-02: gvp 操纵子调控模式发现—模式发现
- GV03-03: gvp 基因簇多基因协同表达优化—混合

Promoter Track

- PR01-01: 启动子识别与跨物种泛化—监督预测
- PR01-02: 启动子调控模式发现—模式发现
- PR01-03: 启动子识别与调控模式发现（混合）—混合

- PR02-01: 启动子强度预测与关键位点归因—监督预测
- PR02-02: 启动子强度预测的跨物种迁移与解释—混合
- PR03-01: 条件启动子生成—生成
- PR03-02: 启动子序列优化与闭环验证—优化 + 验证
- PR03-03: 启动子设计的模式发现与特征反馈—模式发现

XAI Track

- XAI01-01: 梯度类归因方法比较与优化—方法选择
- XAI01-02: 扰动类与博弈论类归因方法比较—方法选择
- XAI01-03: 归因结果的跨模型与跨数据集一致性分析—泛化分析
- XAI01-04: 归因方法模式发现——什么条件下什么方法最优—模式发现
- XAI02-01: 反事实解释的设计与评价—方法设计 + 评价
- XAI02-02: 先验融合机制比较——从像素 Mask 到概念约束—模式发现
- XAI02-03: 测试时训练驱动的自适应解释生成—方法设计 + 评价

Challenges Track

- CH01-01: Amazon Shopping MMLU (KDD Cup 2024) —LLM 评测
- CH01-02: Meta CRAG Challenge (KDD Cup 2024) —RAG 智能体
- CH01-03: Deep Research Agent 开发赛 (天池 2026) —Research Agent
- CH02-01: Meta CRAG-MM Challenge (KDD Cup 2025) —多模态 RAG
- CH02-02: Ariel Data Challenge 2025 (Kaggle) —系外行星光谱
- CH02-03: 出院用药推荐 (天池/CHIP2025) —医疗 NLP

1.3 随机与协商选题

1. 自由组队:
 - 每组 5 人,
 - 每组有唯一编号, 如 G02。
2. 项目随机分配:
 - 课堂上由教师运行一个随机程序, 为每组随机分配一个项目, 如 PR03-02->G10
 - 随机分配的目的, 是保证项目选择过程的公平性, 避免热门项目被少数小组集中选择。
3. 组间协商:
 - 随机分配完成后, 各小组根据项目说明了解自己获得的项目, 并进行组间协商。
 - 如果某小组认为其他项目更加适合本组, 可以与其他小组协商交换项目。项目交换必须经过相关小组共同同意。
4. 项目确认:
 - 每组恰好对应一个项目;
 - 每个项目原则上仅由一个小组完成;
 - 项目交换必须经过相关小组共同同意;
 - 协商结束后项目原则上不再调整。

1.4 数据获取

- GV, PR, XAI TRACK

<https://pan.tju.edu.cn/link/AAC85903DEA75D4DC3B8E604FED612552E>

Folder Name: resources

Expires: 2026-12-11 23:59

Pickup Code: oc7B

- CH TRACK (access from corresponding websites)

1. **任务范式覆盖**: 项目池涵盖监督预测、模式发现、混合任务、生成任务和优化任务五种范式, 确保选题多样性。
2. **里程碑框架**: 所有项目共享统一的五阶段里程碑框架 (M1问题分析 → M2 初步结果 → M3 中期结果 → M4 完整实验 → M5 最终成果), 但各阶段的具体内容由项目特征决定——不同项目可以有不同的内部路径 (M3 不必是 Baseline, M4 不必是优化)。各阶段的 **deadline** 由指导教师根据实际情况设定。
3. **研究问题驱动**: 每个项目显式列出 2–4 个研究问题 (RQ), 学生的实验设计和分析应围绕回答 RQ 展开。

2 Track 1: GV (气囊蛋白)

领域背景

生物气囊 (Gas Vesicles, GVs) 是原核生物 (蓝藻、古菌等) 合成的蛋白质纳米空腔结构, 内部充满气体, 外壳完全由蛋白质构成。GVs 具有可压缩但不透水的物理特性, 在超声成像中产生极高对比度信号, 可通过遗传工程定制, 在血管成像、药物递送和靶向治疗等生物医学领域具有重要应用价值。

GVs 的形成与功能依赖于气囊蛋白 (Gas Vesicle Protein, Gvp) 家族的协同作用。gvp 基因簇由 8–14 个基因构成, 不同物种的基因组成不同。GvpA 构成主壳体 (β -sheet 刚性壳体, 保守域 pfam01132), GvpC 在壳外加固 (富含重复 motif), GvpN 作为 ATPase 驱动囊泡生长, GvpF/L 组成组装起始复合物。GvpE/GvpD 构成转录激活-抑制对, 决定基因簇是否开启。不同物种间 Gvp 序列差异可达 20–40%, 古菌与蓝藻的 operon 结构完全不同。

计算问题

从机器学习角度看, GV 领域的核心计算问题是**生物序列—结构—功能关联建模**。具体展开为: (1) 从氨基酸序列预测 Gvp 蛋白类型与功能 (分类/回归); (2) 从序列中发现功能相关模式 (motif、保守位点、聚类结构); (3) 生成满足生物学约束的新序列 (生成模型); (4) 基因线路层面的表达预测与元件组合优化。这些问题在计算层面共享同一基本结构: 从生物数据中学习表示与目标功能之间的关系, 并利用学习模型完成预测、筛选、优化或设计。

现状与挑战

- **数据稀缺与标注偏差**: 可获得序列数量远大于实验验证的功能标注数量, Gvp 蛋白家族的高质量功能标签有限, 导致小样本学习、类别不平衡和标签噪声问题。
- **跨物种分布偏移**: Gvp 蛋白分布于不同进化谱系, 训练数据与目标数据间存在显著分布偏移。随机划分获得的较高性能不必然意味着跨物种泛化能力——数据划分策略本身是模型设计的一部分。
- **序列与功能的非线性关系**: 相似功能的蛋白质可能序列差异大, 局部变化也可能显著影响结构稳定性。表示方式的选择和模型对序列依赖关系的刻画能力至关重要。
- **多层次信息耦合与观测不完整**: 序列 → 结构 → 功能 → 组装 → 线路 → 系统性能, 各层次相互关联但现有数据无法在所有层次同时提供完整观测。
- **组合空间巨大**: 蛋白质序列设计本质上是离散空间中的约束搜索, 理论搜索空间随长度指数增长。

2.1 GV-T01: 蛋白识别与功能预测

GV 由多种 Gvp 蛋白协同组装——GvpA 构成主壳, GvpC 在壳外强化, GvpN 作为 ATPase 参与调控, GvpF/L 组成组装起始复合物。T01 围绕两个核心方向: 从序列预测蛋白类型和功能属性 (监督预测), 以及从序列数据中发现功能相关的模式 (模式发现)。两者共享同一套表示学习基础, 且互补——预测模型建立的表示和归因结果可为模式发现提供线索, 模式发现的结论又可指导预测模型的特征设计。

2.1.1 GV01-01: Gvp 蛋白类型识别与跨物种泛化

动机

Gvp 蛋白分布于蓝藻、古菌等多种原核生物中，不同物种间同一种 Gvp 蛋白的序列差异可达 20–40%。在实际应用场景中，新发现的 Gvp 序列往往来自训练时未覆盖的物种，模型若仅在随机划分下表现良好，并不能保证其对未知物种具有泛化能力。现有的蛋白质分类工具多针对通用蛋白家族设计，缺乏针对 Gvp 蛋白家族特异性的类型识别方案。更关键的是，Gvp 蛋白数据具有强烈的聚类结构——同一家族的序列高度相似，随机划分会导致训练集和测试集之间存在严重的数据泄漏，产生虚高的性能估计，掩盖真实的泛化瓶颈。因此，如何在物种感知的数据划分下构建具有跨物种泛化能力的 Gvp 蛋白类型识别模型，并通过系统的实验设计揭示表示方式、模型架构和数据划分策略对泛化性能的影响规律，是本项目的核心问题。这一问题的解决不仅具有 GV 领域的实际意义，也代表了生物序列分类任务中的典型挑战。

研究问题

本项目不是简单地“训练一个 Gvp 分类器”，而是围绕以下层层递进的研究问题展开：

■ **RQ1（核心问题）**：随机划分下获得的高分类性能，在多大程度上来自序列相似性泄漏？

■ **RQ2（进一步）**：不同表示方式（手工特征 vs PLM 嵌入）和模型复杂度（传统 ML vs 深度学习）对跨物种泛化的影响是否一致？——即，在 random split 上的最优组合，在 species-aware split 上是否仍然最优？

■ **RQ3（再进一步）**：模型的分类错误是否与序列相似性、物种进化距离和功能类型存在系统性关联？——如果是，这种关联能否指导针对性的模型改进？

学生应在最终报告中明确回答这三个研究问题，并以实验数据支撑结论。

任务目标与阶段任务

总目标：构建 Gvp 蛋白亚基类型分类模型，在物种感知划分下评估跨物种泛化能力，通过系统的对比实验回答上述三个研究问题。

阶段任务：

1. **问题定义与数据构建**（对应 M1）：明确分类目标（GvpA/C/N/F/L/K 等亚基类型，类别体系设计），从 NCBI/UniProt 等公共数据库采集序列，使用 CD-HIT 去冗余，设计 random / species-aware / similarity-aware 三种数据划分策略并说明各自评价目的。
2. **探索性数据分析**（对应 M2）：分析类别分布、物种分布、序列长度分布、序列相似性结构，识别数据中的偏差和挑战（如哪些类别样本极少、哪些物种间序列差异大）。
3. **Baseline 建立**（对应 M3）：使用手工特征（k-mer 频率、氨基酸组成、物理化学特征）+ 传统 ML（SVM/RF/XGBoost）建立基线模型，在三种划分策略下获得基线性能。
4. **表示与模型对比**（对应 M4）：系统比较手工特征 vs 蛋白质语言模型嵌入（ESM2/ProtBERT, frozen vs fine-tuned）、传统 ML vs 深度学习（1D-CNN/BiLSTM/轻量 Transformer），在三种划分策略下获得完整对比矩阵。
5. **针对性优化**（对应 M4）：基于实验中发现的瓶颈（如类别不平衡、跨物种性能骤降），设计针对性优化策略并验证效果。
6. **错误分析与生物学验证**（对应 M5）：分析错误集中于哪些物种/类型，使用归因方法（attention/SHAP/saliency）提取关键位点，与 Pfam01132 保守域和 MSA 高保守位点对比，评估模型的生物学合理性。

实施方案（建议）

■ 以下技术路线为建议性参考，学生可根据问题分析自行选择和调整，但需说明选择依据。

数据构建

- 技术（建议）：NCBI Datasets CLI / Biopython 采集；CD-HIT（90% identity）或 MMseqs2 去冗余；三种划分——random、species-aware（按物种分组）、similarity-aware（按序列聚类分组）
- 决策点：划分策略直接影响泛化评价的有效性，需明确每种策略回答什么问题

特征表示

- 技术 (建议): 基线——k-mer 频率 (k=3-5)、氨基酸组成、疏水性/分子量等物理化学特征; 进阶——ESM2 (650M) 或 ProtBERT 嵌入, 比较不同层 (last hidden vs intermediate layer)、frozen embedding vs LoRA fine-tuning
- 决策点: 表示方式应与数据规模匹配——小样本下 frozen embedding 可能优于全量微调

模型架构

- 技术 (建议): 基线——SVM (RBF核)、Random Forest、XGBoost; 进阶——1D-CNN (捕获局部 motif)、BiLSTM (捕获序列依赖)、轻量 Transformer (捕获长程依赖); PLM 路线——ESM2 + linear probe → ESM2 + LoRA
- 决策点: 模型复杂度应与数据规模和问题特征匹配, 而非追求最先进模型

针对性优化

- 技术 (建议): 类别不平衡——focal loss / class-weighted sampling / 过采样; 跨物种泛化——域对抗训练 (DANN) / mixup 数据增强 / 正则化 (dropout、label smoothing); 表示优化——pooling 策略对比、多尺度特征融合
- 决策点: 优化必须基于实验观察的瓶颈, 而非盲目调参——需明确“观察到什么问题 → 采取什么策略 → 效果如何”

归因分析

- 技术 (建议): Attention weights (Transformer类) / SHAP / Integrated Gradients / Saliency maps; 与 Pfam01132 保守域、MSA 高保守位点 (Jalview/Shade) 对比
- 决策点: 归因结果是否与已知功能区域一致, 是评估模型生物学合理性的关键

实验设计与评价

评价核心不是达到某个固定数值, 而是通过系统的实验设计回答研究问题 RQ1-RQ3。以下实验标注了必做、选做和探索项。

必做实验

实验 1: 数据划分策略对比 (→ RQ1)

- 同一模型 (固定表示 + 架构), 在 random / species-aware / similarity-aware 三种划分下对比性能
- 分析要点: 性能差距揭示了什么? 哪种划分更能反映真实应用场景? random split 的“虚高”程度有多大? 能否量化“相似性泄漏”的贡献?

实验 2: 表示方式对比 (→ RQ2)

- 固定模型架构 (如 SVM), 对比 k-mer 特征 vs PLM 嵌入 (frozen vs LoRA fine-tuned)
- 分析要点: PLM 嵌入是否真正捕获了 Gvp 家族特异性信息? 不同 PLM 层的嵌入质量差异如何? frozen embedding vs fine-tuning 的权衡点在哪里? random split 上的最优表示在 species-aware split 上是否仍然最优?

实验 3: 消融实验 (→ RQ2)

- 逐层消融关键设计: Baseline → +PLM 嵌入 → + 深度模型 → + 针对性优化
- 分析要点: 每一步增加的设计解决了什么瓶颈? 是否引入了新的问题 (如更复杂的模型在 species-aware split 下反而退化)?

实验 4: 跨物种泛化深度分析 (→ RQ3)

- 按物种分解性能: 哪些物种容易分类、哪些困难? 为什么? (序列保守度? 训练集物种覆盖?)
- 按类型分解: 哪些 Gvp 类型跨物种稳定、哪些不稳定?

- 序列相似性与分类性能的关系：是否存在“相似度高但分类错误”的困难样本？错误率与物种进化距离的相关性如何？

选做实验（从中至多选 2 项）

实验 5：模型架构对比（→ RQ2）

- 固定特征表示（如 ESM2 frozen），对比 SVM vs CNN vs Transformer
- 分析要点：模型复杂度与数据规模的匹配关系如何？更复杂的模型是否真正带来跨物种泛化提升？还是在小样本下过拟合？

实验 6：鲁棒性分析

- 多个随机种子（≥5）的均值 ± 标准差，而非单次最优结果
- 不同训练/测试比例（70/30 vs 80/20 vs 60/40）的影响
- 性能方差是否在可接受范围内

实验 7：针对性优化效果验证（→ RQ3 的改进方向）

- 针对实验 4 中发现的具体瓶颈（如某物种性能极低），设计针对性优化策略（如域对抗、数据增强、损失函数调整），对比优化前后效果
- 分析要点：优化策略是否真正解决了目标瓶颈？是否引入了新的问题（如提升困难物种性能时牺牲了其他物种）？

探索项（开放方向，鼓励有余力的团队深入）

- **归因与生物学验证**：使用 attention/SHAP/IG 提取关键位点，与 Pfam01132 保守域和 MSA 高保守位点对比；t-SNE/UMAP 降维后分析嵌入空间聚类结构是否与生物学分类一致——“模型”学到”的生物学信息是否合理？
- **自定义研究问题**：学生基于实验中的发现，自主提出一个延伸研究问题并设计实验回答。需在报告中说明问题的来源（哪个实验现象触发的）、实验设计和结论。

交付物与里程碑

M1 —问题分析

- 分类目标和类别体系定义
- 数据来源和构建方案
- 三种数据划分策略设计及理由
- 研究问题（RQ1-RQ3）的初步拆解——计划用哪些实验回答哪个问题
- 初步的文献调研（Gvp 蛋白分类的现有方法）

M2 —初步结果

- 类别分布与物种分布可视化
- 序列长度统计
- CD-HIT/MMseqs2 聚类结果与序列相似性矩阵
- 数据清洗和标准化流程代码
- 三种划分的数据集统计
- 对 RQ1 的初步预判（相似性结构是否严重）

M3 —中期结果

- 手工特征 + 传统 ML 的完整 pipeline 代码
- 三种划分下的基线性能表
- 初步的混淆矩阵和错误类型分析
- 中期检查演示材料——需展示 random vs species-aware 的性能差距，初步回答 RQ1

M4 —完整实验

- PLM 嵌入实验代码与结果
- 深度模型实验代码与结果（如选做）
- 完整消融实验数据
- 跨物种泛化深度分析（按物种/类型/相似度分解）
- 针对性优化实验（如选做）
- 选做实验结果
- RQ1–RQ3 的实验证据汇总

M5 —最终成果

- 完整实验报告（含问题分析、方法设计、实验结果、错误分析、对 RQ1–RQ3 的明确回答、结论与改进方向）
- 可复现的代码仓库（含 README 和运行说明）
- 答辩 PPT

代码仓库要求：目录结构清晰（data/ preprocessing/ models/ experiments/ results/），关键实验可通过命令行复现，README 包含环境配置和运行说明。

2.1.2 GV01-02: Gvp 蛋白序列模式发现与表示分析

动机

分类器能告诉你”这条序列是 GvpA”，但无法回答”为什么是 GvpA”——哪些序列模式定义了这个蛋白家族？不同 Gvp 类型的序列空间结构有何差异？蛋白质语言模型（PLM）的嵌入是否真正捕获了这些生物学信息，还是只是记住了表面统计特征？这些问题对 GV 领域的深入理解至关重要：如果模型依赖的模式与已知功能域一致，说明特征表示具有生物学合理性；如果不一致，则可能存在标注偏差或模型偏差。此外，跨物种的序列模式差异分析能揭示哪些位点是功能保守的（functional invariant positions）、哪些位点是可变的——这种区分对后续的序列设计（T02）具有直接指导意义。本项目不是训练一个更好的分类器，而是从无标注或少标注的序列数据中挖掘模式，理解 Gvp 蛋白家族的序列空间组织规律。

研究问题

RQ1: PLM 嵌入空间的聚类结构是否与 Gvp 蛋白的生物学功能分类一致——即，不同 Gvp 类型在嵌入空间中是否自然分离？

RQ2: 不同 PLM（ESM2 vs ProtBERT）和不同层（底层 vs 中间层 vs 顶层）的嵌入捕获的生物学信息有何差异——哪一层的表示最适合用于 Gvp 家族的模式发现？

RQ3: 从序列中发现的保守 motif 是否与已知功能域（Pfam01132 等）对应？是否存在 Pfam 未标注但模型和聚类分析一致认为重要的保守区域？

任务目标与阶段任务

总目标：从 Gvp 蛋白序列数据中发现具有生物学意义的模式——序列空间结构、保守 motif 和表示质量——并评估 PLM 嵌入是否捕获了 Gvp 家族特异性的生物学信息。

阶段任务：

1. **问题定义与数据构建**（对应 M1）：明确模式发现的目标（聚类结构、motif、表示分析），采集多物种 Gvp 蛋白序列，去冗余，说明无标注/少标注条件下模式发现的合理性。
2. **探索性数据分析**（对应 M2）：序列长度分布、物种分布、氨基酸组成差异、简单 k-mer 统计——为后续深度分析建立基础认知。
3. **Baseline 模式发现**（对应 M3）：使用手工特征（k-mer / 物理化学特征）+ 传统聚类（K-means / 层次聚类）建立基线，与已知 Gvp 类型标签对比。

4. **PLM 嵌入空间分析** (对应 M4): 使用 ESM2/ProtBERT 嵌入, t-SNE/UMAP 降维可视化, 聚类并计算聚类质量 (silhouette / ARI), 对比不同 PLM 和不同层。
5. **Motif 发现与功能域对比** (对应 M4): MEME/MAST/HMMER 搜索保守 motif, 与 Pfam 域和 MSA 高保守位点对比, 评估发现的生物学合理性。
6. **跨物种模式比较与总结** (对应 M5): 分析不同物种间的 motif 差异和保守性, 总结模式发现结果对 GV 领域的启示。

实施方案 (建议)

数据构建

- 技术 (建议): NCBI 采集多物种 Gvp 序列; CD-HIT 去冗余 (90% identity); 构建无标注和少标注两种数据集
- 决策点: 模式发现是否需要标签——有标签可用于评估聚类质量 (ARI), 无标签则更纯粹

表示方式

- 技术 (建议): 手工特征 (k-mer / 氨基酸组成 / 物理化学特征) 作为基线; PLM 嵌入 (ESM2-650M / ProtBERT), 对比不同层 (底层 / 中间层 / 顶层) 和不同 pooling 策略 (mean / CLS / max)
- 决策点: 不同层捕获的信息层次不同——底层偏局部模式, 顶层偏语义信息, 需分析哪层最适合

聚类与降维

- 技术 (建议): K-means / 层次聚类 / 密度聚类 (HDBSCAN); PCA / t-SNE / UMAP 降维可视化; silhouette / ARI / NMI 量化聚类质量
- 决策点: 聚类数量是否与已知 Gvp 类型数一致? 密度聚类能否发现非球形结构?

Motif 发现

- 技术 (建议): MEME / DREME / STREME 发现 de novo motif; MAST / FIMO 在序列中定位; HMMER3 构建 motif HMM profile; 与 Pfam01132 / Pfam01125 等已知域对比
- 决策点: 发现的 motif E-value 是否足够小? 与已知功能域的重合度如何?

表示质量评估

- 技术 (建议): CKA (Centered Kernel Alignment) 量化不同表示的相似性; 线性探测 (linear probe) 评估嵌入的可分性; 聚类稳定性 (不同随机种子下聚类结果的一致性)
- 决策点: PLM 嵌入的可分性是否显著优于手工特征?

实验设计与评价

必做实验

实验 1: 聚类结构 vs 生物学分类对比 (→ RQ1)

- 在 PLM 嵌入上聚类, 计算 ARI/NMI 与已知 Gvp 类型标签的吻合度
- 分析要点: 聚类数量是否与类型数一致? 哪些类型容易/难以分离? 聚类与生物学分类的偏差出现在哪些类型上?

实验 2: 不同表示的聚类质量对比 (→ RQ2)

- 固定聚类算法, 对比手工特征 vs 不同 PLM (ESM2 vs ProtBERT) vs 不同层的聚类质量
- 分析要点: 哪种表示的聚类质量最高? 不同层捕获的信息层次差异如何体现在聚类结构中?

实验 3: Motif 发现与功能域验证 (→ RQ3)

- 在全部序列和按类型分组的序列上分别运行 MEME, 发现保守 motif, 与 Pfam 域对比
- 分析要点: 发现的 motif 与 Pfam01132 的重合度? 是否存在 Pfam 未覆盖但统计显著的保守区域?

实验 4: 表示质量量化评估 (→ RQ2)

- 线性探测 + CKA: 量化不同表示的可分性和表示相似性
- 分析要点: PLM嵌入是否真正比手工特征捕获了更多 Gvp 家族特异性信息? 还是只是更通用?

选做实验 (从中至多选 2 项)

实验 5: 跨物种模式比较

- 按物种分组分析 motif 差异、保守位点和聚类结构变化
- 分析要点: 哪些模式跨物种稳定? 哪些是物种特异的? 物种间差异与进化距离的关系?

实验 6: 聚类鲁棒性分析

- 多个随机种子下聚类结果的一致性 (ARI between runs)
- 不同降维方法 (t-SNE vs UMAP) 对可视化结论的影响
- 分析要点: 聚类结论是否稳定? 可视化是否引入误导?

实验 7: 无标注 vs 少标注对比

- 对比纯无监督聚类和有标签引导的半监督聚类的结果差异
- 分析要点: 标签信息在多大程度上改变了模式发现的结论?

探索项

- **表示空间的生物学可解释性:** 分析嵌入空间的特定维度是否对应可识别的生物学特征 (如疏水性、二级结构倾向), 探究 PLM 是否以可解释的方式编码了蛋白质物理化学性质。
- **自定义研究问题:** 基于模式发现中的异常现象 (如某类型在嵌入空间中异常分散), 自主提出延伸问题并设计分析。

交付物与里程碑

M1 —问题分析

- 模式发现目标定义 (聚类 / motif / 表示质量)
- 数据来源和构建方案
- 研究问题 (RQ1–RQ3) 拆解和实验计划
- 文献调研 (蛋白质序列模式发现的现有方法)

M2 —初步结果

- 序列长度/物种/类型分布可视化
- 氨基酸组成差异分析
- 简单 k-mer 统计和 MSA 初步对比
- 数据清洗和去冗余流程代码

M3 —中期结果

- 手工特征 + 传统聚类的完整 pipeline
 - 初步聚类结果和可视化
- 初步 motif 发现结果
- 中期检查演示材料——需展示初步的聚类结构和 motif 发现

M4 —完整实验

- PLM 嵌入聚类实验代码与结果
- 不同 PLM 和不同层的对比数据
- 完整 motif 发现与 Pfam 域对比
- 表示质量量化分析 (线性探测 / CKA)
- 选做实验结果

M5 —最终成果

- 完整模式发现报告（含方法、结果、对 RQ1–RQ3 的明确回答、生物学启示）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.1.3 GV01-03: GvpA 功能预测与关键位点归因

动机

GvpA 是 GV 的主壳体蛋白，其氨基酸组成受到强烈约束——内表面疏水、外表面亲水的 β -sheet 结构决定了任意突变都可能破坏壳体合成。如果模型能准确预测 GvpA 的功能属性，并通过归因分析识别出关键位点，且这些位点与 Pfam01132 保守域和 MSA 高保守位点一致，则说明模型学到的不是表面统计特征而是真实的生物学信号。更有价值的是：如果模型关注的高贡献区域中存在 Pfam 未标注但跨物种保守的位点，这可能暗示了尚未被充分研究的潜在功能区域。本项目是“预测 + 发现”的混合范式——预测模型的质量决定了归因分析的可靠性，而归因发现的模式又可能反过来指导特征设计和模型改进。这种双向反馈机制使本项目区别于纯分类任务（GV01-01）和纯模式发现任务（GV01-02），要求学生同时掌握监督预测和可解释性分析两条技术路线。

研究问题

RQ1: 模型预测 GvpA 功能属性时依赖的关键位点，是否与 Pfam01132 保守域和 MSA 高保守位点一致——即模型的决策依据是否具有生物学合理性？

RQ2: 不同归因方法（attention weights / SHAP / Integrated Gradients / Saliency）提取的关键位点是否一致？不一致出现在哪些区域，说明了什么？

RQ3: 是否存在模型一致关注但 Pfam 未标注的保守区域——如果是，这些区域的跨物种保守性和结构特征是否支持其具有功能意义？

任务目标与阶段任务

总目标：训练 GvpA 功能预测模型，使用多种归因方法提取关键位点，与已知功能域对比，探索潜在的未标注功能区域，形成“预测 → 归因 → 发现”的完整链条。

阶段任务：

1. **问题定义与数据构建**（对应 M1）：明确预测目标（功能属性 / 必需性 / 表达成功率），采集 GvpA 序列及标签，使用 similarity-aware split 避免数据泄漏。
2. **探索性数据分析**（对应 M2）：分析 GvpA 序列的保守性分布（MSA + 信息熵），Pfam01132 域的覆盖率和位置分布，标签分布与物种分布的关系。
3. **Baseline 与功能预测**（对应 M3）：使用手工特征 + 传统 ML 建立基线，逐步引入 PLM 嵌入和深度模型。
4. **多方法归因分析**（对应 M4）：在最优模型上使用 ≥ 2 种归因方法（attention / SHAP / IG / Saliency）提取关键位点，计算方法间一致性。
5. **生物学验证与发现**（对应 M4）：归因位点与 Pfam01132 / MSA 高保守位点对比，识别“模型关注但 Pfam 未标注”的区域，分析其跨物种保守性。
6. **总结与改进**（对应 M5）：形成预测 → 归因 → 发现的完整分析报告，讨论归因发现的生物学意义和模型改进方向。

实施方案（建议）

数据构建

- 技术 (建议): NCBI采集 GvpA 序列; CD-HIT 去冗余; 标签来源——Pfam 域存在性 / 文献实验验证 (essential / non-essential); similarity-aware split
- 决策点: 标签质量直接影响归因可靠性——需评估标签噪声水平

特征表示

- 技术 (建议): 手工特征 (k-mer / 组成 / 物理化学) + PLM 嵌入 (ESM2, 残基级和序列级)
- 决策点: 归因分析需要残基级嵌入, 而非仅序列级——pooling策略影响归因粒度

模型架构

- 技术 (建议): SVM / RF (基线); 1D-CNN / Transformer (可归因); ESM2 + LoRA
- 决策点: 选择可归因的模型——Transformer的 attention weights 和 CNN 的 Grad-CAM 提供不同粒度的解释

归因方法

- 技术 (建议): Attention weights (Transformer) / SHAP / Integrated Gradients / Saliency maps / Grad-CAM (CNN); 归因一致性度量——top-k位点重合率 / Spearman 相关 / Jaccard
- 决策点: 不同方法基于不同假设——attention反映模型内部信息流, SHAP/IG 反映特征贡献, 需理解各方法的前提

生物学验证

- 技术 (建议): Pfam01132域位置 / MSA 高保守位点 (信息熵 + Shade) / AlphaFold 结构预测中 pLDDT 低的区域
- 决策点: 归因位点与功能域的重合率是核心评价指标

实验设计与评价

必做实验

实验 1: 功能预测性能 (→ 模型质量保障)

- 在 similarity-aware split 下评估预测性能 (macro-F1 / AUC / MCC)
- 分析要点: 性能是否足够支撑可靠的归因分析——性能过低的模型其归因意义有限

实验 2: 归因位点与已知功能域对比 (→ RQ1)

- 提取 top-k 归因位点, 计算与 Pfam01132 域和 MSA 高保守位点的重合率
- 分析要点: 重合率是否显著高于随机基线? 不重合的归因位点是否集中在特定区域?

实验 3: 归因方法一致性分析 (→ RQ2)

- 使用 ≥ 2 种归因方法, 计算方法间的 top-k 重合率和 Spearman 相关
- 分析要点: 哪些区域是所有方法一致关注的? 哪些区域方法间分歧最大? 分歧说明了什么 (模型内部信号 vs 特征贡献的不同视角)?

实验 4: 未标注保守区域发现 (→ RQ3)

- 识别“模型一致关注但 Pfam 未标注”的区域, 分析其跨物种保守性 (MSA 信息熵) 和结构特征 (AlphaFold pLDDT)
- 分析要点: 这些区域的统计显著性如何? 跨物种保守性是否支持其功能意义?

选做实验 (从中至多选 2 项)

实验 5: 归因指导的特征优化

- 将归因发现的关键位点作为新特征, 重新训练模型, 对比性能变化
- 分析要点: 归因发现是否真正提升了预测——如果是, 说明归因捕获了有效信息

实验 6：跨物种归因稳定性

- 在不同物种子集上分别归因，对比关键位点的一致性
- 分析要点：哪些位点是跨物种稳定的归因目标？哪些是物种特异的？

实验 7：模型架构对归因的影响

- 对比 CNN (Grad-CAM) 和 Transformer (attention) 的归因结果差异
- 分析要点：不同架构的归因粒度和可解释性有何差异？

探索项

- **结构视角的归因验证**：将归因位点映射到 AlphaFold 预测的 3D 结构上，分析高贡献位点是否在结构上聚集（如活性位点或蛋白-蛋白接口）。
- **自定义研究问题**：基于归因中发现的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 预测目标和标签来源定义
- 数据构建方案和 similarity-aware split 设计
- 归因方法选择和生物学验证方案
- RQ1-RQ3 拆解

M2 —初步结果

- GvpA 序列保守性分布 (MSA + 信息熵)
- Pfam01132 域覆盖率和位置分布
- 标签分布与物种分布关系
- 数据清洗流程代码

M3 —中期结果

- 功能预测基线模型
- 初步归因结果（单方法）
- 初步与 Pfam 域对比
- 中期检查演示材料——需展示预测性能和初步归因位点

M4 —完整实验

- 多方法归因实验代码与结果
- 归因一致性分析
- 未标注保守区域发现
- 生物学验证结果
- 选做实验结果

M5 —最终成果

- 完整报告（含预测 → 归因 → 发现链条、对 RQ1-RQ3 的回答、生物学启示）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.2 GV-T02: Gvp 蛋白序列设计与优化

GV 的核心蛋白序列直接决定组装能力和物理特性。计算方法可从已有序列中学习分布规律，系统性地探索更大的序列空间。T02 的六个项目覆盖了从简单生成到多目标优化到主动学习的完整设计链条，逻辑上从”能生成合法序列”逐步推进到”能优化目标性质”和”能用最少评价找到最优候选”。

2.2.1 GV02-01: 蓝藻 GvpA 序列生成

动机

GvpA 是 GV 的主壳体蛋白，其序列空间受到强约束—— β -sheet 刚性壳体要求内表面疏水、外表面亲水，保守域 pfam01132 不可缺失。然而，自然进化仅探索了极小的序列子空间，计算生成方法有望系统性地探索更大的空间，发现自然界不存在的、满足计算层面约束的变体。序列生成的核心挑战不在于”能否产出序列”，而在于”产出的序列在多大程度上满足已知约束条件”。一条好的候选必须在计算层面满足 Pfam 域约束（保守域存在）、新颖性（与已知序列不过度相似）和多样性（候选集内部不趋同）。这三个目标之间可能存在冲突——例如，过度追求新颖性可能破坏保守域，过度追求约束满足可能退化为复制已知序列。因此，如何设计生成模型使其在约束满足度、新颖性和多样性之间取得平衡，并通过系统的评价指标量化生成质量，是本项目的核心问题。

研究问题

RQ1: 不同生成策略（自回归 / VAE / GAN）产出的序列在 Pfam 域约束满足度上的通过率差异如何——哪种策略更善于保持结构约束？

RQ2: 约束满足度、新颖性和多样性三个目标之间的权衡关系如何——是否存在同时优化三者的”甜点”，还是必然存在冲突？

RQ3: 生成序列在 PLM 嵌入空间中的分布与真实序列的差异揭示了什么——模型是否真正学到了 GvpA 序列分布，还是退化为表面统计模仿？

任务目标与阶段任务

总目标: 训练生成模型产出 GvpA 候选序列，构建多维度评价体系量化生成质量（约束满足度/新颖性/多样性/分布），回答不同生成策略的优劣权衡。

阶段任务:

1. **问题定义与数据构建**（对应 M1）：明确生成目标（蓝藻 GvpA），采集序列，去冗余，定义约束满足度/新颖性/多样性指标。
2. **探索性数据分析**（对应 M2）：分析 GvpA 序列长度分布、保守位点分布、氨基酸组成偏好，为生成模型设计提供依据。
3. **Baseline 生成**（对应 M3）：实现随机 k-mer 拼接基线和一个简单生成模型（如 k-mer 频率采样或简单 VAE）。
4. **生成模型对比**（对应 M4）：实现和对比自回归（LSTM/Transformer）/ VAE / GAN，在相同评价体系下比较。
5. **嵌入空间分析**（对应 M4）：将生成序列和真实序列映射到 PLM 嵌入空间，分析分布差异。
6. **总结与改进**（对应 M5）：总结各策略优劣，讨论改进方向。

实施方案（建议）

数据构建

- 技术（建议）：NCBI采集蓝藻 GvpA 序列；CD-HIT 去冗余；Pfam01132 域验证
- 决策点：序列数量是否足够训练生成模型——小样本下 VAE 可能优于自回归

生成模型

- 技术 (建议): 基线——随机 k-mer 拼接 / k-mer 频率采样; 自回归——LSTM / Transformer; VAE——编码器-解码器; GAN——SeqGAN
- 决策点: 不同模型的训练稳定性和样本质量差异——GAN训练不稳定但样本多样性强, VAE 训练稳定但可能模糊

序列表示

- 技术 (建议): one-hot / k-mer / PLM嵌入作为生成模型输入
- 决策点: one-hot简单但维度高, PLM 嵌入信息丰富但可能过拟合

约束满足度验证

- 技术 (建议): HMMER3搜索 Pfam01132 域; BLAST 计算与已知序列的一致性
- 决策点: Pfam E-value阈值如何设定——过严可能淘汰合理变体, 过松可能通过不满足约束的序列

评价体系

- 技术 (建议): 约束满足度 (Pfam域约束满足率) / 新颖性 (BLAST identity < 阈值) / 多样性 (pairwise 距离) / 分布 (PLM 嵌入空间 t-SNE + MMD/核距离 (探索性分布距离指标, 非标准评价指标))
- 决策点: 单一指标不能全面评价——需多维度联合评估

实验设计与评价

必做实验

实验 1: 生成策略对比 (→ RQ1)

- 在相同数据和评价体系下, 对比随机基线 / 自回归 / VAE / GAN 的约束满足度通过率
- 分析要点: 哪种策略最善于保持 Pfam 域? 通过率与生成多样性的关系?

实验 2: 三目标权衡分析 (→ RQ2)

- 对每个生成模型, 绘制约束满足度 vs 新颖性 vs 多样性的权衡曲线
- 分析要点: 三者是否存在同时优化的区域? 不同模型在权衡空间中的位置如何?

实验 3: 消融实验 (→ 模型设计验证)

- 逐层消融: 随机基线 → + 简单生成模型 → + 深度生成模型 → + 针对性优化 (如约束解码 / 罚项)
- 分析要点: 每一步设计对哪些指标有贡献?

实验 4: 嵌入空间分布分析 (→ RQ3)

- 将生成序列和真实序列映射到 ESM2 嵌入空间, t-SNE 可视化 + 分布距离 (MMD / 核距离, 作为探索性分布距离指标, 非标准评价指标)
- 分析要点: 生成序列是否覆盖真实序列的分布区域? 是否存在分布外的“幻觉”样本?

选做实验 (从中至多选 2 项)

实验 5: 约束生成策略

- 在生成过程中引入硬约束 (保守位点锁定) 或软约束 (罚项), 对比约束前后的生成质量
- 分析要点: 约束是否提升了约束满足度? 是否牺牲了多样性?

实验 6: 条件生成探索

- 以物种或功能属性为条件, 探索条件生成是否可控
- 分析要点: 条件信息是否真正影响了生成结果?

实验 7: 生成序列的功能预测

- 使用 GV01-02 / GV01-03 的功能预测模型对生成序列预测功能，间接评估生成质量
- 分析要点：生成序列的预测功能分布是否合理？

探索项

- **结构验证**：使用 AlphaFold/ESMFold 预测生成序列的结构，分析是否保持了 β -sheet 壳体特征——结构层面的约束满足度验证。
- **自定义研究问题**：基于生成结果中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 生成目标和约束定义
- 数据来源和构建方案
- 约束满足度/新颖性/多样性指标定义
- RQ1–RQ3 拆解

M2 —初步结果

- GvpA 序列长度分布、保守位点分布、氨基酸组成分析
- Pfam01132 域覆盖统计
- 数据清洗流程代码

M3 —中期结果

- 随机基线 + 至少一个简单生成模型
- 初步评价指标（约束满足度/新颖性/多样性）
- 中期检查演示材料——需展示生成序列样本和初步评价

M4 —完整实验

- ≥ 2 种深度生成模型代码与结果
- 完整三目标权衡分析
- 消融实验
- 嵌入空间分布分析
- 选做实验结果

M5 —最终成果

- 完整报告（含生成策略对比、权衡分析、对 RQ1–RQ3 的回答）
- 生成序列 FASTA 文件
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.2.2 GV02-02: Gvp 蛋白目标性质预测与设计反馈

动机

在 T02 的序列设计流程中，生成模型（GV02-01）产出的候选序列需要经过性质评估才能进入下游筛选和优化。与 T01 的“从序列识别类型”不同，本项目的核心定位是：构建一个面向设计流程的性质预测器，使其能够对生成序列快速估计目标性质（如功能类别概率、稳定性分值、可表达性估计），并将预测结果反馈到生成或优化环节。这构成了“生成 → 性质预测 → 设计反馈”的闭环：预测器不仅是一个分类/回归模型，更是一个筛选工具，其预测置信度、困难样本识别能力和对生成分布外序列的鲁棒性，直接决定了下游设计流程的效率。核心挑战在于：训练数据来自自然序列分

布，而生成的候选序列可能位于分布外区域——预测器在分布外区域的可靠性如何？不同表示方式（手工特征 vs PLM 嵌入）对分布外的泛化能力差异如何？预测器的置信度能否作为生成质量的间接信号？

研究问题

RQ1: 面向设计流程的性质预测器，在自然序列分布上的性能与在生成序列分布上的性能差异有多大——分布外泛化瓶颈在哪？

RQ2: 不同特征表示（手工特征 vs PLM 嵌入）对生成序列的泛化能力是否一致——哪种表示对分布外更鲁棒？

RQ3: 预测器的置信度（softmax 概率 / 回归不确定性）能否作为生成序列质量的间接信号——高置信度是否对应更高的下游可验证性？

任务目标与阶段任务

总目标: 构建面向序列设计流程的性质预测器，评估其在自然序列和生成序列上的性能差异，建立“预测 → 反馈”的设计闭环。

阶段任务:

1. **问题定义与数据构建**（对应 M1）：明确预测目标（功能分类 / 属性回归 / 可表达性估计），采集 Gvp 序列及标签，构建训练集和生成序列测试集。
2. **探索性分析**（对应 M2）：分析自然序列与生成序列在特征空间中的分布差异（域偏移可视化）。
3. **Baseline 预测**（对应 M3）：在自然序列上训练基线预测器，评估分布内性能。
4. **分布外评估与反馈**（对应 M4）：在生成序列上评估预测器，分析分布外退化，建立置信度 → 质量反馈机制。
5. **总结**（对应 M5）：形成设计反馈分析报告，提出预测器改进建议。

实施方案（建议）

数据构建

- 技术（建议）：UniProt 采集 Gvp 序列及功能/属性标签（自然分布）；GV02-01 的生成序列作为分布外测试集；CD-HIT 去冗余
- 决策点：生成序列的多样性水平如何设定——过窄无法测试泛化，过宽退化随机

特征表示

- 技术（建议）：手工特征（k-mer / 物理化学 / 组成）；PLM 嵌入（ESM2 / ProtBERT）
- 决策点：PLM 的预训练分布是否与 Gvp 蛋白空间重叠——嵌入空间偏移如何影响预测

模型架构

- 技术（建议）：RF / XGBoost（基线）；CNN / Transformer / ESM2+LoRA（进阶）
- 决策点：模型复杂度与分布外鲁棒性的关系——更复杂是否意味着更脆弱

不确定性估计

- 技术（建议）：softmax 置信度 / MC Dropout / 深度集成（Deep Ensemble） / 回归预测区间
- 决策点：不确定性估计能否识别分布外样本——高不确定性是否对应低质量生成序列

实验设计与评价

必做实验

实验 1：分布内 vs 分布外性能（→ RQ1）

- 在自然序列上训练，分别在自然测试集和生成序列集上评估
- 分析要点：分布外性能下降幅度？哪些功能类型退化最严重？退化与生成序列的分布偏移程度的关系？

实验 2：表示方式的分布外泛化（→ RQ2）

- 固定模型架构，对比手工特征 vs PLM 嵌入在分布内/外的性能
- 分析要点：PLM 是否在分布外更鲁棒？还是由于预训练分布偏移反而更脆弱？

实验 3：消融实验

- 基线 → +PLM 嵌入 → + 不确定性估计 → + 域适应
- 分析要点：每步设计对分布外泛化的贡献？

实验 4：置信度 → 质量反馈（→ RQ3）

- 将预测器应用于 GV02-01 生成序列集，按置信度排序，分析高/低置信度序列的下游属性差异
- 分析要点：置信度排序与序列质量（Pfam 域覆盖、保守位点保持率、新颖性）的相关性？

选做实验（从中至多选 2 项）

实验 5：域适应

- 采用 DANN / CORAL / MMD 等域适应方法，利用生成序列的未标注信息提升分布外性能
- 分析要点：域适应能否缓解分布外退化？哪种方法最有效？

实验 6：主动筛选

- 预测器筛选 → 选出 top-k → 人工/结构预测验证 → 反馈标注 → 重新训练
- 分析要点：主动筛选策略的效率？标注预算与筛选质量的权衡？

实验 7：多目标预测器

- 同时预测功能类别 + 稳定性 + 可表达性，分析目标间的相关性
- 分析要点：多目标联合预测是否优于独立预测？

探索项

- **预测器 → 生成条件**：将预测器作为生成模型的条件信号——引导生成模型产出高置信度序列——从”预测 → 反馈”升级为”预测 → 引导生成”。
- **自定义研究问题**：基于分布外分析中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 预测目标定义和标签来源
- 自然序列 vs 生成序列的分布差异假设
- RQ1-RQ3 拆解

M2 —初步结果

- 域偏移可视化（自然 vs 生成序列特征空间对比）
- 数据加载和预处理代码

M3 —中期结果

- 分布内基线预测器训练和性能
- 初步分布外性能评估
- 中期检查演示材料

M4 —完整实验

- 分布外泛化对比实验

- 不确定性估计和反馈机制
- 消融和选做实验

M5 —最终成果

- 完整报告（含分布外分析、表示对比、对 RQ1–RQ3 的回答、设计反馈建议）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.2.3 GV02-03: 多目标候选评价

动机

生成模型产出的候选序列需要经过严格筛选才能进入下游验证。一条好的候选需同时满足多个目标：Pfam 域约束满足度（功能约束）、关键位点保守性（结构稳定）、新颖性（与已知序列不过度相似）、多样性（候选集不趋同）。这些目标之间可能存在冲突——例如，新颖性高的序列可能保守性不足，多样性高的集合可能包含较多不满足约束的序列。如何设计多目标评价函数，使得筛选结果在各个维度上均衡优良，且对评价函数的参数扰动具有鲁棒性，是连接“生成”与“验证”的关键环节。本项目不训练新模型，而是构建评价和筛选系统，要求学生理解多目标决策的本质——不存在单一“最优”聚合策略，不同策略服务于不同的下游应用需求。

研究问题

■ **RQ1:** 约束满足度、保守性、新颖性和多样性四个目标之间的冲突结构如何——哪些目标正相关，哪些负相关？

■ **RQ2:** 不同聚合策略（加权求和 / Pareto 排序 / Top-k per dimension）对最终筛选结果的影响差异如何——哪种策略在什么条件下更优？

■ **RQ3:** 评价函数的鲁棒性如何——权重或阈值的微调是否导致筛选结果显著变化？

任务目标与阶段任务

总目标：为 GvpA 候选序列构建多目标评价体系，比较不同聚合和筛选策略，评估评价函数的鲁棒性。

阶段任务：

1. **问题定义**（对应 M1）：明确评价维度、指标定义和数据来源（使用 GV02-01 的生成序列或自行生成）。
2. **探索性数据分析**（对应 M2）：分析候选序列在各维度上的分布和相关性结构。
3. **评价体系实现**（对应 M3）：实现各维度指标的计算 pipeline。
4. **聚合策略对比**（对应 M4）：实现和对比 ≥ 3 种聚合策略，分析筛选结果差异。
5. **鲁棒性分析**（对应 M4）：评价函数参数扰动下的筛选结果稳定性。
6. **总结**（对应 M5）：给出各策略的适用场景建议。

实施方案（建议）

评价指标

- 技术（建议）：约束满足度——HMMER Pfam扫描 E-value；保守性——关键位点保守率（基于 MSA）；新颖性——BLAST identity 最小值；多样性——pairwise 序列距离均值
- 决策点：每个指标的阈值如何设定——需基于数据分布而非主观指定

聚合策略

- 技术（建议）：加权求和（权重扫描）/ Pareto排序（非支配排序）/ Top-k per dimension（各维度保留最优 k 条）/ 混合策略

- 决策点：不同策略服务于不同下游需求——Pareto保留多样性，加权求和可控偏好

鲁棒性分析

- 技术（建议）：权重扰动（ $\pm 20\%$ ）、阈值扰动、Bootstrap重采样
- 决策点：筛选结果的变化率——高风险评价函数应被识别和改进

实验设计与评价

必做实验

实验 1：维度间相关性分析（→ RQ1）

- 计算四个维度间的 Pearson / Spearman 相关，可视化散点矩阵
- 分析要点：哪些维度正相关/负相关？冲突最严重的维度对是哪个？

实验 2：聚合策略对比（→ RQ2）

- 在相同候选集上，对比 ≥ 3 种聚合策略的筛选结果（重叠度 / 各维度质量 / Pareto 前沿大小）
- 分析要点：不同策略选出的候选有何差异？哪种策略在哪个维度上更优？

实验 3：消融实验

- 逐个移除维度，分析该维度对筛选结果的影响
- 分析要点：哪个维度是“不可或缺”的？哪个维度冗余？

实验 4：鲁棒性分析（→ RQ3）

- 权重和阈值扰动下筛选结果的变化率（Jaccard距离 / 排名变化）
- 分析要点：评价函数在哪些参数区域敏感？如何提高鲁棒性？

选做实验（从中至多选 2 项）

实验 5：下游验证代理

- 使用 GV02-02 的性质预测模型对筛选子集预测性质，间接评估筛选质量
- 分析要点：筛选出的候选是否具有合理的性质预测分布？

实验 6：Pareto 前沿分析

- 在四维目标空间中绘制 Pareto 前沿，分析前沿序列的特征
- 分析要点：前沿序列在哪些维度上“最优”？是否共享某些序列特征？

实验 7：与随机筛选对比

- 对比多目标评价与随机筛选的效果差异
- 分析要点：多目标评价的优势有多大？是否在所有维度上都优于随机？

探索项

- 自定义评价维度：学生自主提出一个新的评价维度（如结构稳定性预测、组装兼容性评分），分析其与现有维度的关系和对筛选结果的影响。
- 自定义研究问题：基于筛选结果中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 评价维度和指标定义
- 数据来源和候选集构建方案
- RQ1-RQ3 拆解

M2 —初步结果

- 候选序列在各维度上的分布可视化
- 维度间相关性初步分析
- 指标计算 pipeline 代码

M3 —中期结果

- 完整四维度评价 pipeline
- 初步聚合策略实现
- 初步筛选结果
- 中期检查演示材料

M4 —完整实验

- ≥ 3 种聚合策略对比实验
- 消融实验
- 鲁棒性分析
- 选做实验结果

M5 —最终成果

- 完整报告（含维度冲突分析、策略对比、对 RQ1–RQ3 的回答、适用场景建议）
- 评价工具代码 + 筛选结果数据
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.2.4 GV02-04: 定向序列优化

动机

从零生成（GV02-01）适合探索广阔的序列空间，但在已有优良候选的基础上，定向优化——在保持已有优点的同时改进特定目标性质——是一种更精细的设计策略。定向优化的核心挑战在于”保持”与”改进”之间的张力：优化目标性质（如性质预测分值、结构稳定性）时，不能破坏 Pfam 保守域和关键位点，否则序列失去计算层面的约束满足度。这本质上是一个约束优化问题——在硬约束（保守位点锁定）和软约束（组成偏好、GC 含量）下最大化目标函数。不同优化策略（梯度引导 / 强化学习 / 进化策略 / 贝叶斯优化）在收敛性、样本效率和约束满足能力上各有优劣。理解这些策略在 GvpA 优化中的适用性和局限，对实际设计流程的策略选择具有直接指导意义。

研究问题

RQ1: 在保持 Pfam 域约束满足的前提下，定向优化能达到的性质提升极限在哪里——提升幅度与序列变化量之间是什么关系？

RQ2: 不同优化策略（梯度引导 / 强化学习 / 进化策略 / 贝叶斯优化）在收敛速度、样本效率和约束满足率上如何对比？

RQ3: 优化后的序列是否引入了新的问题——如功能变化、结构不稳定或组装接口不兼容？

任务目标与阶段任务

总目标: 给定蓝藻 GvpA 参考序列，在保持 Pfam 域约束满足和关键位点保守的前提下，定向优化某项目标性质，比较不同优化策略的效果。

阶段任务:

1. **问题定义** (对应 M1): 明确优化目标 (性质预测分值 / 结构稳定性 / 物理化学性质)、约束条件 (Pfam 域 / 保守位点)、参考序列。
2. **探索性数据分析** (对应 M2): 分析参考序列的保守位点分布、Pfam 域位置、可变区域。
3. **Baseline 优化** (对应 M3): 实现随机突变基线 + 简单优化策略 (如贪心搜索)。
4. **优化策略对比** (对应 M4): 实现和对比 ≥ 2 种深度优化策略。
5. **约束满足与副作用分析** (对应 M4): 验证优化序列的 Pfam 域约束满足度、保守位点完整性、结构稳定性。
6. **总结** (对应 M5): 给出各策略的适用场景和改进方向。

实施方案 (建议)

优化目标

- 技术 (建议): 性质预测分值 (使用 GV02-02 模型) / 结构稳定性 (AlphaFold pLDDT / 聚集倾向) / 物理化学性质 (疏水性 / 等电点)
- 决策点: 目标函数需可微分 (梯度引导) 或可评估 (黑盒优化)

约束机制

- 技术 (建议): 硬约束——保守位点掩码锁定; 软约束——罚项 (GC 含量 / 组成偏好 / 二级结构倾向)
- 决策点: 硬约束保证安全性但限制搜索空间, 软约束灵活但可能不满足

优化策略

- 技术 (建议): 梯度引导 (可微目标函数 + 投影到合法空间) / 强化学习 (奖励 = 目标提升 - 约束违反罚项) / 进化策略 (CMA-ES / 遗传算法) / 贝叶斯优化 (高斯过程代理)
- 决策点: 不同策略的样本效率和约束满足能力——梯度引导快但需可微目标, 进化策略通用但样本效率低

验证

- 技术 (建议): HMMER Pfam 扫描 / 关键位点对比 / AlphaFold 结构预测 / 组装接口兼容性评估
- 决策点: 优化后的序列是否在保持约束满足度的同时真正改进了目标?

实验设计与评价

必做实验

实验 1: 优化策略对比 (→ RQ2)

- 在相同参考序列和目标函数下, 对比 ≥ 2 种优化策略的收敛曲线和最终提升
- 分析要点: 哪种策略收敛最快? 哪种达到的最高目标值? 样本效率如何?

实验 2: 约束满足率 (→ RQ1, RQ3)

- 统计各策略产出序列的 Pfam 域约束满足率、保守位点保持率
- 分析要点: 约束满足与目标提升是否矛盾——提升越大是否约束违反越多?

实验 3: 消融实验

- 随机突变 → + 贪心搜索 → + 深度优化策略 → + 约束机制
- 分析要点: 每步设计对目标提升和约束满足的贡献?

实验 4: 副作用分析 (→ RQ3)

- 分析优化序列的结构变化 (AlphaFold pLDDT)、性质预测变化 (GV02-02 模型)、与参考序列的差异分布
- 分析要点: 优化是否引入了非预期变化? 哪些区域被意外修改?

选做实验 (从中至多选 2 项)

实验 5: 多目标优化

- 同时优化多个目标（如功能分值 + 结构稳定性），分析目标间冲突
- 分析要点：多目标 Pareto 前沿的特征？

实验 6：参考序列敏感性

- 使用不同物种的 GvpA 作为参考，对比优化效果
- 分析要点：优化效果是否依赖于参考序列的选择？

实验 7：优化序列的下游验证

- 使用 GV02-03 的评价体系全面评估优化序列
- 分析要点：优化序列在四维度评价中的表现？

探索项

- **组装兼容性分析**：将优化序列与 GV 其他蛋白的接口位点对比，分析是否保持了组装兼容性——GV 设计的全局视角。
- **自定义研究问题**：基于优化中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 优化目标、约束条件和参考序列定义
- 策略选择和预期方案
- RQ1–RQ3 拆解

M2 —初步结果

- 参考序列保守位点和可变区域分析
- Pfam 域位置和组装接口位点标注
- 约束掩码设计代码

M3 —中期结果

- 随机突变 + 贪心搜索基线
- 初步优化结果和约束验证
- 中期检查演示材料——需展示初步优化效果

M4 —完整实验

- ≥ 2 种深度优化策略实现和对比
- 完整约束满足和副作用分析
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含策略对比、约束分析、对 RQ1–RQ3 的回答）
- 优化序列数据
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.2.5 GV02-05: 跨物种序列生成

动机

GV 分布于蓝藻和古菌等不同进化谱系中，不同物种间的 GvpA 序列差异可达 20–40%，反映了进化适应和功能特化。如果生成模型能学习这种物种间分布差异，并以物种标签为条件生成目标物种风格的序列，就能突破数据稀缺物种的样本限制——例如，古菌 GvpA 序列远少于蓝藻，条件生成可从蓝藻数据中学习通用规律并迁移到古菌风格。然而，跨物种条件生成的核心挑战在于“条件可控性”和“分布保真度”的矛盾：模型可能生成了“看起来像古菌”的序列但缺乏古菌 GvpA 的关键功能特征，或者条件信号太弱导致生成结果与条件无关。评估条件生成质量需要一个独立于生成模型的外部评价器——物种分类器，以及生物学验证（Pfam 域 / BLAST），避免“自验证”偏差。

研究问题

■ **RQ1**：条件生成模型能否产出具有目标物种风格特征的序列——独立物种分类器的判别准确率说明了什么？

■ **RQ2**：跨物种生成的瓶颈在于数据不平衡（古菌样本太少）还是模型条件控制能力不足——如何区分？

■ **RQ3**：生成序列的物种特异性位点与真实物种间差异位点的对应关系如何——模型学到了哪些物种区分特征？

任务目标与阶段任务

总目标：训练条件生成模型，以物种标签为条件生成 GvpA 序列，使用独立方法评估条件可控性和计算层面的约束满足度。

阶段任务：

1. **问题定义与数据构建**（对应 M1）：采集蓝藻和古菌 GvpA 序列，标注物种标签，去冗余。
2. **物种差异分析**（对应 M2）：分析物种间序列差异位点、组成偏好和保守性差异。
3. **Baseline 生成**（对应 M3）：无条件的基线生成模型 + 随机物种标签基线。
4. **条件生成**（对应 M4）：实现条件 VAE / 迁移学习 / 对抗域适应。
5. **条件评估**（对应 M4）：训练独立的物种分类器，评估条件可控性。
6. **生物学验证**（对应 M5）：Pfam 域 / BLAST / 物种特异性位点分析。

实施方案（建议）

数据构建

- 技术（建议）：NCBI 采集蓝藻 + 古菌 GvpA；按物种标注；CD-HIT 去冗余；评估数据不平衡程度
- 决策点：古菌样本太少时，考虑数据增强或迁移学习策略

条件生成模型

- 技术（建议）：条件 VAE（物种标签 one-hot 条件化）/ 迁移学习（蓝藻预训练 → 古菌微调）/ 对抗域适应（DANN）/ 自回归条件生成
- 决策点：不同策略对数据不平衡的敏感度不同——迁移学习可能更适合极端不平衡

独立评价器

- 技术（建议）：训练独立的物种分类器（不使用生成模型的编码器）；使用分类器判断生成序列的物种归属
- 决策点：评价器必须与生成模型不同源——否则会产生“自验证”偏差

生物学验证

- 技术（建议）：HMMER Pfam 扫描；BLAST 与已知序列对比；物种特异性位点分析（真实 vs 生成）
- 决策点：条件生成了“看起来像”还是“真的是”目标物种风格？

实验设计与评价

必做实验

实验 1：条件可控性评估（→ RQ1）

- 用独立物种分类器判断生成序列的物种归属，计算命中率
- 分析要点：命中率是否显著高于随机？不同物种的命中率差异如何？

实验 2：生成策略对比（→ RQ2）

- 对比条件 VAE / 迁移学习 / 对抗域适应的条件控制效果
- 分析要点：哪种策略在数据不平衡下更鲁棒？瓶颈是数据还是模型？

实验 3：消融实验

- 无条件基线 → + 随机条件 → + 条件模型 → + 针对性优化
- 分析要点：条件信号在多大程度上影响了生成结果？

实验 4：物种特异性位点分析（→ RQ3）

- 对比真实物种间差异位点和生成序列的物种特异性位点
- 分析要点：模型学到的物种区分特征与真实差异的对应度？

选做实验（从中至多选 2 项）

实验 5：少样本条件生成

- 在古菌样本极少（< 10 条）的条件下，测试条件生成效果
- 分析要点：少样本条件下条件生成是否仍然有效？

实验 6：条件强度控制

- 调节条件信号强度（如 β -VAE 的 KL 权重），分析条件控制与多样性的权衡
- 分析要点：条件越强是否多样性越低？是否存在最优平衡点？

实验 7：生成序列性质预测

- 使用 GV02-02 的性质预测模型评估生成序列
- 分析要点：条件生成是否保持了功能合理性？

探索项

- **进化路径推测**：分析生成序列在物种间的“中间态”特征——是否存在介于蓝藻和古菌风格之间的序列？这能否推测进化路径？
- **自定义研究问题**：基于条件生成中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 条件生成目标和物种标签定义
- 数据构建方案和不平衡分析
- 独立评价器设计
- RQ1-RQ3 拆解

M2 —初步结果

- 物种间序列差异位点分析
- 组成偏好和保守性差异
- 数据不平衡程度评估
- 预处理流程代码

M3 —中期结果

- 无条件基线 + 简单条件模型

- 初步条件评估结果
- 中期检查演示材料

M4 —完整实验

- ≥ 2 种条件生成策略实现和对比
- 独立评价器训练和评估
- 物种特异性位点分析
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含条件可控性分析、策略对比、对 RQ1–RQ3 的回答）
- 生成序列 FASTA 文件
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.2.6 GV02-06: 主动学习驱动的迭代设计

动机

在 GV 序列设计的实际流程中，候选序列的评价（如功能预测、结构验证）是有成本的——每条候选的评价消耗计算资源或实验资源。如果评价预算有限（如只能验证 50 条候选），随机选择 50 条很可能错过最优候选。主动学习的核心思想是：智能选择“信息量最大”的候选进行评价，用最少的的评价次数达到最好的设计效果。这本质上是一个探索与探究（exploration and exploitation）的权衡——探索未评价区域可能发现更好的候选，探究已评价区域附近可能优化已有候选。不同采样策略（不确定性采样 / 期望改善 / 多样性采样）在这个权衡中偏重不同。理解这些策略在 GV 设计中的适用性和局限，对实际设计流程的效率优化具有直接价值。本项目是 GV02 系列的收尾——将生成（GV02-01）、评价（GV02-03）和优化（GV02-04）串联为闭环系统。

研究问题

RQ1: 主动采样策略相比随机采样在有限评价预算下的优势有多大——在什么预算范围内优势最显著？

RQ2: 不同采样策略（不确定性 / 期望改善 / 多样性 / 混合）的适用场景和局限——各自在探索-探究权衡中的位置如何？

RQ3: 代理模型对真实评价函数的近似质量如何——哪些区域近似准确，哪些区域偏差大？代理质量如何影响主动学习的效果？

任务目标与阶段任务

总目标: 构建闭环设计系统（生成 → 评价 → 主动采样 → 反馈），在有限评价预算内比较不同采样策略的效果。

阶段任务:

1. **问题定义**（对应 M1）：明确评价预算、候选池来源（使用前序项目的生成序列或自行生成）、目标函数。
2. **探索性分析**（对应 M2）：分析候选池在目标空间的分布、聚类结构。
3. **Baseline 系统**（对应 M3）：实现随机采样基线 + 代理模型训练。
4. **主动学习策略**（对应 M4）：实现 ≥ 2 种采样策略，运行闭环迭代。
5. **策略对比与代理分析**（对应 M4）：绘制收敛曲线，分析代理模型质量。
6. **总结**（对应 M5）：给出策略适用场景和系统改进建议。

实施方案（建议）

闭环系统

- 技术（建议）：生成器（可复用 GV02-01 模型）→ 评价器（真实评价函数）→ 代理模型（轻量近似）→ 主动采样 → 反馈更新
- 决策点：代理模型的选择应与目标函数特性匹配——回归树适合离散目标，GP 适合连续目标

采样策略

- 技术（建议）：不确定性采样（代理模型预测不确定性最高的候选）/ 期望改善（EI / UCB）/ 多样性采样（覆盖未探索区域）/ 混合策略
- 决策点：不同策略在探索-探究权衡中的偏重——不确定性偏探究，EI 平衡两者

代理模型

- 技术（建议）：随机森林 / 高斯过程 / 轻量神经网络；代理校准（预测值 vs 真实值的 Spearman 相关）
- 决策点：代理质量是主动学习效果的关键——代理不准确时主动学习可能不如随机

实验设计与评价

必做实验

实验 1：采样策略对比（→ RQ1, RQ2）

- 在相同预算和候选池下，对比随机 / 不确定性 / EI / 多样性的收敛曲线
- 分析要点：哪种策略收敛最快？最终找到的最优候选质量差异？预算大小对策略排名的影响？

实验 2：代理模型质量分析（→ RQ3）

- 在不同迭代轮次评估代理模型的预测质量（Spearman ρ / RMSE）
- 分析要点：代理在哪些区域准确/偏差？代理质量如何影响采样决策？

实验 3：消融实验

- 随机采样 → + 代理模型 → + 主动策略 → + 混合策略
- 分析要点：代理模型的贡献 vs 采样策略的贡献？

实验 4：预算敏感性分析（→ RQ1）

- 在不同预算（10/30/50/100）下对比各策略效果
- 分析要点：预算越小主动学习优势越大？在什么预算下主动学习不再有优势？

选做实验（从中至多选 2 项）

实验 5：多目标主动学习

- 在多目标空间（约束满足度 + 功能 + 新颖性）中进行主动采样
- 分析要点：多目标 EI 如何计算？策略效果如何？

实验 6：代理模型对比

- 对比 RF / GP / NN 作为代理模型的效果
- 分析要点：哪种代理最适合 GvpA 评价函数？

实验 7：与批量评价对比

- 对比主动逐条评价和批量评价的效率
- 分析要点：主动学习在什么条件下比批量评价更高效？

探索项

- **人机协作设计**：将主动学习推荐的高不确定性候选展示给领域专家（或教师），结合人工判断进行筛选——探索人机协作的设计模式。
- **自定义研究问题**：基于闭环系统中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 评价预算和目标函数定义
- 候选池来源和闭环系统架构
- RQ1-RQ3 拆解

M2 —初步结果

- 候选池在目标空间的分布分析
- 聚类结构和密度分析
- 代理模型训练代码

M3 —中期结果

- 随机采样基线 + 代理模型训练 pipeline
- 初步闭环迭代结果
- 中期检查演示材料——需展示闭环系统运行

M4 —完整实验

- ≥ 2 种采样策略实现和对比
- 收敛曲线和代理质量分析
- 预算敏感性分析
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含策略对比、代理分析、预算敏感性、对 RQ1-RQ3 的回答、系统改进建议）
- 闭环系统代码 + 迭代日志
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.3 GV-T03: 气囊基因线路建模与设计

GV 组装需约 10 种 Gvp 蛋白协同表达，基因调控层面决定表达水平。T03 从蛋白质层面下沉到基因线路层面，关注调控序列预测、操纵子模式发现和多基因协同优化。三个项目覆盖了从“单基因表达预测”到“操纵子模式发现”再到“多基因协同优化”的递进逻辑。

2.3.1 GV03-01: Gvp 启动子强度预测与跨物种迁移

动机

GV 基因簇的表达水平首先取决于启动子强度。GvpE 作为转录激活因子结合在 gvp 启动子区域，GvpD 作为抑制因子拮抗 GvpE——这对调控开关决定了 GV 基因簇是否“开启”。然而，GV 系统的实验表达数据极为稀缺——绝大多数启动子强度数据来自 E. coli 等模式生物，Gvp 启动子的实测强度数据几乎没有。这意味着模型必须在 E. coli 数据上学习通用的启动子-强度映射规律，然后迁移到 Gvp 启动子预测。跨物种迁移的核心挑战在于：Gvp 启动子可能具有 E.

coli 数据中不常见的特征（如 GvpE 结合位点），模型在分布外数据上的泛化能力是关键瓶颈。理解迁移性能下降的原因——是序列特征差异还是模型表示能力不足——对设计迁移策略至关重要。

研究问题

RQ1: 在 E. coli 启动子-表达数据上训练的强度预测模型，零样本迁移到 Gvp 启动子的性能下降幅度有多大——下降来自什么原因？

RQ2: 哪些迁移策略（零样本 / 少样本微调 / 特征迁移 / 域适应）在不同数据条件下效果最优——迁移效果是否取决于 Gvp 与 E. coli 启动子的序列差异程度？

RQ3: Gvp 启动子与 E. coli 启动子的序列特征差异（-10/-35 box / GvpE 结合位点 / GC 含量）如何解释迁移性能下降？

任务目标与阶段任务

总目标: 在 E. coli 启动子数据上训练强度预测模型，设计多种迁移策略应用于 Gvp 启动子预测，分析迁移性能下降的原因。

阶段任务:

1. **问题定义与数据构建**（对应 M1）：明确预测目标（启动子强度回归），采集 E. coli 启动子-表达数据和多物种 gvp 上游序列。
2. **探索性数据分析**（对应 M2）：分析 E. coli 和 Gvp 启动子的序列特征差异（-10/-35 box / GC / 长度）。
3. **Baseline 预测**（对应 M3）：在 E. coli 数据上训练基线模型，评估 E. coli 内性能。
4. **迁移实验**（对应 M4）：实现 ≥ 3 种迁移策略，评估 Gvp 迁移性能。
5. **迁移分析**（对应 M4）：对比迁移性能下降，分析原因。
6. **总结**（对应 M5）：给出迁移策略建议和改进方向。

实施方案（建议）

数据构建

- 技术（建议）：E. coli 启动子-表达数据（如 Promoter Calculator 数据集 / MPRA 数据）；多物种 gvp 上游序列（NCBI 基因组注释提取）；与 Promoter Calculator (Salis Lab) 对比
- 决策点：Gvp 启动子是否有实验强度数据——如果没有，只能定性评估（排序一致性）

特征表示

- 技术（建议）：k-mer / one-hot / PWM（位置权重矩阵）/ DNA 大模型嵌入（DNABERT-2 / LucaOne）
- 决策点：DNA 大模型可能捕获更通用的启动子特征，有利于迁移

模型架构

- 技术（建议）：Ridge / CNN / Transformer / DNABERT-2 + LoRA
- 决策点：模型选择应考虑迁移能力——预训练模型可能迁移性更好

迁移策略

- 技术（建议）：零样本（直接预测，无 Gvp 微调）/ 少样本微调（少量 Gvp 数据微调）/ 特征迁移（共享编码器）/ 域适应（DANN）
- 决策点：不同策略需要不同量的 Gvp 数据——零样本不需要但可能最差，少样本微调需要标注数据

实验设计与评价

必做实验

实验 1: E. coli 基线性能（→ 模型质量保障）

- 在 E. coli 数据上评估模型性能 (R^2 / Spearman ρ / MAE)
- 分析要点: 基线性能是否足够支撑迁移实验——性能过低的模型迁移意义有限

实验 2: 迁移策略对比 (→ RQ1, RQ2)

- 对比零样本 / 少样本 / 特征迁移 / 域适应在 Gvp 启动子上的性能
- 分析要点: 迁移性能下降幅度? 不同策略的差异? 下降原因分析

实验 3: 消融实验

- E. coli only → +DNA 大模型预训练 → + 少样本微调 → + 域适应
- 分析要点: 每步设计对迁移性能的贡献?

实验 4: 序列特征差异分析 (→ RQ3)

- 对比 E. coli 和 Gvp 启动子的 -10/-35 box / GC / GvpE 结合位点
- 分析要点: 哪些特征差异最大? 这些差异是否与迁移性能下降相关?

选做实验 (从中至多选 2 项)

实验 5: 与 Promoter Calculator 对比

- 将模型预测与 Salis Lab Promoter Calculator 对比
- 分析要点: 专用工具 vs 数据驱动模型的迁移能力差异?

实验 6: GvpE 结合位点影响

- 分析含/不含 GvpE 结合位点的 Gvp 启动子的预测差异
- 分析要点: 模型是否感知了 GvpE 结合位点的影响?

实验 7: 跨物种迁移矩阵

- 在多个物种间构建迁移矩阵, 分析迁移性能的对称性
- 分析要点: 迁移性能是否对称? 哪些物种对迁移最困难?

探索项

- **GvpE/D 调控建模:** 尝试将 GvpE 结合位点的存在和位置作为特征, 预测 GvpE 依赖型启动子的激活倍数——探索调控层面的预测。
- **自定义研究问题:** 基于迁移分析中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 预测目标和数据来源
- E. coli 和 Gvp 启动子的特征差异初步分析
- 迁移策略设计和评价方案
- RQ1-RQ3 拆解

M2 —初步结果

- E. coli 和 Gvp 启动子序列特征对比 (-10/-35 / GC / 长度)
- GvpE 结合位点位置分析
- 数据清洗和划分流程代码

M3 —中期结果

- E. coli 基线模型训练
- 零样本迁移初步结果

- 中期检查演示材料——需展示 E. coli 性能和零样本迁移效果

M4 —完整实验

- ≥ 3 种迁移策略实验
- 迁移性能下降原因分析
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含迁移策略对比、特征差异分析、对 RQ1–RQ3 的回答）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.3.2 GV03-02: gvp 操纵子调控模式发现

动机

gvp 操纵子的调控逻辑尚未被完全揭示——GvpE/D 结合位点的精确位置、各基因 RBS 的强度分布规律、基因间距与转录调控的关系，这些信息分散在文献和数据库中，缺乏系统性的计算分析。从多物种 gvp 操纵子调控区域发现保守 motif、RBS 分布规律和基因间距调控信号，不仅能填补 GV 调控知识的空白，还能为 GV03-03 的基因线路优化提供数据基础。本项目是纯模式发现类型——不训练预测模型，而是从序列数据中挖掘模式。核心挑战在于：发现的模式是否具有统计显著性和生物学合理性——保守 motif 的 E-value 是否足够小？RBS 分布是否与基因功能角色相关？不同物种间的调控模式差异是否反映了进化适应？这些发现需要在多数据集上验证一致性。

研究问题

RQ1: 从多物种 gvp 操纵子调控区域发现的保守 motif，是否与已知调控元件（GvpE 结合位点 / -10/-35 box / RBS）对应？

RQ2: 各基因的 RBS 强度分布是否与基因在操纵子中的位置和功能角色（必需 vs 增强）相关——存在什么规律？

RQ3: 不同物种间 gvp 操纵子的调控模式差异揭示了什么——是否存在物种特异的调控策略？

任务目标与阶段任务

总目标：从多物种 gvp 操纵子调控区域发现保守 motif、RBS 分布规律和基因间距调控信号，与已知调控元件对比，分析跨物种差异。

阶段任务：

1. **问题定义与数据构建**（对应 M1）：明确模式发现目标，采集多物种 gvp 基因簇序列和注释。
2. **探索性数据分析**（对应 M2）：分析 gvp 操纵子结构、基因排列、基因间距分布。
3. **Motif 发现**（对应 M3）：MEME/DREME 搜索保守 motif，与 RegulonDB/文献对比。
4. **RBS 和基因间距分析**（对应 M4）：RBS Calculator 计算各基因强度，分析分布规律；基因间距与调控关系分析。
5. **跨物种比较**（对应 M4）：不同物种间 motif / RBS / 基因间距的差异分析。
6. **总结**（对应 M5）：形成 gvp 调控模式发现报告。

实施方案（建议）

数据构建

- 技术（建议）：NCBI采集多物种 gvp 基因簇序列和注释；提取启动子区域 / RBS 区域 / 基因间距

- 决策点：物种覆盖度——蓝藻 + 古菌 + 其他，保证进化多样性

Motif 发现

- 技术 (建议): MEME / DREME / STREME 发现 de novo motif; FIMO / MAST 在序列中定位; 与 RegulonDB / 文献已知的 GvpE 结合位点 / σ^{54} -10/-35 box 对比
- 决策点: motif E-value 阈值——生物学显著 vs 统计显著

RBS 分析

- 技术 (建议): RBS Calculator (Salis Lab) 计算各基因翻译起始速率; 分析 RBS 强度与基因功能角色 (必需 vs 增强) 的关系
- 决策点: RBS 强度分布是否与操纵子位置相关 (如首位基因 RBS 最强)?

基因间距分析

- 技术 (建议): 统计相邻基因间距分布; 短间距 (翻译耦合) / 中间距 (独立 RBS) / 长间距 (独立启动子) 分类
- 决策点: 间距分布是否暗示 operon 拆分点?

实验设计与评价

必做实验

实验 1: Motif 发现与已知调控元件对比 (→ RQ1)

- MEME 发现的 motif 与 GvpE 结合位点 / -10/-35 box / RBS (AGGAGG) 对比
- 分析要点: 重合度如何? 是否存在未知的保守 motif? E-value 是否足够小?

实验 2: RBS 强度分布分析 (→ RQ2)

- RBS Calculator 计算各基因强度, 分析分布与功能角色的关系
- 分析要点: 必需基因 (gvpA/C/F/L/N) 的 RBS 是否强于增强基因? 首位基因是否最强?

实验 3: 跨物种保守性分析 (→ RQ3)

- 分析核心 motif / RBS 分布 / 基因间距在不同物种间的一致性
- 分析要点: 哪些模式跨物种稳定? 哪些是物种特异的? 物种间差异与进化距离的关系?

实验 4: 基因间距与调控关系

- 分析基因间距分布与操纵子结构的关系
- 分析要点: 间距分布是否暗示 operon 拆分点? 是否存在独立的内部启动子?

选做实验 (从中至多选 2 项)

实验 5: GvpE/D 调控网络推断

- 基于 GvpE/D 结合位点和基因共现关系, 推断 gvp 调控网络
- 分析要点: GvpE 调控哪些基因? 网络拓扑特征?

实验 6: 终止子分析

- 预测 gvp 基因间终止子, 分析终止效率与基因表达的关系
- 分析要点: 终止子分布是否影响操纵子内各基因的相对表达量?

实验 7: 与 RegulonDB 对比

- 将发现的 motif 与 RegulonDB 中的 E. coli 调控元件对比
- 分析要点: gvp 调控元件与通用细菌调控元件的相似性和差异?

探索项

- **调控网络建模**：将发现的所有调控元件整合为 gvp 操纵子的调控网络模型，可视化元件间的调控关系——系统生物学视角。
- **自定义研究问题**：基于模式发现中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 模式发现目标和数据来源
- 物种覆盖度和操纵子结构初步分析
- RQ1–RQ3 拆解

M2 —初步结果

- gvp 操纵子结构可视化
- 基因排列和间距分布统计
- 物种间操纵子结构差异分析
- 数据提取和清洗流程代码

M3 —中期结果

- MEME/DREME 运行和结果
- 初步与已知调控元件对比
- RBS Calculator 初步结果
- 中期检查演示材料——需展示发现的 motif 和 RBS 分布

M4 —完整实验

- 完整 motif 分析和功能元件对比
- RBS 分布规律分析
- 基因间距分析
- 跨物种保守性分析
- 选做实验结果

M5 —最终成果

- 完整模式发现报告（含 motif / RBS / 间距分析、对 RQ1–RQ3 的回答、生物学启示）
- 模式发现结果数据
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

2.3.3 GV03-03: gvp 基因簇多基因协同表达优化

动机

GV 组装要求约 10 种 Gvp 蛋白以特定比例协同表达——GvpA 需要大量（构成壳体），GvpC 少量（壳外加固），GvpF/L/N 适量（组装起始）。比例失衡会导致组装失败：GvpA 过多则壳体碎片化，GvpC 过多则过度加固导致气囊无法膨胀。在异源表达中（如 *E. coli*），天然 gvp operon 的各基因比例往往不匹配，因为宿主的翻译系统与天然宿主不同。多基因协同表达优化的核心是：给定 gvp 基因簇拓扑和目标表达比例，调整各基因的 RBS 强度（和可能的 operon 拆分方案），使表达比例匹配目标。这是一个高维约束优化问题——搜索空间是各基因 RBS 强度的组合，约束包括 RBS 约束满足度、operon 完整性和总量预算，目标是比例匹配度。不同优化策略（贝叶斯优化 / 进化策略 / 随机搜索）的样本效率差异显著，且优化方案的鲁棒性（RBS 强度扰动下比例匹配的稳定性）是实际应用的关键考量。

研究问题

RQ1: 在给定 RBS 强度参数空间下，多基因协同表达的比例匹配能达到什么精度——影响匹配精度的关键因素是什么？

RQ2: 不同优化策略（贝叶斯优化 / 进化策略 / 随机搜索）的样本效率和收敛性如何对比——哪种策略最适合高维 RBS 组合优化？

RQ3: 优化方案的鲁棒性如何——RBS 强度扰动下比例匹配的稳定性？鲁棒性是否与优化策略相关？

任务目标与阶段任务

总目标: 给定 gvp 基因簇拓扑和目标表达比例，优化各基因 RBS 强度，比较不同优化策略的效果和鲁棒性。

阶段任务:

1. **问题定义** (对应 M1): 明确优化目标 (比例匹配度)、约束 (RBS 约束满足度 / operon 完整性 / 总量预算)、参数空间 (各基因 RBS 强度)。
2. **探索性分析** (对应 M2): 分析天然 gvp operon 的 RBS 强度分布和目标比例差距。
3. **Baseline 优化** (对应 M3): 实现随机搜索基线。
4. **优化策略对比** (对应 M4): 实现 ≥ 2 种优化策略，对比收敛性和匹配精度。
5. **鲁棒性分析** (对应 M4): RBS 强度扰动下比例匹配的稳定性分析。
6. **总结** (对应 M5): 给出策略建议和系统改进方向。

实施方案 (建议)

建模

- 技术 (建议): 参数化各基因 RBS 强度 (如 $[0, 1]$ 连续值或离散档位); 构建表达预测代理模型 (RBS Calculator + 简单线性模型或数据驱动模型)
- 决策点: RBS 强度是连续还是离散——连续空间适合贝叶斯优化, 离散空间适合进化策略

优化策略

- 技术 (建议): 随机搜索 (基线) / 贝叶斯优化 (高斯过程 + EI/UCB) / 进化策略 (CMA-ES / 遗传算法) / 梯度优化 (如代理模型可微)
- 决策点: 不同策略的样本效率——高维空间中贝叶斯优化可能优于进化策略

约束处理

- 技术 (建议): 罚项法 (违反约束的目标值降低) / 修复法 (将非法解投影到合法空间) / 可行域限制 (只在合法 RBS 强度范围内搜索)
- 决策点: 约束处理方式影响优化效率——罚项简单但可能不满足约束

鲁棒性分析

- 技术 (建议): 在最优解附近添加高斯扰动 ($\sigma = 5-20\%$), 分析比例匹配的变化
- 决策点: 鲁棒性是实际应用的关键——实验中 RBS 强度无法精确控制

实验设计与评价

必做实验

实验 1: 优化策略对比 (→ RQ1, RQ2)

- 在相同目标比例和约束下, 对比随机 / 贝叶斯 / 进化策略的收敛曲线和最终匹配精度
- 分析要点: 哪种策略收敛最快? 哪种达到最高匹配精度? 样本效率如何?

实验 2: 消融实验

- 随机搜索 → + 代理模型 → + 智能采样 → + 约束处理
- 分析要点：代理模型和智能采样各自的贡献？

实验 3：目标比例敏感性

- 在不同目标比例（如 GvpA:GvpC = 10:1 / 5:1 / 3:1）下，对比各策略效果
- 分析要点：目标比例的极端程度如何影响优化难度？

实验 4：鲁棒性分析（→ RQ3）

- 在最优解附近扰动 RBS 强度，分析比例匹配的变化
- 分析要点：哪些基因的 RBS 最敏感？优化策略是否影响了鲁棒性？

选做实验（从中至多选 2 项）

实验 5：Operon 拆分策略

- 对比天然单 operon 和拆分为多个转录单元的方案
- 分析要点：拆分是否改善了比例匹配？拆分方案的设计原则？

实验 6：多目标优化

- 同时优化比例匹配和总量达标，分析目标间冲突
- 分析要点：比例匹配和总量是否冲突？Pareto 前沿特征？

实验 7：与 RBS Calculator 直接对比

- 将优化结果与 RBS Calculator 的理论预测对比
- 分析要点：理论预测与优化结果的差异？代理模型的准确性？

探索项

- **密码子优化整合**：在 RBS 优化的基础上，进一步考虑密码子偏好性优化，分析两者是否存在交互效应——多层优化的系统视角。
- **自定义研究问题**：基于优化中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 优化目标、约束和参数空间定义
- 基因簇拓扑和目标比例
- RQ1-RQ3 拆解

M2 —初步结果

- 天然 gvp operon RBS 强度分布（RBS Calculator）
- 天然比例与目标比例差距分析
- 代理模型构建代码

M3 —中期结果

- 随机搜索基线
- 初步优化结果
- 中期检查演示材料——需展示闭环优化系统运行

M4 —完整实验

- ≥ 2 种优化策略实现和对比
- 鲁棒性分析

- 消融实验
- 目标比例敏感性分析
- 选做实验结果

M5 —最终成果

- 完整报告（含策略对比、鲁棒性分析、对 RQ1-RQ3 的回答、系统改进建议）
- 优化结果数据
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3 Track 2: Promoter (启动子)

领域背景

启动子 (Promoter) 是 DNA 序列上 RNA 聚合酶识别和结合的区域，决定基因转录的起始和强度。在合成生物学中，启动子是基因线路设计的基础调控元件——不同强度的启动子组合可以实现基因表达的精确调控。原核生物启动子的核心结构包括 -10 box (Pribnow box, TATAAT) 和 -35 box (TTGACA)，两者间的间距 (15–19 bp) 和保守度共同影响启动子强度。真核生物启动子结构更复杂，涉及 TATA box、Inr、CpG 岛等多种元件。

在 GV 领域中，gvp 基因簇的启动子具有特殊调控逻辑——GvpE 作为转录激活因子结合在 gvp 启动子区域增强表达，GvpD 作为抑制因子拮抗 GvpE。这对调控开关决定了 GV 基因簇是否开启。理解 gvp 启动子的序列特征和强度调控机制，对 GV 系统的异源表达优化具有直接指导意义。

计算问题

从机器学习角度看，启动子研究的核心计算问题沿着“识别 → 预测 → 生成”三个层次递进：(1) 从 DNA 序列中识别启动子区域（二分类/多分类）；(2) 从启动子序列预测转录强度（回归）；(3) 生成具有目标强度的启动子序列（序列生成）。这三个层次共享同一套序列表示基础，且递进依赖——识别模型的特征可用于预测，预测模型可用作生成模型的评价器。

现状与挑战

- **数据不平衡与标注偏差**：强启动子序列远多于弱启动子，标注来源（实验 vs 计算）可靠性不一。
- **跨物种泛化**：不同物种的启动子特征存在差异（-10/-35 box 保守度、GC 含量、调控元件），模型在跨物种预测时性能下降。
- **表示选择与信息层次**：k-mer / one-hot / PWM / DNA 大模型嵌入，不同表示捕获的信息层次不同。
- **强度预测的非线性**：启动子序列与强度之间存在非线性关系，单一位点突变可能显著改变强度。
- **生成序列的约束满足度约束**：生成的启动子需同时满足核心元件完整性、物种适配性和强度目标。

3.1 PR-T01: 启动子识别与跨物种表征

启动子识别是基因调控分析的基础。T01 从序列中识别启动子区域，分析跨物种的序列特征差异，并发现启动子调控的模式。三个项目覆盖了监督预测、模式发现和混合范式。

3.1.1 PR01-01: 启动子识别与跨物种泛化

动机

启动子识别是从 DNA 序列中判断给定区域是否为启动子的二分类（或多分类）问题。现有方法多在 E. coli 等模式生物数据上训练，而不同物种的启动子特征存在显著差异——蓝藻和古菌的 -10/-35 box 保守度不同，GC 含量差异大，且

可能存在物种特异的调控元件。跨物种泛化是启动子识别模型的核心挑战：随机划分下 F1 可能很高，但换到未见物种时性能骤降。此外，启动子序列与随机 DNA 序列之间的区分难度取决于负样本的构造方式——从编码区随机采样 vs 从非启动子调控区采样，得到的性能估计差异巨大。理解数据划分策略和负样本构造对性能估计的影响，对客观评估模型泛化能力至关重要。

研究问题

RQ1: 不同负样本构造策略（随机 DNA / 编码区 / 非启动子调控区）如何影响启动子识别的性能估计——哪种策略最能反映真实识别难度？

RQ2: 不同表示方式（k-mer / one-hot / DNA 大模型嵌入）和模型复杂度对跨物种泛化的影响是否一致？

RQ3: 模型在跨物种场景下的错误模式——是否集中在某些启动子类型（如不同 σ 因子类型）或某些物种上？错误是否与 -10/-35 box 的保守度相关？

任务目标与阶段任务

总目标: 构建启动子识别模型，在物种感知划分下评估跨物种泛化能力，分析负样本构造和表示方式对性能的影响。

阶段任务:

1. **问题定义与数据构建**（对应 M1）：明确分类目标（启动子 vs 非启动子 / σ 因子类型），设计正负样本构造策略和物种感知划分。
2. **探索性数据分析**（对应 M2）：分析启动子的 -10/-35 box 分布、GC 含量、物种间特征差异。
3. **Baseline 识别**（对应 M3）：手工特征 + 传统 ML 建立基线。
4. **表示与模型对比**（对应 M4）：k-mer / one-hot / DNA 大模型嵌入，传统 ML vs 深度学习。
5. **跨物种泛化分析**（对应 M4）：按物种和类型分解性能。
6. **总结**（对应 M5）：回答 RQ1-RQ3。

实施方案（建议）

数据构建

- 技术（建议）：RegulonDB (E. coli) / DBTBS (枯草芽孢杆菌) / 各物种基因组注释；三种负样本——随机 DNA / 编码区 / 非启动子调控区；物种感知划分
- 决策点：负样本构造直接影响性能估计——随机 DNA 太简单，非启动子调控区更有挑战性

特征表示

- 技术（建议）：k-mer 频率 (k=3-6) / one-hot + 位置编码 / DNA 大模型嵌入 (DNABERT-2 / Nucleotide Transformer)
- 决策点：DNA 大模型可能捕获更通用的启动子特征，有利于跨物种迁移

模型架构

- 技术（建议）：SVM / RF / XGBoost（基线）；CNN / Transformer / DNABERT-2 + LoRA（进阶）
- 决策点：CNN 适合捕获局部 motif (-10/-35 box)，Transformer 适合捕获长程依赖

实验设计与评价

必做实验

实验 1：负样本构造策略对比（→ RQ1）

- 固定模型，在三种负样本下对比性能
- 分析要点：性能差距多大？哪种负样本最能反映真实难度？

实验 2：跨物种泛化 (→ RQ2)

- 在 E. coli 上训练，迁移到其他物种，对比性能下降
- 分析要点：下降幅度？哪些物种迁移最困难？原因分析

实验 3：消融实验

- k-mer → +DNA 大模型 → + 深度模型 → + 域适应
- 分析要点：每步设计对跨物种泛化的贡献？

实验 4：错误分析 (→ RQ3)

- 按 σ 因子类型和物种分解性能
- 分析要点：哪些类型/物种困难？错误是否与 -10/-35 box 保守度相关？

选做实验 (从中至多选 2 项)

实验 5：模型架构对比 (→ RQ2)

- 固定表示，对比 SVM / CNN / Transformer
- 分析要点：不同架构对局部 motif 和长程依赖的捕获能力差异

实验 6：-10/-35 box 影响分析

- 移除/突变 -10/-35 box 后分析模型预测变化
- 分析要点：模型是否真正依赖核心 motif？

实验 7：物种特异特征发现

- 对比不同物种启动子的特征差异，发现物种区分性 motif
- 分析要点：哪些特征最具物种区分力？

探索项

- **调控元件可视化**：使用归因方法提取模型关注的区域，与已知 -10/-35 box 和转录因子结合位点对比——模型学到了什么？
- **自定义研究问题**：基于错误分析中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 分类目标、正负样本构造策略和划分设计
- RQ1-RQ3 拆解

M2 —初步结果

- 启动子特征分布 (-10/-35 / GC / 长度)
- 物种间特征差异分析
- 数据清洗流程代码

M3 —中期结果

- 手工特征 + 传统 ML pipeline
- 三种负样本下的基线性能
- 中期检查演示材料

M4 —完整实验

- DNA 大模型嵌入实验

- 跨物种泛化实验
- 消融和错误分析
- 选做实验结果

M5 —最终成果

- 完整报告（含负样本分析、跨物种泛化、对 RQ1–RQ3 的回答）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3.1.2 PR01-02: 启动子调控模式发现

动机

启动子的 -10/-35 box 是核心调控元件，但不同物种、不同 σ 因子类型的启动子在核心元件之外还存在大量变异和辅助元件——如 UP 元件、抑制子结合位点、激活子结合位点等。这些元件的组成和排列模式决定了启动子的调控特异性和强度。从多物种启动子序列中系统性地发现这些调控模式——核心 motif 的变异谱、辅助 motif 的出现频率、元件间的间距分布——不仅能填补调控知识的空白，还能为启动子强度预测（T02）和设计（T03）提供特征基础。本项目是纯模式发现类型，核心挑战在于发现的模式是否具有统计显著性和跨数据集一致性。

研究问题

RQ1: 从多物种启动子序列中发现的 de novo motif，与已知核心元件（-10/-35 box / UP element）和辅助调控元件的重合度如何？

RQ2: 不同 σ 因子类型的启动子在 motif 组成和间距分布上有何差异——是否存在类型特异的调控模式？

RQ3: 发现的调控模式在跨物种和跨数据集上是否一致——哪些模式是通用的，哪些是物种/数据集特异的？

任务目标与阶段任务

总目标: 从多物种启动子序列中发现调控 motif 和间距模式，与已知元件对比，分析跨物种和跨类型一致性。

阶段任务:

1. **问题定义与数据构建**（对应 M1）：采集多物种启动子序列，按 σ 因子类型分组。
2. **探索性数据分析**（对应 M2）：分析 -10/-35 box 位置分布、GC 含量、类型间差异。
3. **Motif 发现**（对应 M3）：MEME/DREME 全序列和分组发现 motif。
4. **间距和排列分析**（对应 M4）：分析 motif 间间距分布和排列顺序。
5. **跨物种和数据集验证**（对应 M4）：不同物种和数据集上的 motif 发现结果一致性。
6. **总结**（对应 M5）：回答 RQ1–RQ3。

实施方案（建议）

数据构建

- 技术（建议）：RegulonDB / DBTBS / 各物种基因组注释；按 σ 因子类型标注
- 决策点：物种和类型覆盖度——保证 motif 发现的代表性

Motif 发现

- 技术（建议）：MEME / DREME / STREME 全序列和按组发现；FIMO 定位；与已知元件对比
- 决策点：E-value 阈值和 motif 宽度范围

间距分析

- 技术（建议）：统计 motif 间距离分布；按类型对比间距模式
- 决策点：间距分布是否类型特异？

验证

- 技术（建议）：在不同物种/数据集上重复 motif 发现，计算一致性
- 决策点：跨数据集一致性是模式可靠性的关键

实验设计与评价

必做实验

实验 1：Motif 发现与已知元件对比（→ RQ1）

- 分析要点：发现的 motif 与 -10/-35 box / UP element 的重合度？是否存在新 motif？

实验 2：类型间模式差异（→ RQ2）

- 分析要点：不同 σ 因子类型的 motif 组成和间距差异？类型特异 motif？

实验 3：消融实验

- 全序列 motif → + 分组 motif → + 间距分析 → + 跨物种验证
- 分析要点：每步分析揭示了什么新信息？

实验 4：跨数据集一致性（→ RQ3）

- 分析要点：哪些 motif 在所有数据集上一致发现？哪些是数据集特异的？

选做实验（从中至多选 2 项）

实验 5：Motif 强度与启动子强度关联

- 分析 motif 存在/缺失与启动子强度的关系
- 分析要点：哪些 motif 与强度显著相关？

实验 6：Motif 组合模式

- 分析多个 motif 的共现模式，构建 motif 组合网络
- 分析要点：哪些 motif 倾向于共现？组合模式是否类型特异？

实验 7：与转录因子结合位点对比

- 将发现的 motif 与 RegulonDB 中已知的 TF 结合位点对比
- 分析要点：发现的 motif 是否对应已知 TFBS？

探索项

- **调控语法建模**：将发现的 motif 和间距模式形式化为“调控语法”规则，用规则验证新启动子的约束满足度——从模式发现到模式应用的闭环。
- **自定义研究问题**：基于发现中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 模式发现目标和数据来源
- σ 因子类型和物种覆盖
- RQ1–RQ3 拆解

M2 —初步结果

- -10/-35 box 位置和保守度分布
- GC 含量和类型间差异
- 数据提取流程代码

M3 —中期结果

- MEME 运行和结果
- 初步与已知元件对比
- 中期检查演示材料

M4 —完整实验

- 分组 motif 发现和类型间差异
- 间距分析
- 跨数据集验证
- 选做实验结果

M5 —最终成果

- 完整模式发现报告
- 模式数据
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3.1.3 PR01-03: 启动子识别与调控模式发现（混合）

动机

启动子识别模型通过分类器判断“是不是启动子”，但缺乏对决策依据的理解——模型依据了哪些 motif？这些 motif 与已知元件是否一致？模式发现方法（MEME 等）能发现 motif 但缺乏预测能力。将两者结合：训练识别模型 → 归因分析提取关键位点 → 与模式发现结果对比 → 发现新特征反馈模型，形成“预测 → 归因 → 发现 → 改进”的闭环。这种混合范式要求学生同时掌握监督学习和模式发现两条技术路线，并在两者间建立有效的信息流。核心挑战在于归因结果的可靠性和发现的生物学合理性——模型关注的高贡献区域是否真正具有功能意义？

研究问题

■ **RQ1**: 识别模型归因的关键位点与 PR01-02 发现的调控 motif 和已知元件的重合度如何？

■ **RQ2**: 归因发现与模式发现的结果是否一致——两种独立方法对同一问题给出了什么结论？

■ **RQ3**: 将归因/模式发现的关键 motif 作为新特征反馈模型，是否能提升跨物种泛化性能？

任务目标与阶段任务

总目标: 训练启动子识别模型，通过归因分析提取关键位点，与模式发现结果对比，并将发现反馈到模型改进中。

阶段任务

1. **问题定义**（对应 M1）: 明确识别目标和反馈改进路径。
2. **EDA + 模式发现**（对应 M2）: 分析启动子特征，运行初步 motif 发现。
3. **识别模型训练**（对应 M3）: 训练基线和进阶识别模型。

4. **归因分析** (对应 M4): 多种归因方法提取关键位点, 与 motif 发现对比。
5. **反馈改进** (对应 M4): 将关键 motif 作为特征反馈模型, 对比改进效果。
6. **总结** (对应 M5): 回答 RQ1-RQ3, 评估闭环效果。

实施方案 (建议)

识别模型

- 技术 (建议): SVM / CNN / Transformer / DNABERT-2 + LoRA
- 决策点: 模型需可归因——CNN (Grad-CAM) / Transformer (attention)

归因方法

- 技术 (建议): Attention weights / SHAP / Integrated Gradients / Saliency / Grad-CAM
- 决策点: 不同方法的假设和粒度差异

模式发现

- 技术 (建议): MEME / DREME (复用 PR01-02 结果或独立运行)
- 决策点: 归因结果可作为 MEME 的种子/先验

反馈机制

- 技术 (建议): 将归因/motif发现的关键位置作为 binary 特征或 attention mask, 反馈到模型
- 决策点: 反馈是否真正提升了性能——需对比实验

实验设计与评价

必做实验

实验 1: 归因位点与已知元件对比 (→ RQ1)

- 分析要点: 归因 top-k 位点与 -10/-35 box / motif 发现结果的重合度?

实验 2: 归因与模式发现一致性 (→ RQ2)

- 分析要点: 两种方法发现的关键区域是否一致? 不一致出现在哪里?

实验 3: 消融实验

- 识别模型 → + 归因分析 → + 模式发现对比 → + 反馈改进
- 分析要点: 每步揭示了什么? 反馈改进了多少?

实验 4: 反馈改进效果 (→ RQ3)

- 分析要点: 加入关键 motif 特征后跨物种性能变化? 改进是真实的还是噪声?

选做实验 (从中至多选 2 项)

实验 5: 多方法归因一致性

- 对比 ≥ 2 种归因方法的 top-k 重合率
- 分析要点: 哪些区域是方法一致的?

实验 6: 跨物种归因稳定性

- 不同物种子集上的归因对比
- 分析要点: 哪些位点是跨物种稳定的归因目标?

实验 7: 归因指导的数据增强

- 基于归因发现的关键位点设计数据增强策略

- 分析要点：增强是否提升了困难类型的性能？

探索项

- **调控语法学习**：从归因和模式发现的结果中提取”调控语法规则”（如”-35 box必须存在且间距 15–19 bp”），形式化为约束用于生成验证——跨任务的系统视角。
- **自定义研究问题**：基于闭环中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 识别目标和闭环改进路径设计
- RQ1–RQ3 拆解

M2 —初步结果

- 启动子特征分析
- 初步 motif 发现结果
- 数据清洗流程代码

M3 —中期结果

- 基线识别模型训练
- 初步归因结果
- 中期检查演示材料

M4 —完整实验

- 多方法归因和一致性分析
- 与模式发现对比
- 反馈改进实验
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含闭环分析、对 RQ1–RQ3 的回答）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3.2 PR-T02: 启动子强度预测与可解释分析

启动子强度预测是从序列预测转录强度的回归问题。T02 的两个项目分别关注预测性能和可解释性——模型不仅要准确预测，还要揭示”为什么这个启动子强/弱”。

3.2.1 PR02-01: 启动子强度预测与关键位点归因

动机

启动子强度预测的目标是从启动子序列直接预测转录速率（如相对表达量），为基因线路设计提供量化工具。现有工具（如 Salis Lab 的 Promoter Calculator）基于热力学模型，数据驱动方法（CNN/Transformer）有潜力捕获更多非线性特征。然而，仅预测强度不够——还需要理解模型依据了哪些位点和 motif 做出预测。如果归因显示模型依赖 -10/-35 box 的保守度和间距，说明模型学到了合理的生物学信号；如果归因指向与调控无关的区域，则可能存在偏差。归因发现的位点可指导理性启动子设计——哪些位点突变可能改变强度？这与 T03 的序列生成形成闭环。

研究问题

RQ1: 数据驱动模型与热力学工具 (Promoter Calculator) 在启动子强度预测上的性能差异如何——在什么条件下数据驱动方法更优?

RQ2: 模型归因的关键位点是否与已知强度决定因素 (-10/-35 box 保守度 / 间距 / UP element) 一致?

RQ3: 基于归因的位点突变实验——突变高贡献位点是否如预期改变预测强度? 归因是否具有因果指导意义?

任务目标与阶段任务

总目标: 训练启动子强度预测模型, 通过归因分析揭示强度决定位点, 并与热力学工具对比。

阶段任务:

1. **问题定义与数据构建** (对应 M1): 采集启动子-强度数据, 明确回归目标。
2. **探索性数据分析** (对应 M2): 分析强度分布、-10/-35 box 与强度的关系。
3. **Baseline 预测** (对应 M3): 热力学基线 (Promoter Calculator) + 简单 ML 基线。
4. **深度模型 + 归因** (对应 M4): CNN/Transformer 训练 + 归因分析。
5. **位点突变验证** (对应 M4): 计算突变高贡献位点后的预测强度变化。
6. **总结** (对应 M5): 回答 RQ1-RQ3。

实施方案 (建议)

数据构建

- 技术 (建议): MPRA数据 / Salis Lab 数据 / 文献实验数据; 强度标准化和划分
- 决策点: 强度数据的标尺——不同实验间的强度标尺不一致

模型架构

- 技术 (建议): Ridge / SVR (基线); CNN / Transformer / DNABERT-2 + LoRA (进阶)
- 决策点: CNN适合捕获局部 motif, Transformer 适合捕获长程依赖

归因方法

- 技术 (建议): Integrated Gradients / SHAP / Attention weights / Saliency
- 决策点: 归因方法选择与模型架构匹配

对比基线

- 技术 (建议): Promoter Calculator (Salis Lab)热力学预测
- 决策点: 热力学 vs 数据驱动——互补还是替代?

实验设计与评价

必做实验

实验 1: 预测性能对比 (→ RQ1)

- 对比 ML / 深度模型 / Promoter Calculator 的 R^2 / Spearman ρ
- 分析要点: 数据驱动在什么条件下更优? 热力学在什么条件下更优?

实验 2: 归因位点分析 (→ RQ2)

- 提取归因 top-k 位点, 与 -10/-35 box / 间距 / UP element 对比
- 分析要点: 重合度? 归因位点是否集中在核心调控区域?

实验 3: 消融实验

- k-mer → + 深度模型 → +DNA 大模型 → + 归因
- 分析要点：每步设计的贡献？

实验 4：位点突变验证（→ RQ3）

- 突变归因高贡献位点，分析预测强度变化方向
- 分析要点：突变是否如预期改变强度？归因的因果指导意义？

选做实验（从中至多选 2 项）

实验 5：跨物种迁移

- 在 E. coli 数据上训练，迁移到其他物种
- 分析要点：迁移性能下降？物种间强度决定因素的差异？

实验 6：多方法归因一致性

- 对比 ≥ 2 种归因方法
- 分析要点：方法间一致性如何？

实验 7：与 PR01-02 motif 对比

- 将归因位点与 PR01-02 发现的 motif 对比
- 分析要点：归因与模式发现是否一致？

探索项

- **理性设计**：基于归因发现，人工设计突变体（增强/减弱强度），用模型预测验证——从解释到设计的闭环。
- **自定义研究问题**：基于归因中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 预测目标和数据来源
- RQ1-RQ3 拆解

M2 —初步结果

- 强度分布和 -10/-35 box 关系分析
- 数据清洗和标准化流程代码

M3 —中期结果

- 热力学 + ML 基线
- 初步预测性能
- 中期检查演示材料

M4 —完整实验

- 深度模型训练和性能对比
- 归因分析和位点突变验证
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含性能对比、归因分析、对 RQ1-RQ3 的回答）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3.2.2 PR02-02: 启动子强度预测的跨物种迁移与解释

动机

启动子强度数据绝大多数来自 *E. coli*，其他物种的实验数据极少。如果模型在 *E. coli* 上学到的强度-序列映射规律能迁移到其他物种，就能大幅降低新物种启动子设计的实验成本。然而，跨物种迁移面临序列特征差异的挑战——不同物种的 -10/-35 box 保守度、GC 含量和调控元件不同。理解迁移性能下降的原因，以及不同迁移策略的效果，对多物种启动子设计至关重要。本项目与 PR02-01 的区别在于核心关注点是跨物种迁移而非单一物种预测，且要求对迁移失败案例进行归因分析——模型在未见物种上依赖了什么特征？这些特征是否具有跨物种通用性？

研究问题

RQ1: *E. coli* 启动子强度预测模型零样本迁移到其他物种的性能下降幅度——下降来自序列特征差异还是模型表示能力不足？

RQ2: 不同迁移策略（零样本 / 少样本 / 域适应）的效果对比——在什么数据条件下哪种策略最优？

RQ3: 迁移成功/失败案例的归因分析——模型在目标物种上依赖了什么特征？这些特征是否跨物种保守？

任务目标与阶段任务

总目标: 在 *E. coli* 数据上训练强度预测模型，设计迁移策略应用于其他物种，归因分析迁移成败的原因。

阶段任务:

1. **问题定义**（对应 M1）：明确迁移源（*E. coli*）和目标物种，数据来源。
2. **EDA**（对应 M2）：分析物种间启动子特征差异。
3. **Baseline 迁移**（对应 M3）：*E. coli* 模型零样本迁移。
4. **迁移策略**（对应 M4）：少样本 / 域适应 / 特征迁移。
5. **归因分析**（对应 M4）：迁移成功/失败案例的归因对比。
6. **总结**（对应 M5）：回答 RQ1-RQ3。

实施方案（建议）

迁移策略

- 技术（建议）：零样本（直接预测）/ 少样本微调（少量目标物种数据）/ 域适应（DANN / MMD）/ 特征迁移（共享编码器）
- 决策点：不同策略需要不同量的目标物种数据

归因分析

- 技术（建议）：IG / SHAP对比源域和目标域的归因差异
- 决策点：模型在目标物种上依赖了什么——是否与源域一致？

实验设计与评价

必做实验

实验 1：零样本迁移基线（→ RQ1）

- 分析要点：性能下降幅度？哪些物种下降最严重？

实验 2：迁移策略对比（→ RQ2）

- 分析要点：不同策略的效果差异？数据量需求？

实验 3：消融实验

- 零样本 → + 少样本 → + 域适应 → +DNA 大模型预训练
- 分析要点：每步对迁移的贡献？

实验 4：迁移归因分析（→ RQ3）

- 对比成功和失败案例的归因
- 分析要点：成功案例依赖了什么特征？失败案例归因是否异常？

选做实验（从中至多选 2 项）

实验 5：物种距离与迁移性能

- 分析物种进化距离与迁移性能下降的相关性
- 分析要点：距离越远迁移越差？

实验 6：特征重要性跨物种一致性

- 对比不同物种上模型的特征重要性排序
- 分析要点：哪些特征是跨物种通用的？

实验 7：与热力学工具迁移对比

- 对比数据驱动模型和 Promoter Calculator 的跨物种表现
- 分析要点：热力学模型是否迁移性更好（因为基于通用物理原理）？

探索项

- **物种适应设计**：基于迁移分析发现的目标物种特异特征，设计物种适应的启动子——从迁移理解到物种设计。
- **自定义研究问题**：基于迁移中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 迁移源和目标物种定义
- RQ1-RQ3 拆解

M2 —初步结果

- 物种间启动子特征差异分析
- 数据清洗流程代码

M3 —中期结果

- E. coli 基线模型
- 零样本迁移初步结果
- 中期检查演示材料

M4 —完整实验

- ≥ 3 种迁移策略
- 归因分析
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含迁移策略对比、归因分析、对 RQ1-RQ3 的回答）

- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3.3 PR-T03: 启动子序列生成与闭环验证

启动子生成是设计新启动子序列的任务。T03 的三个项目从生成到优化到闭环验证，构成完整的设计链条。

3.3.1 PR03-01: 条件启动子生成

动机

启动子设计的核心目标是生成具有目标强度的启动子序列——给定“我需要一个中等强度的 $\sigma_{\square\square}$ 启动子”，模型应产出满足该约束的序列。条件生成模型（如条件 VAE / 扩散模型 / 自回归条件生成）可实现这一目标，但核心挑战在于生成序列的约束满足度和可控性：生成的序列必须包含 -10/-35 box 等核心元件，且强度与目标条件匹配。评价条件生成质量需要独立的强度预测器（如 PR02-01 的模型或 Promoter Calculator），避免自验证偏差。此外，生成序列的新颖性——与已知启动子的差异度——和多样性——候选集内部的差异度——也是重要评价维度。

研究问题

- **RQ1**: 条件生成模型产出的序列在多大程度上满足目标强度条件——独立强度预测器的评估说明了什么？
- **RQ2**: 不同生成策略（条件 VAE / 扩散 / 自回归）在条件可控性、约束满足度和新颖性上的权衡如何？
- **RQ3**: 生成序列的 -10/-35 box 保守度和间距是否与真实启动子一致——模型学到了核心调控元件的约束吗？

任务目标与阶段任务

总目标：训练条件启动子生成模型，以目标强度为条件生成序列，使用独立方法评估条件可控性和计算层面的约束满足度。

阶段任务：

1. **问题定义**（对应 M1）：明确生成目标、条件标签和约束。
2. **EDA**（对应 M2）：分析启动子序列空间分布和强度-特征关系。
3. **Baseline 生成**（对应 M3）：无条件基线 + 简单条件模型。
4. **条件生成**（对应 M4）：条件 VAE / 扩散 / 自回归。
5. **评估**（对应 M4）：独立强度预测器 + motif 验证 + 新颖性/多样性。
6. **总结**（对应 M5）：回答 RQ1-RQ3。

实施方案（建议）

条件生成模型

- 技术（建议）：条件 VAE（强度/类型条件化）/ 扩散模型（离散扩散）/ 自回归条件生成（LSTM/Transformer + 条件 prefix）
- 决策点：不同模型的条件控制能力和训练稳定性差异

独立评估器

- 技术（建议）：PR02-01的强度预测模型 / Promoter Calculator
- 决策点：评估器必须与生成模型不同源

约束满足度验证

- 技术（建议）：-10/-35 box检测（PWM / HMMER） / 间距合理性 / GC 含量合理性
- 决策点：约束满足度的定义——是否要求严格匹配已知 motif，还是允许变异？

实验设计与评价

必做实验

实验 1：条件可控性评估（→ RQ1）

- 用独立强度预测器评估生成序列的强度，对比目标条件
- 分析要点：生成强度与目标条件的匹配度？不同强度档位的可控性差异？

实验 2：生成策略对比（→ RQ2）

- 对比条件 VAE / 扩散 / 自回归的条件控制效果
- 分析要点：哪种策略条件控制最好？约束满足度/新颖性/多样性的权衡？

实验 3：消融实验

- 无条件 → + 随机条件 → + 条件模型 → + 约束机制
- 分析要点：条件信号的贡献？约束机制的效果？

实验 4：核心元件分析（→ RQ3）

- 检测生成序列的 -10/-35 box 和间距
- 分析要点：生成的核心元件与真实启动子的相似度？间距分布合理吗？

选做实验（从中至多选 2 项）

实验 5：强度分辨率

- 在多个强度档位（弱/中/强）下测试条件控制精度
- 分析要点：哪些档位可控性好？哪些困难？

实验 6：约束生成策略

- 在生成中引入 -10/-35 box 硬约束，对比约束前后质量
- 分析要点：约束是否提升约束满足度？是否牺牲多样性？

实验 7：生成序列的功能验证

- 使用 PR01-01 的识别模型验证生成序列是否被识别为启动子
- 分析要点：识别模型的判断与约束满足度验证是否一致？

探索项

- 从头设计验证：将最优生成序列提交给 Promoter Calculator 预测热力学强度，对比数据驱动和热力学评估的一致性——跨方法验证。
- 自定义研究问题：基于生成结果中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 生成目标、条件标签和约束定义
- 独立评估器设计
- RQ1-RQ3 拆解

M2 —初步结果

- 启动子序列空间和强度-特征关系分析

- 数据清洗流程代码

M3 —中期结果

- 无条件基线 + 简单条件模型
- 初步评估结果
- 中期检查演示材料

M4 —完整实验

- ≥ 2 种条件生成策略
- 独立评估器评估
- 消融和核心元件分析
- 选做实验结果

M5 —最终成果

- 完整报告（含条件可控性分析、策略对比、对 RQ1-RQ3 的回答）
- 生成序列 FASTA 文件
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3.3.2 PR03-02: 启动子序列优化与闭环验证

动机

给定一个已知启动子，如何通过少量突变提升其强度？这是定向优化的核心问题——在保持核心元件完整的前提下，通过调整非关键位点的碱基来优化强度。与从头生成（PR03-01）不同，定向优化有明确的参考序列和更小的搜索空间，但也面临“保持”与“改进”的矛盾。闭环验证指将优化后的序列反馈到强度预测模型（PR02-01）和识别模型（PR01-01）中进行验证，形成“优化 → 预测 → 验证”的闭环。核心挑战在于优化序列是否真正改进了强度，以及改进是否以牺牲约束满足度为代价——如果突变破坏了 -10/-35 box，即使预测强度提升也不具实际价值。

研究问题

■ **RQ1**：在保持 -10/-35 box 完整的前提下，定向优化的强度提升极限在哪里？

■ **RQ2**：不同优化策略（梯度引导 / 进化策略 / 贝叶斯优化）的收敛性和约束满足能力如何对比？

■ **RQ3**：闭环验证——优化序列在强度预测模型和识别模型中的表现是否一致？是否存在“预测提升但识别失败”的不一致案例？

任务目标与阶段任务

总目标：给定参考启动子，在保持核心元件完整性下定向优化强度，通过闭环验证评估优化效果。

阶段任务：

1. **问题定义**（对应 M1）：明确参考序列、优化目标、约束条件。
2. **EDA**（对应 M2）：分析参考序列的核心元件位置和可变区域。
3. **Baseline 优化**（对应 M3）：随机突变基线 + 贪心搜索。
4. **深度优化**（对应 M4）： ≥ 2 种优化策略实现和对比。
5. **闭环验证**（对应 M4）：强度预测模型 + 识别模型 + motif 验证。
6. **总结**（对应 M5）：回答 RQ1-RQ3。

实施方案 (建议)

优化策略

- 技术 (建议): 梯度引导 (可微强度模型) / 进化策略 (CMA-ES / 遗传算法) / 贝叶斯优化 (GP + EI)
- 决策点: 不同策略的样本效率和约束满足能力

约束机制

- 技术 (建议): 硬约束——核心元件掩码锁定; 软约束——罚项 (GC / 组成)
- 决策点: 硬约束保证安全性但限制搜索空间

闭环验证

- 技术 (建议): 强度预测 (PR02-01模型) / 识别验证 (PR01-01 模型) / motif 约束满足度 (HMMER / PWM)
- 决策点: 闭环验证的多角度一致性是关键

实验设计与评价

必做实验

实验 1: 优化策略对比 (→ RQ2)

- 收敛曲线和最终强度提升对比
- 分析要点: 哪种策略收敛快? 哪种提升大? 约束满足率?

实验 2: 约束满足与约束满足度验证 (→ RQ1)

- 统计优化序列的 -10/-35 box 完整性和间距合理性
- 分析要点: 优化是否破坏了核心元件? 约束满足度与提升的权衡?

实验 3: 消融实验

- 随机突变 → + 贪心 → + 深度优化 → + 约束机制
- 分析要点: 每步设计的贡献?

实验 4: 闭环验证一致性 (→ RQ3)

- 优化序列在强度预测和识别模型中的表现对比
- 分析要点: 是否存在“预测提升但识别失败”的不一致? 原因分析?

选做实验 (从中至多选 2 项)

实验 5: 多位点协同突变

- 分析多个位点的协同效应——单点突变 vs 组合突变
- 分析要点: 位点间是否存在交互效应?

实验 6: 参考序列敏感性

- 不同参考启动子的优化效果对比
- 分析要点: 优化效果是否依赖参考选择?

实验 7: 与 PR03-01 生成对比

- 定向优化 vs 从头生成的效果对比
- 分析要点: 哪种方式产出的候选质量更高?

探索项

- 理性设计验证: 基于归因分析 (PR02-01) 选择突变位点, 对比理性设计与自动优化的效果——人类先验 vs 算法搜索。

- **自定义研究问题：**基于优化中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 参考序列、优化目标和约束定义
- 闭环验证设计
- RQ1–RQ3 拆解

M2 —初步结果

- 参考序列核心元件和可变区域分析
- 约束掩码设计代码

M3 —中期结果

- 随机突变 + 贪心搜索基线
- 初步闭环验证结果
- 中期检查演示材料

M4 —完整实验

- ≥ 2 种优化策略实现和对比
- 闭环验证实验
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含策略对比、闭环验证、对 RQ1–RQ3 的回答）
- 优化序列数据
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

3.3.3 PR03-03: 启动子设计的模式发现与特征反馈

动机

前两个项目（PR03-01 生成、PR03-02 优化）产出了大量候选启动子序列。这些序列中蕴含着模式信息——什么样的序列特征与高强度相关？什么样的 motif 组合出现在最优候选中？从生成/优化结果中进行模式发现，不仅能理解模型“学到了什么”，还能将发现的模式反馈为新的设计约束或特征，进一步提升生成/优化质量。这种“设计 → 发现 → 反馈 → 改进设计”的闭环是计算设计的核心范式。本项目是 T03 的收尾，也是整个 Promoter Track 的综合——整合识别（T01）、预测（T02）和生成（T03）的发现，形成系统性的设计知识。

研究问题

RQ1：从生成/优化产出的候选序列中发现的 motif，与 PR01-02 从自然启动子中发现的 motif 有何异同——模型生成的高强度序列是否具有独特的序列特征？

RQ2：将发现的模式作为新约束或特征反馈到生成/优化中，是否能提升候选质量？

RQ3：自然启动子和设计启动子在序列空间中的分布差异揭示了什么——设计序列是否探索了自然序列未覆盖的区域？

任务目标与阶段任务

总目标：从生成/优化候选序列中发现序列模式，与自然启动子对比，将发现反馈为设计约束，评估改进效果。

阶段任务：

1. **问题定义**（对应 M1）：明确候选集来源、模式发现目标和反馈机制设计。
2. **EDA**（对应 M2）：分析候选集在序列空间的分布。
3. **模式发现**（对应 M3）：在候选集上运行 motif 发现和强度-特征关联分析。
4. **与自然对比**（对应 M4）：候选集 motif 与 PR01-02 自然 motif 对比。
5. **反馈改进**（对应 M4）：将发现作为约束/特征反馈到生成/优化，对比改进效果。
6. **总结**（对应 M5）：回答 RQ1-RQ3，形成系统性设计知识。

实施方案（建议）

模式发现

- 技术（建议）：MEME / DREME在候选集和强度分组上发现 motif；强度-特征关联分析（Spearman / 互信息）
- 决策点：候选集的大小和质量影响模式发现的可靠性

对比分析

- 技术（建议）：候选集 vs 自然启动子的 motif 重合度 / 序列空间分布（t-SNE + PLM 嵌入）
- 决策点：设计序列是否探索了新区域？

反馈机制

- 技术（建议）：将发现的 motif 作为生成约束（硬约束锁定）/ 优化目标（软约束罚项）/ 预测特征
- 决策点：反馈是否真正改进了质量——需对比实验

实验设计与评价

必做实验

实验 1：候选集模式发现（→ RQ1）

- 在候选集上发现 motif，分析强度-特征关联
- 分析要点：高强度候选的共性特征是什么？与自然启动子的 motif 差异？

实验 2：序列空间分布对比（→ RQ3）

- 候选集和自然启动子在 PLM 嵌入空间中的分布对比
- 分析要点：设计序列是否覆盖了自然序列未覆盖的区域？

实验 3：消融实验

- 模式发现 → + 与自然对比 → + 反馈约束 → + 改进评估
- 分析要点：每步揭示了什么？反馈改进了多少？

实验 4：反馈改进效果（→ RQ2）

- 加入模式反馈后，生成/优化质量的变化
- 分析要点：改进是真实的还是噪声？哪些指标提升了？

选做实验（从中至多选 2 项）

实验 5：设计语法提取

- 从模式发现中提取“设计语法规则”（如“高强度启动子需包含 motif X 且 -10/-35 间距为 17 bp”）
- 分析要点：语法规则的覆盖率和准确率？

实验 6：跨条件模式

- 在不同强度/类型条件下分别发现模式
- 分析要点：条件特异的模式？跨条件通用模式？

实验 7：设计序列的下游验证

- 使用 PR02-01 强度模型和 PR01-01 识别模型全面评估设计序列
- 分析要点：多角度评估的一致性？

探索项

- **设计知识图谱**：将所有 Track 的发现整合为启动子设计知识图谱——从识别到预测到生成的系统性设计知识——全 Track 综合视角。
- **自定义研究问题**：基于发现中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 候选集来源和模式发现目标
- 反馈机制设计
- RQ1–RQ3 拆解

M2 —初步结果

- 候选集分布和特征分析
- 数据预处理代码

M3 —中期结果

- MEME 运行和强度-特征关联分析
- 初步与自然启动子对比
- 中期检查演示材料

M4 —完整实验

- 完整模式发现和对比分析
- 反馈改进实验
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含模式发现、反馈改进、对 RQ1–RQ3 的回答、系统性设计知识总结）
- 模式发现数据
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

4 Track 3: XAI（可解释人工智能）

领域背景

可解释人工智能（XAI）旨在揭示深度学习模型的决策依据，使“黑箱”模型的推理过程可追溯、可理解、可信任。在医学影像、自动驾驶、金融风控等高风险场景中，仅有预测结果不够——模型必须展示“依据了哪些特征”才能获得用户信任。特征归因是 XAI 的核心技术：量化每个输入特征对模型预测的贡献，生成热力图或重要性排序。

归因方法主要分为三类：梯度类（Saliency Map、Integrated Gradients、Grad-CAM 系列）、扰动类（LIME、RISE、Ablation）和博弈论类（Shapley 值及近似）。不同方法的假设前提、计算成本和适用场景各异——不存在“万能最优”的归因方法。

计算问题

从机器学习角度看，XAI 领域的核心计算问题是：(1) 方法选择——给定模型和数据，如何选择合适的归因方法？选择依据是什么？(2) 归因质量评价——归因结果“好不好”如何量化？忠实性、定位性、稳定性和鲁棒性之间如何权衡？(3) 先验融合——如何将领域知识、结构先验和辅助标注引入解释过程以提升解释的精度和合理性？

现状与挑战

- **方法选择困境**：归因方法众多，但“什么条件下用什么方法”的规律性认识不足——实践中常依赖经验而非系统比较。
- **评价冲突**：忠实性、定位性、稳定性和鲁棒性指标之间可能存在冲突——不存在单一“最优”归因方法。
- **基线依赖**：梯度类方法对基线选择高度敏感，零基线、模糊基线、生成式基线的归因结果可能显著不同。
- **迁移性不足**：自然图像上的解释结论难以直接迁移到医学影像等特定领域。
- **先验融合深度**：现有方法多停留在特征拼接层面，更深层的融合（反事实生成、概念约束）尚待探索。

4.1 XAI-T01: 特征归因方法选择与评价

T01 的主线是“给定模型和数据，选择合适的归因方法并评价”。学生从梯度类、扰动类、博弈论类方法中选择并组合，针对具体解释目标进行设计、优化和多维度评价。4 个项目分别从梯度类方法比较、扰动类与博弈论类比较、跨模型跨数据集一致性、模式发现四个角度切入。前沿论文方法（FourierShap、MA-GIG、DePass、OrdShap、SurvFD 等）作为选做的方法候选，不是必须实现的主体任务。

4.1.1 XAI01-01: 梯度类归因方法比较与优化

动机

梯度类归因是深度模型最直接的解释方法——利用反向传播计算输入特征对预测的梯度，生成像素级重要性热力图。代表性方法包括 Saliency Map（原始梯度）、Integrated Gradients（沿路径积分）、Expected Gradients（对基线分布取期望）和 Grad-CAM 系列（通道加权空间映射）。这些方法看似相似，但基线选择、积分路径和聚合方式的不同会导致显著不同的归因结果。理解“同一个模型为什么不同梯度方法给出不同解释”是归因方法选择的基础。

本项目给定一个预训练 ResNet-50（ImageNet）和胸部 X 光数据集（CHNCXR），要求学生选择并实现至少 3 种梯度类归因方法，分析它们在不同基线和不同数据类型上的表现差异。基线选择是核心设计变量——零基线、模糊基线、随机基线各有假设前提，学生需要理解这些假设如何影响归因结果。前沿方法如 MA-GIG（生成式基线）和 TIMING（时间感知路径）可作为选做扩展。

研究问题

RQ1：不同梯度类归因方法（Saliency / IG / EG / Grad-CAM）在同一个模型和同一批图像上的归因结果差异有多大——差异主要体现在哪些区域？

RQ2：基线选择（零 / 模糊 / 随机 / 生成式）如何影响 IG 和 EG 的归因质量——什么基线在什么条件下更优？

RQ3：自然图像（ImageNet）上获得的“最优基线/方法”结论，在医学影像（CHNCXR）上是否仍然成立——解释方法的迁移性如何？

任务目标与阶段任务

总目标：给定预训练模型，选择并实现梯度类归因方法，比较基线选择对归因质量的影响，验证跨数据集迁移性。

阶段任务：

1. **问题定义**（对应 M1）：选择模型和数据集，确定对比的归因方法和基线策略。
2. **初步实验**（对应 M2）：实现 Saliency Map 和 Grad-CAM 基线，获得初步归因结果。
3. **中期实验**（对应 M3）：实现 IG 和 EG，对比不同基线，获得多方法多基线归因结果。
4. **完整实验**（对应 M4）：跨数据集迁移验证，消融实验，选做方法扩展。
5. **总结**（对应 M5）：回答 RQ1-RQ3，形成方法选择建议。

实施方案（建议）

归因方法

- 方法候选（建议必选 ≥ 3 ）：Saliency Map / Integrated Gradients / Expected Gradients / Grad-CAM / Grad-CAM++
- 选做扩展：MA-GIG生成式基线（参考 ICML 2026 论文思路，使用 VAE 隐空间路径替代零基线）；TIMING 时间感知路径（参考 ICML 2025 论文思路，参数化路径形状）
- 决策点：不同方法的假设前提——Saliency假设局部线性，IG 假设路径积分合理，EG 假设基线分布有意义

基线策略

- 策略候选：零基线 / 高斯模糊基线 / 随机基线 / 生成式基线（VAE 隐空间采样）
- 决策点：基线选择是设计变量——从简单到复杂，需分析复杂度增加的边际收益

评价指标

- 忠实性（Insertion/Deletion/Drop/Increase）/ 稳定性（Max-Sensitivity）/ 效率（计算时间）
- 决策点：不同指标可能冲突——需多维度联合评估

实验设计与评价

必做实验

实验 1：方法间归因差异（→ RQ1）

- 对同一批图像，用 ≥ 3 种方法生成归因图，计算归因图间相似度（CosineSim / SpearmanCorr / top-k 重合率）
- 分析要点：哪些区域方法间一致？哪些分歧大？分歧的原因（基线？路径？聚合方式？）

实验 2：基线选择影响（→ RQ2）

- 固定方法（IG或 EG），对比 ≥ 3 种基线的归因质量（忠实性 / 稳定性）
- 分析要点：哪种基线在忠实性上最优？在稳定性上呢？基线选择与数据类型的关系？

实验 3：消融实验

- Saliency → +IG（零基线）→ +EG（模糊基线）→ +EG（生成式基线）→ +Grad-CAM
- 分析要点：每步方法/基线改进对归因质量的贡献？

实验 4：跨数据集迁移（→ RQ3）

- 在 ImageNet 和 CHNCXR 上分别验证基线选择结论
- 分析要点：ImageNet上的最优基线在 CHNCXR 上是否仍然最优？医学影像的基线差异？

选做实验（从中至多选 2 项）

实验 5：生成式基线探索

- 训练 VAE 生成基线，对比零基线/模糊/生成式基线的 EG 归因质量
- 分析要点：生成式基线在哪些指标上改善？改善的幅度和计算成本？

实验 6：路径采样数影响

- 分析 IG/EG 积分路径上采样点数量对归因稳定性的影响
- 分析要点：采样数与计算成本的权衡？收敛速度？

实验 7：与扰动类方法对比

- 对比梯度类方法（最优配置）与 LIME/SHAP 的归因质量
- 分析要点：梯度类和扰动类的归因差异？各自的优势场景？

探索项

- **自适应基线**：根据图像内容自动选择基线类型——而非全局固定——探索基线选择的自适应策略。
- **自定义研究问题**：基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- 模型和数据集选择、归因方法和基线策略设计
- RQ1–RQ3 拆解

M2 —初步结果

- Saliency Map + Grad-CAM 基线实现
- 初步归因结果和可视化

M3 —中期结果

- IG + EG 实现，多基线对比结果
- 中期检查演示材料

M4 —完整实验

- 跨数据集迁移实验
- 消融和选做实验
- 完整多方法多基线对比

M5 —最终成果

- 完整报告（含方法对比、基线分析、对 RQ1–RQ3 的回答、方法选择建议）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

4.1.2 XAI01-02: 扰动类与博弈论类归因方法比较

动机

扰动类方法（LIME、RISE、Ablation）通过观察输入扰动后输出变化来推断特征重要性，不依赖梯度计算；博弈论类方法（SHAP / KernelSHAP）基于 Shapley 值提供公理化公平分配。这些方法在理论上比梯度类更严谨（SHAP 满足效率性/对称性/哑属性等公理），但计算成本也更高。理解扰动类和博弈论类方法的适用条件、计算效率和质量权衡，与方法选择直接相关。

本项目给定与 XAI01-01 相同的预训练模型和数据集，要求学生选择并实现至少 2 种扰动类方法和 1 种博弈论类方法，分析它们在效率、忠实性和稳定性上的权衡。前沿方法如 OrdShap（位置归因，NeurIPS 2025）和 SurvFD（高阶交互，ICML 2026）可作为选做扩展——学生可以选择性地探索“值贡献 vs 位置贡献”或“一阶 vs 高阶交互”，但核心任务是标准方法的系统比较。

研究问题

RQ1: 扰动类（LIME / RISE / Ablation）和博弈论类（SHAP）方法在忠实性和效率上的权衡如何——计算成本增加是否带来归因质量提升？

RQ2: 扰动粒度（超像素大小 / 扰动比例 / 采样数）如何影响扰动类方法的归因质量——什么粒度最优？

RQ3: 博弈论类方法（SHAP）的公理性保证在实践中是否转化为更优的归因质量——与梯度类和扰动类相比？

任务目标与阶段任务

总目标: 给定预训练模型，选择并实现扰动类和博弈论类归因方法，比较效率、忠实性和稳定性权衡。

阶段任务:

1. **问题定义**（对应 M1）：选择对比方法和扰动粒度参数。
2. **初步实验**（对应 M2）：实现 LIME 和 Ablation 基线。
3. **中期实验**（对应 M3）：实现 SHAP / KernelSHAP，获得多方法对比结果。
4. **完整实验**（对应 M4）：扰动粒度分析，与梯度类方法交叉对比，选做扩展。
5. **总结**（对应 M5）：回答 RQ1-RQ3，形成方法选择建议。

实施方案（建议）

扰动类方法

- 方法候选（建议必选 ≥ 2 ）：LIME（超像素扰动） / RISE（随机 Mask 采样） / Ablation（逐区域消除）
- 选做扩展：OrdShap 位置归因（参考 NeurIPS 2025 论文思路，区分值贡献和位置贡献）
- 决策点：扰动粒度是核心设计变量——超像素太小则噪声大，太大则分辨率低

博弈论类方法

- 方法候选（建议必选 1）：SHAP / KernelSHAP / DeepSHAP
- 选做扩展：SurvFD 高阶交互（参考 ICML 2026 论文思路，分解值函数为一阶项和高阶交互项）
- 决策点：Shapley 值的精确计算复杂度 $O(2^C)$ ——采样近似的精度与效率权衡

评价指标

- 忠实性（Insertion/Deletion） / 稳定性（Max-Sensitivity / CosineSim） / 效率（计算时间 vs 采样数）
- 决策点：效率是扰动类和博弈论类的核心约束——如何在不爆炸的计算预算下获得可靠归因

实验设计与评价

必做实验

实验 1：方法间效率-质量权衡（→ RQ1）

- 对比 LIME / RISE / SHAP 在同一批图像上的忠实性和计算时间
- 分析要点：SHAP 的理论保证是否转化为更优质量？计算时间增加的边际收益？

实验 2：扰动粒度分析（→ RQ2）

- 固定方法（LIME 或 RISE），变化超像素大小 / 扰动比例 / 采样数
- 分析要点：最优粒度？粒度与图像内容的关系？粒度对稳定性的影响？

实验 3：消融实验

- LIME $\rightarrow$ +RISE $\rightarrow$ +SHAP $\rightarrow$ + (选做扩展)
- 分析要点：方法复杂度增加的边际收益？

实验 4：与梯度类方法交叉对比 ($\rightarrow$ RQ3)

- 对比 XAI01-01 最优梯度类配置 vs 本项目最优扰动/博弈论类配置
- 分析要点：不同类别方法的优势场景？理论严谨性是否与实践表现一致？

选做实验 (从中至多选 2 项)

实验 5：位置归因探索

- 实现 OrdShap 位置归因，对比传统 SHAP 值归因
- 分析要点：位置贡献是否提供了额外信息？值贡献和位置贡献的分离是否有意义？

实验 6：高阶交互分析

- 实现 SurvFD 高阶交互分解，分析值函数的可加性
- 分析要点：高阶交互是否显著？在哪些模型上更重要？

实验 7：医学影像验证

- 在 CHNCXR 上验证扰动/博弈论类方法
- 分析要点：方法在医学影像上的迁移性？扰动粒度是否需要调整？

探索项

- **混合策略**：组合梯度类和扰动类方法——如用 Grad-CAM 快速定位再用 SHAP 精细化——探索混合归因策略。
- **自定义研究问题**：基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- 对比方法选择和扰动粒度参数设计
- RQ1-RQ3 拆解

M2 —初步结果

- LIME + Ablation 基线实现
- 初步归因结果

M3 —中期结果

- SHAP / KernelSHAP 实现
- 多方法初步对比结果
- 中期检查演示材料

M4 —完整实验

- 扰动粒度分析和与梯度类交叉对比
- 消融和选做实验

M5 —最终成果

- 完整报告 (含效率-质量权衡、粒度分析、对 RQ1-RQ3 的回答)
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

4.1.3 XAI01-03: 归因结果的跨模型与跨数据集一致性分析

动机

归因方法的一个核心问题是：同一张图像，在不同模型上得到的解释是否一致？如果 ResNet-50 和 VGG-16 对同一张图像给出截然不同的归因图，那归因结果反映的是“数据特征”还是“模型偏好”？更进一步，同一个模型在不同数据集（自然图像 vs 医学影像）上的归因行为是否一致？这些一致性问题直接影响归因方法的可信度。

本项目不提出新方法，而是系统分析“已有归因方法”在“不同模型 × 不同数据集”上的表现一致性。学生选择 1–2 种归因方法（可复用 XAI01-01/02 的实现），在 ≥ 2 种模型（如 VGG-16 vs ResNet-50 vs DenseNet-121）和 ≥ 2 种数据集（ImageNet vs CHNCXR）上运行，分析归因结果的变异来源。这种分析对实践中的方法选择具有直接指导意义——如果发现归因方法在模型间的方差很大，就说明该方法不够稳健。

研究问题

RQ1: 同一种归因方法在不同模型架构（VGG / ResNet / DenseNet）上的归因结果一致性如何——变异的主要来源是模型差异还是图像差异？

RQ2: 同一个模型在不同数据集（ImageNet / CHNCXR）上的归因行为是否一致——数据分布偏移如何影响归因？

RQ3: 归因一致性与模型预测置信度的关系——高置信度预测的归因是否更稳定？

任务目标与阶段任务

总目标：选择归因方法，在多种模型和数据集上运行，分析归因结果的一致性和变异来源。

阶段任务：

1. **问题定义**（对应 M1）：选择归因方法、模型集和数据集。
2. **初步实验**（对应 M2）：在 1 种模型上运行 1 种方法，建立分析 pipeline。
3. **中期实验**（对应 M3）：扩展到 ≥ 2 种模型 $\times$ ≥ 2 种数据集，获得初步一致性分析。
4. **完整实验**（对应 M4）：变异来源分解（ANOVA），置信度-一致性分析，选做扩展。
5. **总结**（对应 M5）：回答 RQ1–RQ3，形成一致性分析报告。

实施方案（建议）

实验设计

- 归因方法（建议选 1–2 种）：Grad-CAM / SHAP / IG（可复用前两个项目的代码）
- 模型集（建议 ≥ 2 ）：VGG-16 / ResNet-50 / DenseNet-121
- 数据集（建议 ≥ 2 ）：ImageNet（自然图像）/ CHNCXR（医学影像）
- 指标：归因图间相似度（CosineSim / SpearmanCorr / top-k重合率）/ 忠实性 / 稳定性

变异分析

- 技术（建议）：方差分析（ANOVA）——分解归因变异来源为模型效应 / 数据集效应 / 图像效应 / 交互效应
- 决策点：哪个因素对归因变异贡献最大——模型？数据集？还是图像本身？

实验设计与评价

必做实验

实验 1：跨模型一致性（ $\rightarrow$ RQ1）

- 同一方法在 ≥ 2 种模型上运行，计算归因图间相似度
- 分析要点：哪些区域模型间一致？哪些分歧大？分歧是否与模型架构差异相关？

实验 2：跨数据集一致性（→ RQ2）

- 同一模型在 ≥ 2 种数据集上运行，分析归因行为变化
- 分析要点：自然图像和医学影像的归因模式差异？数据偏移如何影响归因？

实验 3：变异来源分解

- 用 ANOVA 分解归因变异为模型效应 / 数据集效应 / 图像效应 / 交互效应
- 分析要点：哪个因素贡献最大？是否存在显著的模型 $\times$ 数据集交互？

实验 4：置信度-一致性关系（→ RQ3）

- 按模型预测置信度分组，分析高/低置信度样本的归因稳定性
- 分析要点：高置信度是否对应更稳定的归因？低置信度样本的归因是否更不可靠？

选做实验（从中至多选 2 项）

实验 5：多方法一致性

- 对同一模型和数据集，对比 ≥ 3 种方法的归因一致性
- 分析要点：哪些方法间一致性高？哪些分歧大？方法一致性是否与忠实性相关？

实验 6：类别层面分析

- 按预测类别分组，分析不同类别的归因模式
- 分析要点：哪些类别的归因更稳定？类别差异的来源？

实验 7：归因鲁棒性

- 对输入添加高斯噪声 / 对抗扰动 (FGSM)，分析归因变化
- 分析要点：哪种模型 + 方法的组合归因最鲁棒？鲁棒性与一致性的关系？

探索项

- 归因稳定性指标设计：基于跨模型一致性分析，设计一个新的归因稳定性评分——从分析到方法设计。
- 自定义研究问题：基于一致性分析中的异常发现自主延伸。

交付物与里程碑

M1 —问题分析

- 归因方法、模型集和数据集选择
- 一致性分析方案设计
- RQ1-RQ3 拆解

M2 —初步结果

- 1 种模型 $\times$ 1 种方法的分析 pipeline
- 初步归因结果和可视化

M3 —中期结果

- ≥ 2 种模型 $\times$ ≥ 2 种数据集的初步对比
- 初步一致性分析
- 中期检查演示材料

M4 —完整实验

- ANOVA 变异分解
- 置信度-一致性分析
- 消融和选做实验

M5—最终成果

- 完整报告（含一致性分析、变异分解、对 RQ1-RQ3 的回答）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

4.1.4 XAI01-04: 归因方法模式发现——什么条件下什么方法最优

动机

XAI01-01 至 XAI01-03 分别从方法选择、基线选择和一致性角度分析归因方法。本项目将这些分析整合，系统比较多标准归因方法在多种条件下的表现，发现”方法 × 模型 × 数据集 × 指标”空间中的规律性模式。这种模式发现对实践中的方法选择具有直接指导意义——例如，如果发现扰动类方法在小模型上优势显著但在大模型上不明显，就能指导方法选择策略。

本项目是纯模式发现类型，不提出新方法，核心挑战在于实验设计的完备性和模式发现的统计显著性。与之前项目不同，本项目要求学生自己设计实验矩阵（方法 × 模型 × 数据集 × 指标），管理实验组合的爆炸问题，并用统计方法分析模式。前沿方法（如 FourierShap、MA-GIG）可作为选做的方法候选加入比较，但主体是标准方法的系统比较。

研究问题

RQ1: 在”方法 × 模型 × 数据集 × 指标”空间中，是否存在稳定的优势模式——即某种方法在某种条件下系统地优于其他方法？

RQ2: 不同归因方法在忠实性、稳定性和效率三个维度上的权衡关系如何——是否存在 Pareto 最优方法？

RQ3: 不同评价指标之间是否存在系统性冲突——高忠实性的方法是否必然低稳定性？

任务目标与阶段任务

总目标: 设计实验矩阵，系统比较多标准归因方法在多条件下的表现，发现方法选择的模式规律。

阶段任务:

1. **问题定义**（对应 M1）：设计方法集、模型集、数据集和指标集，构建实验矩阵。
2. **初步实验**（对应 M2）：运行 2 种基线方法（如 Grad-CAM + SHAP），建立分析 pipeline。
3. **中期实验**（对应 M3）：扩展到 ≥ 4 种方法，获得初步对比结果。
4. **完整实验**（对应 M4）：完成实验矩阵，统计分析模式（ANOVA / Pareto / 相关性）。
5. **总结**（对应 M5）：回答 RQ1-RQ3，形成方法选择指南。

实施方案（建议）

实验空间设计

- 方法（建议 ≥ 4）：Grad-CAM / IG / SHAP / RISE / LIME / Ablation（可复用前三个项目的代码）
- 选做扩展：FourierShap加速 / MA-GIG 生成式基线（参考前沿论文思路）
- 模型（建议 ≥ 2）：VGG-16 / ResNet-50 / DenseNet-121
- 数据集（建议 ≥ 2）：ImageNet / VOC / CHNCCXR
- 指标（建议 ≥ 3）：忠实性 / 稳定性 / 效率

模式分析

- 技术（建议）：方差分析（ANOVA）/主效应图 / 交互效应图 / 相关性矩阵 / 聚类分析
- 决策点：模式发现的统计显著性——p-value和效应大小；实验组合爆炸的管理——分层采样或 Latin Hypercube

实验设计与评价

必做实验

实验 1：方法 × 模型交叉对比（→ RQ1）

- 在固定数据集和指标下，对比所有方法在 ≥ 2 种模型上的表现
- 分析要点：是否存在方法 × 模型交互效应？某种方法在某种模型上系统性更优？

实验 2：Pareto 前沿分析（→ RQ2）

- 在三维指标空间（忠实性 / 稳定性 / 效率）中绘制各方法的 Pareto 前沿
- 分析要点：哪些方法是 Pareto 最优的？权衡关系如何？

实验 3：指标冲突分析（→ RQ3）

- 计算指标间的相关性，分析冲突
- 分析要点：哪些指标正相关/负相关？冲突最严重的指标对？

实验 4：模式统计检验

- 用 ANOVA 检验方法、模型、数据集的主效应和交互效应的显著性
- 分析要点：哪些因素显著？效应大小如何？

选做实验（从中至多选 2 项）

实验 5：前沿方法加入比较

- 将 FourierShap 或 MA-GIG 加入实验矩阵，对比标准方法
- 分析要点：前沿方法在什么条件下优于标准方法？改进的边际收益？

实验 6：方法聚类

- 在指标空间中对方法聚类，发现方法群体
- 分析要点：哪些方法行为相似？是否可以归为几类？

实验 7：方法选择决策树

- 基于实验结果构建方法选择的决策树
- 分析要点：什么条件选择什么方法——可操作的选择指南

探索项

- **方法推荐工具**：构建一个交互式工具，允许选择模型/数据集/指标后推荐最优归因方法——从模式发现到实践应用。
- **自定义研究问题**：基于模式发现中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 实验矩阵设计（方法 × 模型 × 数据集 × 指标）
- 组合爆炸管理策略
- RQ1–RQ3 拆解

M2 —初步结果

- 2 种基线方法运行
- 分析 pipeline 建立

M3 —中期结果

- ≥ 4 种方法运行
- 初步对比和 Pareto 分析
- 中期检查演示材料

M4 —完整实验

- 完整实验矩阵
- ANOVA 和相关性分析
- 选做实验结果

M5 —最终成果

- 完整报告（含模式发现、Pareto分析、对 RQ1–RQ3 的回答、方法选择指南）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

4.2 XAI-T02: 先验信息融合的解释生成

T02 从归因方法选择转向解释生成，核心关注如何将结构先验、领域知识和辅助信息引入解释过程。3 个项目分别从反事实解释、先验融合机制比较和测试时训练自适应解释三个角度切入。前沿方法（LeapFactual、CCR）作为选做的方法候选，主体任务是标准解释生成方法的设计与评价。

4.2.1 XAI02-01: 反事实解释的设计与评价

动机

传统归因方法（Grad-CAM / SHAP）回答的是”模型关注了哪里”——给出空间热力图。但在很多场景中，更有价值的回答是”改变什么会导致预测改变”——这是反事实层面的解释。反事实解释不仅指出模型关注了什么，还指出改变什么会导致预测改变，具有更直接的因果含义。

反事实解释的生成不需要前沿生成模型——简单的特征扰动（遮挡、替换、消除）也可以生成反事实：将图像的某个区域遮挡，如果预测改变，则该区域对预测有因果贡献。这种朴素方法与 Grad-CAM 的热力图解释互补——热力图告诉你”模型看了哪里”，反事实告诉你”改变哪里会改变结果”。核心挑战在于反事实的”近邻性”（与原图差异小）和”有效性”（预测确实改变）的权衡，以及如何系统评价反事实解释的质量。前沿方法如 LeapFactual（条件流匹配，NeurIPS 2025）可作为选做扩展，探索更强的反事实生成策略。

研究问题

RQ1: 简单扰动式反事实解释（遮挡/替换）与梯度归因（Grad-CAM/SHAP）在定位精度和因果含义上有何差异——反事实是否提供了热力图无法提供的信息？

RQ2: 反事实解释的近邻性（与原图差异大小）和有效性（预测改变率）之间的权衡如何——最优工作点在哪里？

RQ3: 自然图像上的反事实解释结论在医学影像（CHNCXR）上是否适用——数据分布对反事实策略的影响？

任务目标与阶段任务

总目标: 设计反事实解释方法，与传统归因对比，评价反事实质量，验证跨数据集迁移。

阶段任务：

1. **问题定义**（对应 M1）：选择模型和数据集，定义反事实目标和评价指标。
2. **初步实验**（对应 M2）：实现遮挡式反事实基线，与传统归因对比。
3. **中期实验**（对应 M3）：实现多种扰动策略（遮挡/替换/消除），获得近邻性-有效性权衡曲线。
4. **完整实验**（对应 M4）：跨数据集验证，消融实验，选做方法扩展。
5. **总结**（对应 M5）：回答 RQ1-RQ3，形成反事实解释评价报告。

实施方案（建议）

反事实生成

- 方法候选（建议必选 ≥ 2 ）：遮挡式（区域置零/模糊）/ 替换式（替换为均值/随机纹理）/ 消除式（超像素消除）/ 梯度引导式（沿梯度方向扰动）
- 选做扩展：LeapFactual 条件流匹配（参考 NeurIPS 2025 论文思路，在数据流形上生成最小反事实）/ GAN 反事实（Counterfactual GAN）
- 决策点：朴素扰动 vs 生成式——朴素方法简单但可能离开数据流形，生成式保真但复杂

评价指标

- 有效性（预测改变率）/ 近邻性（L1/L2 距离 / SSIM）/ 定位性（与 ground truth 区域的 IoU）/ 可理解性（定性评估）
- 决策点：四个维度的权衡——不存在同时最优的方法

实验设计与评价

必做实验

实验 1：反事实 vs 传统归因（ $\rightarrow$ RQ1）

- 对比遮挡式反事实和 Grad-CAM/SHAP 的定位结果
- 分析要点：反事实在哪些场景下更直观？传统归因在哪些场景下更有效？两者是否互补？

实验 2：近邻性-有效性权衡（ $\rightarrow$ RQ2）

- 变化扰动幅度（遮挡区域大小 / 替换强度），绘制近邻性-有效性曲线
- 分析要点：最优工作点在哪里？不同扰动策略的权衡曲线差异？

实验 3：消融实验

- 单区域遮挡 $\rightarrow$ + 多区域 $\rightarrow$ + 替换式 $\rightarrow$ + 梯度引导 $\rightarrow$ + （选做扩展）
- 分析要点：不同扰动策略的边际贡献？

实验 4：跨数据集迁移（ $\rightarrow$ RQ3）

- 在 ImageNet 和 CHNCXR 上分别验证
- 分析要点：自然图像的反事实策略在医学影像上是否适用？数据分布对策略选择的影响？

选做实验（从中至多选 2 项）

实验 5：生成式反事实探索

- 实现 LeapFactual 条件流匹配或 GAN 反事实，对比朴素扰动式
- 分析要点：生成式反事实在近邻性和真实性上是否更优？计算成本？

实验 6：因果归因尝试

- 将反事实解释与因果推断结合——探索从“关联归因”到“因果归因”的升级路径
- 分析要点：反事实在什么条件下具有因果含义？

实验 7：可理解性用户评估

- 设计简单的用户评估（如让同学判断反事实 vs 热力图的可理解性）
- 分析要点：反事实解释是否真的更直观？在什么场景下？

探索项

- **反事实可视化系统**：构建交互式工具，并排展示热力图和反事实解释——从研究到工具的转化。
- **自定义研究问题**：基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- 模型和数据集选择、反事实目标和评价设计
- RQ1-RQ3 拆解

M2 —初步结果

- 遮挡式反事实基线实现
- 与 Grad-CAM 初步对比

M3 —中期结果

- 多种扰动策略实现
- 近邻性-有效性权衡曲线
- 中期检查演示材料

M4 —完整实验

- 跨数据集迁移实验
- 消融和选做实验
- 完整对比分析

M5 —最终成果

- 完整报告（含反事实 vs 归因对比、权衡分析、对 RQ1-RQ3 的回答）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

4.2.2 XAI02-02: 先验融合机制比较——从像素 Mask 到概念约束

动机

先验信息融合是提升解释质量的关键策略——在医学影像中，器官边界、病灶标注、解剖结构等先验信息可以约束解释的生成空间。但融合机制的选择空间巨大：从简单的特征拼接、注意力引导，到高级的原型匹配和概念约束。不同融合机制在定位精度、临床合理性和计算成本上的表现差异巨大，且可能与先验类型（边界框 / 像素 Mask / 概念级标签）存在交互效应。

本项目系统比较多种先验融合机制在不同条件下的表现，发现“什么条件下什么融合机制最优”的模式规律。学生从简单融合（特征拼接、注意力引导）开始，逐步扩展到更复杂的机制（原型匹配、Mask 引导），分析复杂度增加的边际收益。前沿方法如 CCR（约束概念精炼，ICML 2025）可作为选做扩展。本项目是纯模式发现类型，是 T02 的收尾——将 T02 的方法纳入系统性比较。

研究问题

■ **RQ1**：不同融合机制（特征拼接 / 注意力引导 / 原型匹配 / Mask 引导）在定位精度和合理性上的表现差异如何？

RQ2: 融合机制 × 先验类型 (边界框 / 像素 Mask / 概念标签) 是否存在交互效应——某种融合机制在某种先验类型上系统性更优?

RQ3: 复杂融合机制相比简单融合 (拼接/注意力) 的边际收益在什么条件下最显著——什么时候简单融合已足够?

任务目标与阶段任务

总目标: 系统比较多种先验融合机制在不同条件下的表现, 发现优势组合模式。

阶段任务:

1. **问题定义** (对应 M1): 选择融合机制集、先验类型和评价维度。
2. **初步实验** (对应 M2): 实现简单融合基线 (拼接/注意力)。
3. **中期实验** (对应 M3): 扩展到 ≥ 3 种融合机制, 获得初步对比。
4. **完整实验** (对应 M4): 交互效应分析, 消融实验, 选做扩展。
5. **总结** (对应 M5): 回答 RQ1-RQ3, 形成融合机制选择指南。

实施方案 (建议)

融合机制

- 机制候选 (建议必选 ≥ 3): 特征拼接 / 注意力引导 / 原型匹配 (ProtoPNet 式) / Mask 引导 (用先验 Mask 加权归因)
- 选做扩展: CCR 概念约束精炼 (参考 ICML 2025 论文思路, 在概念空间约束解释) / 反事实生成 (XAI02-01 的方法作为融合策略)
- 决策点: 从简单到复杂——需分析复杂度增加的边际收益

实验空间设计

- 先验类型: 边界框 (粗粒度) / 像素 Mask (细粒度) / 概念级标签 (语义级)
- 模型 (建议 ≥ 2): ResNet-50 / VGG-16
- 数据集 (建议 ≥ 2): VOC (有标注边界框) / CHNCXR (医学影像)
- 指标: 定位性 (IoU / Pointing Game) / 合理性 (定性评估) / 效率

模式分析

- 技术 (建议): ANOVA / 主效应图 / 交互效应图 / 聚类分析
- 决策点: 三维交互效应——哪些组合系统性更优

实验设计与评价

必做实验

实验 1: 融合机制对比 (→ RQ1)

- 固定先验类型和模型, 对比 ≥ 3 种融合机制的定位性
- 分析要点: 哪些机制在哪些指标上更优? 是否有稳定优势机制?

实验 2: 融合 × 先验交互分析 (→ RQ2)

- 分析融合机制 × 先验类型的交互效应
- 分析要点: 哪些组合系统性更优? 交互效应是否显著?

实验 3: 消融实验

- 特征拼接 → + 注意力引导 → + 原型匹配 → + Mask 引导 → + (选做扩展)
- 分析要点: 复杂度增加的边际收益?

实验 4：高级 vs 简单融合（→ RQ3）

- 对比高级融合和简单融合
- 分析要点：边际收益在什么条件下最显著？什么条件下简单融合已足够？

选做实验（从中至多选 2 项）

实验 5：概念约束探索

- 实现 CCR 概念约束精炼，对比标准融合机制
- 分析要点：概念约束在什么先验条件下优于像素级融合？

实验 6：医学影像验证

- 在 CHNCXR 上重复实验，对比自然图像模式
- 分析要点：融合机制选择模式在医学影像上是否一致？

实验 7：选择决策树

- 构建融合机制选择决策树
- 分析要点：什么条件选择什么融合机制

探索项

- **融合机制推荐工具**：构建交互式工具，允许选择先验类型后推荐最优融合机制——从模式发现到实践应用。
- **自定义研究问题**：基于模式发现中的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- 融合机制集和先验类型设计
- 实验空间设计
- RQ1-RQ3 拆解

M2 —初步结果

- 简单融合基线实现（拼接/注意力）
- 初步归因结果

M3 —中期结果

- ≥ 3 种融合机制实现
- 初步对比结果
- 中期检查演示材料

M4 —完整实验

- 交互效应分析
- 消融和选做实验
- 完整模式分析

M5 —最终成果

- 完整报告（含融合机制对比、交互分析、对 RQ1-RQ3 的回答、选择指南）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

4.2.3 XAI02-03: 测试时训练驱动自适应解释生成

动机

传统解释方法（Grad-CAM、SHAP）在模型训练完成后，使用固定的映射函数生成解释——同一架构对所有图像采用相同的归因逻辑。但不同图像的判别区域分布差异很大：简单图像可能只需关注显著物体，而困难图像或医学影像中病灶小、对比度低，固定归因往往定位不准。测试时训练（Test-Time Training, TTT）提供了一种动态替代方案——在推理阶段，利用测试图像自身生成监督信号（CAM 作为弱监督、预测标签作为自监督），训练一个轻量解释网络，实现逐样本自适应。这种方法不需要预训练解释模型，能够针对每张图像的视觉特征动态调整解释策略，尤其适合分布外样本和困难样本的解释。核心挑战在于：TTT 的两阶段（弱监督 / 自监督）各自的贡献如何？超参数（训练步数、学习率、损失权重）对解释质量的敏感性如何？先验信息能否融入 TTT 框架进一步提升定位精度？这些问题的回答对于 TTT 作为解释方法的可行性至关重要。

研究问题

RQ1: TTT 自适应解释相比固定映射方法（Grad-CAM / SHAP）在忠实性和定位性上是否系统更优——逐样本适应的收益体现在哪类图像上？

RQ2: TTT 两阶段（Stage 1 弱监督 → Stage 2 自监督）的贡献如何——哪个阶段对解释质量影响更大？不同图像类型是否依赖不同阶段？

RQ3: TTT 对超参数（训练步数 / 学习率 / 损失权重）的敏感性如何——是否存在稳定的默认配置，还是需要逐案例调参？

任务目标与阶段任务

总目标: 实现 TTT 驱动的自适应解释方法，与固定归因对比，分析阶段贡献和超参数敏感性。

阶段任务:

1. **问题定义**（对应 M1）：选择模型和数据集，设计 TTT 两阶段框架和评价指标。
2. **初步实验**（对应 M2）：实现 Stage 1（CAM 弱监督）解释基线，与 Grad-CAM 初步对比。
3. **中期实验**（对应 M3）：完成两阶段 TTT 实现，获得阶段消融初步结果。
4. **完整实验**（对应 M4）：超参数敏感性分析，跨数据集验证，选做先验融合扩展。
5. **总结**（对应 M5）：回答 RQ1–RQ3，形成 TTT 解释评价报告。

实施方案（建议）

TTT 框架设计

- Stage 1 弱监督（建议必选）：将 Grad-CAM 热力图作为模糊标签，训练轻量解释网络（BCE + Dice Loss），使解释网络学习 CAM 的判别区域分布
- Stage 2 自监督（建议必选）：利用图像预测标签作为自监督信号，添加分类损失 + Deletion Loss，使解释网络的学习与模型预测一致
- 解释网络架构（建议）：小型 U-Net 或 1–2 层 CNN，输入为 CNN 特征图，输出为归因 Mask
- 决策点：Stage 1 → Stage 2 的顺序 vs 并行——顺序训练更稳定还是联合训练更有效？

对比基线

- 固定归因（建议必选 ≥ 2 ）：Grad-CAM / SHAP / Integrated Gradients
- 决策点：TTT 的动态性是否带来稳定优势，还是因样本而异？

超参数空间

- 训练步数（建议）：5 / 10 / 20 / 50 步
- 学习率（建议）： $1e-4$ / $1e-3$ / $1e-2$

- 损失权重（建议）：Stage 1 权重 vs Stage 2 权重的比例
- 决策点：是否存在“一档通用”的默认配置？

评价指标

- 忠实性（Insertion / Deletion / Drop / Increase）
- 定位性（EBPG / IoU / Pointing Game）
- 稳定性（CosineSim / Max-Sensitivity）
- 效率性（每图推理时间 / GPU 显存占用）
- 决策点：TTT 的质量提升是否值得额外的计算开销？

实验设计与评价

必做实验

实验 1：TTT vs 固定归因（→ RQ1）

- 对比 TTT 两阶段解释与 Grad-CAM / SHAP 的忠实性和定位性
- 分析要点：TTT 在哪类图像上优势明显（简单 vs 困难 / 显著物体 vs 小目标）？固定归因在哪些场景仍更优？

实验 2：阶段消融（→ RQ2）

- 对比：仅 Stage 1 → 仅 Stage 2 → 两阶段顺序 → 两阶段并行
- 分析要点：各阶段的独立贡献？顺序依赖性？不同图像类型是否依赖不同阶段？

实验 3：超参数敏感性（→ RQ3）

- 变化训练步数、学习率、损失权重，绘制敏感性曲线
- 分析要点：哪些超参数影响最大？是否存在稳定区间？默认配置的推荐值？

实验 4：跨数据集验证

- 在 ImageNet（自然图像）和 CHNCXR（医学影像）上分别验证
- 分析要点：TTT 在医学影像（小目标、低对比度）上的自适应能力是否更强？

选做实验（从中至多选 2 项）

实验 5：先验信息融入 TTT

- 在 Stage 1 中引入先验 Mask（边界框 / 像素级标注）作为额外约束
- 分析要点：先验约束是否提升 TTT 的定位精度？先验质量对 TTT 的影响 vs 对固定归因的影响？

实验 6：TTT 解释稳定性分析

- 分析不同随机种子下 TTT 解释的方差
- 对比固定归因的稳定性——动态训练是否引入更大的解释不确定性？

实验 7：计算效率优化

- 探索减少 TTT 训练步数 / 网络规模的策略，分析质量-效率权衡
- 分析要点：最少多少步即可达到 Grad-CAM 水平？是否存在“提前停止”准则？

探索项

- **TTT 可视化工具**：构建交互式工具，展示 TTT 训练过程中归因 Mask 的逐步演化——从模糊到精准动态过程的可视化。
- **自定义研究问题**：基于实验中发现的异常现象自主延伸。

交付物与里程碑

M1 —问题分析

- TTT 两阶段框架设计
- 对比基线和评价指标选择
- RQ1-RQ3 拆解

M2 —初步结果

- Stage 1 弱监督解释实现
- 与 Grad-CAM 初步对比

M3 —中期结果

- 完整两阶段 TTT 实现
- 阶段消融初步结果
- 中期检查演示材料

M4 —完整实验

- 超参数敏感性分析
- 跨数据集验证
- 选做实验（如先验融合、稳定性分析）

M5 —最终成果

- 完整报告（含 TTT vs 固定归因对比、阶段消融、超参数敏感性分析、对 RQ1-RQ3 的回答）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

5 Track 4: Challenges（开放竞赛）

选题说明

Challenges Track 从天池、KDD Cup、Kaggle 等开放竞赛平台选取 6 个竞赛任务，覆盖语言模型应用、多模态感知和领域智能三个方向。与自建 Track（GV/Promoter/XAI）不同，Challenges Track 的任务要求来自竞赛原始描述，不做修改——学生按竞赛要求完成任务，方法空间完全开放。Challenges Track 的定位是“真实世界问题的端到端解决”，难度略高于自建 Track，要求学生面对真实数据的噪声、缺失和不平衡，构建完整 pipeline。

选题原则

- **来源多样**：覆盖天池/KDD/Kaggle三大平台
- **任务多样**：覆盖 LLM 微调、RAG、Agent、多模态 RAG、科学计算、医疗 NLP
- **难度适配**：要求多技术组合，工作量略高于自建 Track
- **数据开放**：所有竞赛数据公开可获取
- **评价客观**：使用竞赛官方评价标准

5.1 CH-T01: 语言模型应用与智能体

T01 的三个竞赛构成“LLM 能力 → 知识接入 → 自主推理”的递进链条。

5.1.1 CH01-01: Amazon Shopping MMLU（KDD Cup 2024）

竞赛信息

- 来源: KDD Cup 2024
- 链接: <https://amazon-kddcup24.github.io/>
- 数据: Shopping MMLU benchmark (GitHub公开)
- 状态: 已结束, 数据可获取

动机

电商购物助手需要理解商品知识、推理用户意图并执行行为对齐。Amazon Shopping MMLU 覆盖 57 个子任务、5 种题型, 要求 LLM 同时具备概念理解、知识推理、行为对齐和多语言能力。这个竞赛的核心挑战在于多任务 LLM 微调——如何用一个模型同时处理 57 种不同类型的任务, 且在每种任务上都保持合理性能。这涉及任务间知识共享与干扰的权衡、领域知识注入策略和多语言平衡问题。

研究问题

■ RQ1: 单一 LLM 在 57 个子任务上的性能分布如何——哪些任务类型容易, 哪些困难? 困难任务的原因是什么?

■ RQ2: 不同微调策略 (全量微调 / LoRA / 多任务混合) 对任务间性能平衡的影响如何?

■ RQ3: 领域知识注入 (商品知识 / 用户行为模式) 是否能改善困难任务的性能?

任务目标与阶段任务

总目标: 训练/微调 LLM 完成 Amazon Shopping MMLU 的多任务电商助手评测, 分析任务间性能差异和微调策略效果。

阶段任务:

1. **问题定义与数据构建** (对应 M1): 理解竞赛要求和任务类型, 构建训练/评测数据。
2. **探索性数据分析** (对应 M2): 分析任务分布、题型分布、多语言覆盖。
3. **Baseline** (对应 M3): 零样本 LLM 基线 + 简单微调。
4. **多任务微调** (对应 M4): 全量/LoRA/混合策略对比。
5. **知识注入与优化** (对应 M4): 领域知识注入 + 困难任务针对性优化。
6. **总结** (对应 M5): 回答 RQ1-RQ3, 提交竞赛结果。

实施方案 (建议)

模型选择

- 技术 (建议): Qwen / LLaMA / Mistral 系列 (7B-13B); 根据计算资源选择
- 决策点: 模型大小与任务复杂度的匹配——57 类任务可能需要较大模型

微调策略

- 技术 (建议): 全量微调 / LoRA / QLoRA / 多任务混合训练 (task mixing ratio)
- 决策点: 不同策略的显存需求和性能权衡

知识注入

- 技术 (建议): RAG 注入商品知识 / instruction tuning 注入行为模式 / 多语言数据平衡
- 决策点: 知识注入的效率 vs 效果

实验设计与评价

必做实验

实验 1: 零样本基线 (→ RQ1)

- 分析要点：哪些任务零样本已可处理？哪些需要微调？

实验 2：微调策略对比（→ RQ2）

- 分析要点：不同策略在任务平衡上的差异？

实验 3：消融实验

- 零样本 → + 简单微调 → + 多任务混合 → + 知识注入
- 分析要点：每步的贡献？

实验 4：困难任务分析（→ RQ1, RQ3）

- 分析要点：困难任务的共性特征？知识注入是否改善了困难任务？

与竞赛报到性能的对比：将本组最优结果与竞赛排行榜公开成绩进行对比，分析差距及可能原因。

选做实验（从中至多选 2 项）

实验 5：多语言平衡

- 分析不同语言间的性能差异和平衡策略

实验 6：任务分组微调

- 将 57 个任务分组，每组单独微调，对比混合训练
- 分析要点：分组是否提升了困难任务？

实验 7：prompt engineering 对比

- 对比不同 prompt 策略的效果

探索项

- **任务迁移分析：**分析在一种任务上学到的能力是否迁移到其他任务——多任务学习的知识共享机制。
- **自定义研究问题：**基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- 竞赛要求分析和任务类型分类
- 模型选择和微调策略设计
- RQ1-RQ3 拆解

M2 —初步结果

- 任务/题型/语言分布分析
- 数据加载和预处理 pipeline

M3 —中期结果

- 零样本 + 简单微调基线
- 初步性能和任务间差异分析
- 中期检查演示材料

M4 —完整实验

- 多策略对比实验
- 知识注入实验
- 消融和困难任务分析
- 选做实验结果

M5 —最终成果

- 完整报告（含任务分析、策略对比、对 RQ1–RQ3 的回答）
- 阶段性成果评价（含与竞赛报到性能的对比分析）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

5.1.2 CH01-02: Meta CRAG Challenge (KDD Cup 2024)

竞赛信息

- 来源：KDD Cup 2024
- 链接：<https://kddcup24.github.io/>
- 数据：CRAG benchmark（4,409 QA对 + 模拟检索 API）
- 状态：已结束，数据可获取

动机

检索增强生成（RAG）旨在减少 LLM 的幻觉问题——通过从外部知识源检索信息来支撑回答。Meta CRAG Challenge 构建了模拟 Web 搜索和知识图谱搜索 API，要求参赛者构建完整的 RAG 系统：从问题理解到检索策略到答案生成。核心挑战在于检索-生成的平衡——检索太多引入噪声，检索太少信息不足。此外，多步检索协调和幻觉抑制是工程难点。

研究问题

■ **RQ1**：不同检索策略（单步 vs 多步 / Web vs KG vs 混合）对答案准确性的影响如何？

■ **RQ2**：检索结果数量与答案质量的关系——存在最优检索量吗？

■ **RQ3**：幻觉率与检索策略的关系——哪种策略最能抑制幻觉？

任务目标与阶段任务

总目标：构建 RAG 系统完成 CRAG 的事实性 QA 任务，分析检索策略对答案质量和幻觉率的影响。

阶段任务：

1. **问题定义与数据构建**（对应 M1）：理解 CRAG 的检索 API 和 QA 格式。
2. **EDA**（对应 M2）：分析 QA 类型分布和检索 API 特性。
3. **Baseline RAG**（对应 M3）：单步检索 + 直接生成基线。
4. **多步 RAG**（对应 M4）：多步检索 + 重排序 + 答案生成。
5. **幻觉分析**（对应 M4）：量化不同策略的幻觉率。
6. **总结**（对应 M5）：回答 RQ1–RQ3。

实施方案（建议）

检索策略

- 技术（建议）：单步检索 / 多步检索（ReAct 式） / Web 搜索 / KG 搜索 / 混合检索
- 决策点：多步检索的成本 vs 收益

生成策略

- 技术（建议）：直接生成 / 检索结果重排序后生成 / 自我验证生成
- 决策点：重排序是否提升了答案质量？

幻觉评估

- 技术（建议）：事实一致性检测 / 答案-检索结果对齐度 / 人工评估子集
- 决策点：幻觉率是 RAG 系统的核心评价维度

实验设计与评价

必做实验

实验 1：检索策略对比（→ RQ1）

- 分析要点：不同检索策略的准确性差异？

实验 2：检索量-质量关系（→ RQ2）

- 分析要点：最优检索量？过多/过少的影响？

实验 3：消融实验

- 直接生成 → + 单步检索 → + 多步检索 → + 重排序 → + 自我验证
- 分析要点：每步的贡献？

实验 4：幻觉分析（→ RQ3）

- 分析要点：哪种策略幻觉率最低？

与竞赛报到性能的对比：将本组最优结果与竞赛排行榜公开成绩进行对比，分析差距及可能原因。

选做实验（从中至多选 2 项）

实验 5：多步 vs 单步深度分析

- 分析多步检索在什么类型问题上优势最大

实验 6：KG vs Web 检索对比

- 分析两种检索源的互补性

实验 7：答案置信度估计

- 构建答案置信度估计器，分析高/低置信答案的准确率差异

探索项

- **自适应检索：**根据问题类型自适应选择检索策略和检索量——从固定策略到自适应策略的升级。
- **自定义研究问题：**基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- CRAG API 分析和 RAG 系统设计
- RQ1-RQ3 拆解

M2 —初步结果

- QA 类型分布和检索 API 特性分析
- 数据加载代码

M3 —中期结果

- 单步 RAG 基线
- 初步准确率和幻觉率

- 中期检查演示材料

M4 —完整实验

- 多步检索和重排序实现
- 幻觉量化分析
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含策略对比、幻觉分析、对 RQ1–RQ3 的回答）
- 阶段性成果评价（含与竞赛报到性能的对比分析）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

5.1.3 CH01-03: Deep Research Agent 开发赛（天池 2026）

竞赛信息

- 来源：天池 2026
- 链接：天池平台 + GitHub (https://github.com/66Kevin/research_agent_tianchi2026)
- 数据：初赛 100 题 + 复赛 100 题
- 状态：进行中

动机

Research Agent 要求 LLM 自主完成复杂问题的多轮搜索和推理——从简单事实查询到需要多跳推理和交叉验证的复杂问题。这是 LLM 从“回答问题”到“自主研究”的能力跃迁。核心挑战在于 Agent 架构设计（ReAct 循环 / Plan-then-Execute）、多跳检索的协调、证据验证和查询去重。与 CH01-02（CRAG）相比，Research Agent 的自主性更强——系统需要自己决定“搜索什么、搜几次、何时停止”，而非按预设流程执行。

研究问题

■ **RQ1**：不同 Agent 架构（ReAct / Plan-then-Execute / Tree-of-Thought）在复杂问题上的表现差异如何？

■ **RQ2**：搜索轮次与答案准确性的关系——存在最优搜索深度吗？

■ **RQ3**：证据验证和交叉验证对减少幻觉的效果如何？

任务目标与阶段任务

总目标：构建自主 Research Agent 完成天池竞赛的复杂问题解答，分析 Agent 架构和搜索策略的效果。

阶段任务：

1. **问题定义**（对应 M1）：理解竞赛要求和问题类型分类。
2. **EDA**（对应 M2）：分析问题类型分布和难度分级。
3. **Baseline Agent**（对应 M3）：单轮搜索 + 直接回答基线。
4. **多轮 Agent**（对应 M4）：ReAct / Plan-then-Execute 实现。
5. **证据验证**（对应 M4）：交叉验证和证据去重。
6. **总结**（对应 M5）：回答 RQ1–RQ3。

实施方案（建议）

Agent 架构

- 技术（建议）：ReAct（推理-行动循环）/ Plan-then-Execute（先规划后执行）/ Tree-of-Thought（树搜索）
- 决策点：不同架构的自主性和效率差异

搜索策略

- 技术（建议）：关键词提取 / 查询改写 / 多跳搜索 / 查询去重
- 决策点：搜索策略的效率——查询去重避免冗余搜索

证据验证

- 技术（建议）：多源交叉验证 / 答案一致性检查 / 置信度估计
- 决策点：验证策略增加延迟但提升可靠性

实验设计与评价

必做实验

实验 1：Agent 架构对比（→ RQ1）

- 分析要点：不同架构在复杂问题上的差异？

实验 2：搜索深度分析（→ RQ2）

- 分析要点：最优搜索轮次？过多是否引入噪声？

实验 3：消融实验

- 单轮搜索 → + 多轮搜索 → + 查询改写 → + 证据验证
- 分析要点：每步的贡献？

实验 4：证据验证效果（→ RQ3）

- 分析要点：交叉验证对幻觉率的影响？

与竞赛报到性能的对比：将本组最优结果与竞赛排行榜公开成绩进行对比，分析差距及可能原因。

选做实验（从中至多选 2 项）

实验 5：问题难度分级分析

- 按问题难度分析不同架构的表现差异

实验 6：搜索效率优化

- 分析查询去重和缓存对延迟的改善

实验 7：中文实体规范化

- 分析中文实体匹配和规范化对搜索效果的影响

探索项

- **Agent 自进化：**让 Agent 从错误中学习——分析错误案例后自动调整搜索策略——从固定策略到自适应策略。
- **自定义研究问题：**基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- 竞赛分析和 Agent 架构设计

- RQ1–RQ3 拆解

M2 —初步结果

- 问题类型和难度分布分析
- 基础搜索 API 集成代码

M3 —中期结果

- 单轮搜索 Agent
- 初步准确率
- 中期检查演示材料

M4 —完整实验

- ReAct / Plan-then-Execute 实现
- 证据验证和交叉验证
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含架构对比、搜索分析、对 RQ1–RQ3 的回答）
- 阶段性成果评价（含与竞赛报到性能的对比分析）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

5.2 CH-T02: 多模态感知与领域智能

T02 的三个竞赛构成”跨模态理解 → 科学计算 → 领域决策”的递进链条。

5.2.1 CH02-01: Meta CRAG-MM Challenge (KDD Cup 2025)

竞赛信息

- 来源：KDD Cup 2025
- 链接：HuggingFace (crag-mm-2025/crag-mm-single-turn-public + crag-mm-multi-turn-public)
- 数据：约 6,500 个（图像, 问题, 答案）三元组 + 约 2,000 组多轮对话，6,200 张 egocentric 图像
- 状态：已结束，数据可获取

动机

多模态 RAG 系统需要同时处理图像和文本信息——从 egocentric 图像（模拟智能眼镜拍摄）和多轮对话中检索信息并回答问题。相比纯文本 RAG (CH01-02)，多模态 RAG 的核心挑战在于跨模态对齐——图像内容与文本查询的语义匹配、多源检索（Web/KG）的融合、以及图像质量鲁棒性。多轮对话还引入了上下文连贯性挑战——当前问题的理解依赖之前的对话历史。

研究问题

■ **RQ1**: 多模态检索（图像 + 文本）相比纯文本检索在答案准确性上的提升幅度如何？

■ **RQ2**: 多轮对话中上下文利用策略（全历史 vs 摘要 vs 滑动窗口）对答案质量的影响？

■ **RQ3**: 图像质量扰动（模糊/遮挡/低光照）对多模态 RAG 鲁棒性的影响？

任务目标与阶段任务

总目标：构建多模态 RAG 系统完成 CRAG-MM 的视觉问答任务，分析多模态融合和多轮上下文策略的效果。

阶段任务：

1. **问题定义**（对应 M1）：理解 CRAG-MM 的三个子任务和检索 API。
2. **EDA**（对应 M2）：分析图像分布、对话结构和领域覆盖。
3. **Baseline**（对应 M3）：纯文本 RAG + 单轮基线。
4. **多模态多轮 RAG**（对应 M4）：图像 + 文本融合 + 多轮上下文。
5. **鲁棒性分析**（对应 M4）：图像质量扰动实验。
6. **总结**（对应 M5）：回答 RQ1-RQ3。

实施方案（建议）

多模态融合

- 技术（建议）：CLIP/ViT图像编码 + LLM 文本编码 / 跨注意力融合 / 早期融合 vs 晚期融合
- 决策点：融合策略影响跨模态对齐质量

多轮上下文

- 技术（建议）：全历史拼接 / 历史摘要 / 滑动窗口 / 检索增强记忆
- 决策点：上下文长度限制 vs 信息完整性

实验设计与评价

必做实验

实验 1：多模态 vs 纯文本（→ RQ1）

- 分析要点：图像信息的贡献？在哪些问题上多模态优势最大？

实验 2：上下文策略对比（→ RQ2）

- 分析要点：不同策略在多轮对话中的效果？

实验 3：消融实验

- 纯文本单轮 → + 多模态 → + 多轮 → + 上下文策略
- 分析要点：每步的贡献？

实验 4：鲁棒性分析（→ RQ3）

- 分析要点：图像质量扰动对性能的影响？哪些策略更鲁棒？

与竞赛报到性能的对比：将本组最优结果与竞赛排行榜公开成绩进行对比，分析差距及可能原因。

选做实验（从中至多选 2 项）

实验 5：跨域分析

- 分析 13 个领域间的性能差异和跨域迁移

实验 6：图像质量自适应

- 根据图像质量自适应调整融合权重
- 分析要点：自适应是否提升了鲁棒性？

实验 7：检索源对比

- 对比 Web 检索和 KG 检索在多模态场景下的效果

探索项

- **视觉记忆**：构建基于图像的长期记忆模块，在多轮对话中积累视觉信息——从单次检索到持续记忆。
- **自定义研究问题**：基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- CRAG-MM 子任务分析和系统设计
- RQ1–RQ3 拆解

M2 —初步结果

- 图像分布、对话结构和领域覆盖分析
- 数据加载代码

M3 —中期结果

- 纯文本 RAG + 单轮基线
- 初步准确率
- 中期检查演示材料

M4 —完整实验

- 多模态融合和多轮上下文实现
- 鲁棒性实验
- 消融实验
- 选做实验结果

M5 —最终成果

- 完整报告（含多模态分析、上下文策略、对 RQ1–RQ3 的回答）
- 阶段性成果评价（含与竞赛报到性能的对比分析）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。

5.2.2 CH02-02: Ariel Data Challenge 2025 (Kaggle)

竞赛信息

- 来源：Kaggle / NeurIPS 2025
- 链接：<https://www.kaggle.com/competitions/ariel-data-challenge-2025>
- 数据：合成光谱数据（AIRS传感器 283 通道 + FGS 单通道）+ 轨道参数
- 状态：进行中

动机

系外行星表征是天文学的前沿领域。Ariel 空间望远镜将通过透射光谱观测系外行星大气，但观测数据充满噪声——仪器抖动、热漂移、暗电流和临边变暗等系统误差使得真实透射深度的提取极为困难。Ariel Data Challenge 要求从噪声光谱中恢复 283 个波长通道的真实透射深度，且需同时预测不确定性 σ ——这对不确定性量化提出了高要求。评价函数（Gaussian Log-Likelihood）联合奖励准确预测和不确定性校准，使得“知道什么时候不确定”成为核心能力。

研究问题

■ **RQ1**：不同噪声类型（抖动/漂移/暗电流）对透射深度恢复的影响差异如何——哪种噪声最难处理？

RQ2: 不确定性量化方法 (MC Dropout / Deep Ensemble / Bayesian NN / 分位数回归) 在校准性和精度上的对比?

RQ3: 轨道参数作为辅助信息对透射深度恢复的贡献如何?

任务目标与阶段任务

总目标: 从噪声光谱中恢复系外行星透射深度并预测不确定性, 在 GLL 指标上达到合理水平。

阶段任务:

1. **问题定义** (对应 M1): 理解 AIRS/FGS 传感器特性和噪声模型。
2. **EDA** (对应 M2): 分析噪声分布、通道间相关性和轨道参数。
3. **Baseline** (对应 M3): 简单回归 + 固定不确定性基线。
4. **深度模型 + 不确定性** (对应 M4): CNN/Transformer + MC Dropout/Ensemble。
5. **噪声建模** (对应 M4): 针对性噪声处理和轨道参数利用。
6. **总结** (对应 M5): 回答 RQ1-RQ3。

实施方案 (建议)

噪声处理

- 技术 (建议): 抖动对齐 / 漂移校正 / 暗电流扣除 / 临边变暗建模
- 决策点: 不同噪声类型的处理策略不同——需针对性设计

不确定性量化

- 技术 (建议): MC Dropout / Deep Ensemble / Bayesian Neural Network / 分位数回归 / Evidential Deep Learning
- 决策点: GLL联合奖励精度和校准——不确定性估计的质量直接影响得分

模型架构

- 技术 (建议): 1D-CNN (通道间卷积) / Transformer (长程依赖) / 混合架构
- 决策点: 283通道间的空间相关性如何建模?

实验设计与评价

必做实验

实验 1: 噪声影响分析 (→ RQ1)

- 分析要点: 不同噪声类型对恢复精度的影响? 哪种最难处理?

实验 2: 不确定性方法对比 (→ RQ2)

- 分析要点: 不同方法的校准性 (calibration curve) 和精度? GLL得分差异?

实验 3: 消融实验

- 简单回归 → + 深度模型 → + 噪声处理 → + 不确定性量化 → + 轨道参数
- 分析要点: 每步的贡献?

实验 4: 校准分析 (→ RQ2)

- 分析要点: 预测不确定性与实际误差的校准曲线? 哪些方法过自信/欠自信?

与竞赛报到性能的对比: 将本组最优结果与竞赛排行榜公开成绩进行对比, 分析差距及可能原因。

选做实验 (从中至多选 2 项)

实验 5: 通道间相关性建模

- 分析通道间空间相关性的建模效果

实验 6: 域适应 (FGS→AIRS)

- 分析 FGS 单通道和 AIRS 多通道间的迁移

实验 7: 物理约束模型

- 在模型中引入临边变暗等物理约束
- 分析要点: 物理约束是否提升了恢复精度?

探索项

- **不确定性引导的主动学习**: 选择高不确定性样本进行额外观测——从被动预测到主动观测策略。
- **自定义研究问题**: 基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- 传感器特性和噪声模型分析
- 不确定性量化策略设计
- RQ1–RQ3 拆解

M2 —初步结果

- 噪声分布和通道间相关性分析
- 轨道参数统计
- 数据加载代码

M3 —中期结果

- 简单回归 + 固定不确定性基线
- 初步 GLL 得分
- 中期检查演示材料

M4 —完整实验

- CNN/Transformer + 多种不确定性方法
- 噪声处理和轨道参数实验
- 消融和校准分析
- 选做实验结果

M5 —最终成果

- 完整报告 (含噪声分析、不确定性对比、对 RQ1–RQ3 的回答)
- 阶段性成果评价 (含与竞赛报到性能的对比分析)
- 可复现代码仓库
- 答辩 PPT

代码仓库要求: 同 GV01-01。

5.2.3 CH02-03: 出院用药推荐 (天池/CHIP2025)

竞赛信息

- 来源: 天池 / CHIP2025

- 链接：天池平台
- 数据：CDrugRed统一评测数据集（中文电子病历 + 651 种候选药物）
- 状态：已结束，数据可获取

动机

出院用药推荐是医疗 NLP 的核心应用——从中文电子病历（EMR）的诊疗信息中，为患者生成精准的出院用药方案。这与 GV Track 和 Promoter Track 的序列任务不同，是自然语言理解 + 多标签分类 + 领域推理的组合任务。核心挑战在于：中文医疗文本的语义理解（专业术语、缩写、不规范表述）、651 种药物的多标签分类（类别极多且分布不平衡）、药物相互作用的推理（某些药物组合禁忌）、以及临床决策的可解释性（医生需要理解推荐依据）。

研究问题

RQ1: 不同文本表示方法（TF-IDF / Word2Vec / BERT / 医疗 BERT）对用药推荐准确性的影响如何？

RQ2: 多标签分类策略（Binary Relevance / Classifier Chains / Label Embedding / LLM 生成式）在 651 类上的表现差异？

RQ3: 药物相互作用知识注入是否能改善推荐质量——减少禁忌组合？

任务目标与阶段任务

总目标: 从中文 EMR 构建出院用药推荐系统，在 651 种候选药物中生成精准推荐，分析表示方法和分类策略的效果。

阶段任务:

1. **问题定义与数据构建**（对应 M1）：理解 EMR 数据结构和药物分类目标。
2. **EDA**（对应 M2）：分析药物分布、共现模式、文本特征。
3. **Baseline**（对应 M3）：TF-IDF + Binary Relevance 基线。
4. **深度模型**（对应 M4）：BERT/医疗 BERT + 多标签策略对比。
5. **知识注入**（对应 M4）：药物相互作用知识注入。
6. **总结**（对应 M5）：回答 RQ1-RQ3。

实施方案（建议）

文本表示

- 技术（建议）：TF-IDF / Word2Vec / BERT / 医疗领域 BERT（MCBERT / PCL-MedBERT）
- 决策点：医疗领域 BERT 是否优于通用 BERT——领域适配的价值？

多标签策略

- 技术（建议）：Binary Relevance / Classifier Chains / Label Embedding（LABEL）/ LLM生成式推荐
- 决策点：651类的极端多标签——LLM 生成式 vs 判别式分类器的权衡

知识注入

- 技术（建议）：药物相互作用知识图谱 / 禁忌规则约束 / RAG 注入药物知识
- 决策点：知识注入是否减少了禁忌组合推荐？

实验设计与评价

必做实验

实验 1：文本表示对比（→ RQ1）

- 分析要点：不同表示的 F1/AUC 差异？医疗 BERT 是否优于通用 BERT？

实验 2：多标签策略对比（→ RQ2）

- 分析要点：不同策略在 651 类上的表现？哪种策略处理类别不平衡最好？

实验 3：消融实验

- TF-IDF → +BERT → + 医疗 BERT → + 多标签策略 → + 知识注入
- 分析要点：每步的贡献？

实验 4：知识注入效果（→ RQ3）

- 分析要点：药物相互作用知识注入后禁忌组合的减少率？

与竞赛报到性能的对比：将本组最优结果与竞赛排行榜公开成绩进行对比，分析差距及可能原因。

选做实验（从中至多选 2 项）

实验 5：LLM 生成式推荐

- 使用 LLM 直接生成用药推荐
- 分析要点：生成式 vs 判别式的优劣？

实验 6：可解释性分析

- 分析推荐依据——模型关注了 EMR 的哪些部分？
- 分析要点：推荐依据是否具有临床合理性？

实验 7：类别不平衡深度分析

- 分析高频/低频药物的性能差异和不平衡策略效果

探索项

- **药物推荐知识图谱：**构建药物-疾病-症状的知识图谱，将推荐结果映射到图谱上验证合理性——从预测到知识验证。
- **自定义研究问题：**基于实验中的发现自主延伸。

交付物与里程碑

M1 —问题分析

- EMR 数据结构和药物分类目标分析
- 表示方法和多标签策略设计
- RQ1-RQ3 拆解

M2 —初步结果

- 药物分布、共现模式和文本特征分析
- 数据加载和预处理 pipeline

M3 —中期结果

- TF-IDF + Binary Relevance 基线
- 初步推荐性能
- 中期检查演示材料

M4 —完整实验

- BERT/医疗 BERT + 多标签策略实验
- 药物相互作用知识注入
- 消融实验

- 选做实验结果

M5 —最终成果

- 完整报告（含表示对比、策略分析、对 RQ1–RQ3 的回答）
- 阶段性成果评价（含与竞赛报到性能的对比分析）
- 可复现代码仓库
- 答辩 PPT

代码仓库要求：同 GV01-01。