

《机器学习综合实践》

课程介绍与实践安排

宫秀军✉

天津大学人工智能学院

2026 年秋季学期

机器学习的三个基本问题

Q1: How to represent the past experience, performance or raw data

Answer: by a 2-dimension matrix (so called **training data set**) D with n rows and $m = f + k$ columns, where

- each row is an **instance**: $d_i = (x_i, y_i)$
- first $f > 1$ columns are **features**: $x_i = (d[i, 0], \dots, d[i, f - 1])$
- last $k \geq 0$ columns are **labels**: $y_i = (d[i, f], \dots, d[i, f + k - 1])$
- the types of machine learning are categorized by k and y_i
 - ▶ supervised learning: if $k \geq 1$
 - classification: if values of y_i are discrete
 - regression: if values of y_i are continuous
 - single label learning: if $k = 1$, else multi label learning
 - ▶ unsupervised learning: if $k = 0$
 - ▶ semi-supervised learning: if parts of values of y_i are unknown

Q2: How to generates or learn **rules**

Answer: by **building a model** to best explain data including training data and future data (so called testing data)

- For **(semi-)supervised** learning, the model is a function f mapping the X to Y
- For **unsupervised** learning, the model is a function f mapping the X to C
 - ▶ **clustering**: if C has similar structure with Y
 - ▶ **dimension reduction**: if C is a subset or merged subset of X
 - ▶ **networking learning**: if C is a set of relationships among X
- The best explain means that model best **fits** data including testing and training
 - ▶ Probabilistic model: Bayesian, Maximize Likelihood, Entropy ...
 - ▶ Algebra motivated model: LDM, SVM, Neural network, ...
 - ▶ Geometry motivated model: manifold learning, ...
 - ▶ Information theory motivated model: Decision tree, RF, ...
 - ▶ Deep learning: CNN, RNN, Transformer, ...

Q3: How to evaluate and use the **model**

Answer: **Using** the model just simply call the function f , this procedure is also called **predicting**

To evaluate the model, experimental study is often used meaning that random partitioning data into **training** and **testing** parts:

- **Hold out**: Iteratively random dividing data into two independent datasets, e.g., training set (2/3), test set(1/3)
- **Leave one out**: One as testing set, remaining as training set, until all of data have been tested.
- **k-fold cross-validation**:
 - ▶ randomly divide the data set into k subsamples
 - ▶ use $k-1$ subsamples as training data and one sub-sample as test data
 - ▶ repeat k times

课程定位

课程基本信息

- 课程名称：机器学习综合实践 (Machine Learning Projects)
- 学时/学分：32 学时 / 1.5 学分
- 课程类型：专业必修
- 适用专业：人工智能
- 先修课程：机器学习与深度学习

定位：连接机器学习理论与实践应用的桥梁。课程以真实场景问题为载体，致力于培养学生复杂问题**建模能力**、针对问题特性的机器学习**系统构建**与**迭代调优能力**，以及在项目实践中的**团队协作**与**项目管理能力**，实现从理论知识到产业实战的能力跃迁。

这门课与其他课程有什么不同

与相关课程的区别

- 与理论课的区别：不以模型知识讲授为主，而是以问题建模和模型设计为主线
- 与常规实验课的区别：不局限于算法模块的练习性实现，而是面向完整问题的系统设计与靶向优化

聚焦三项核心能力

- 复杂问题的机器学习建模能力——将真实场景抽象为计算任务
- 问题特性驱动的系统构建与迭代调优能力——针对问题特性构建模型、靶向优化
- 项目实践中的团队协作与项目管理能力——异步协作、版本管控、进度把控

■ 实现从”使用模型”到”设计模型”的根本转变。

课程核心目标

三维目标体系

- **知识目标**：理解问题抽象过程、模型设计流程、不同模型的适用条件
- **能力目标 (核心)**：复杂问题建模能力 + 问题特性驱动的系统构建与迭代调优能力
- **素质目标**：团队协作能力、项目管理能力、系统工程思维

实践组织与管理

集中实践 + 敏捷管理

- 不设定固定的每日上课时间与教室
- 以里程碑交付物为核心驱动
- 学生团队自主规划开发时间

核心节点

- 项目启动会
- 阶段性交付物（不定期）
- 中期检查（Baseline 演示）
- 最终答辩（项目成果展示）

弹性指导机制

- 支持线上预约
- 针对各组具体瓶颈进行”靶向指导”

考核方式与评分标准

总分 100 分 = 平时过程 40 分 + 项目成果 60 分

平时过程 (40 分)

- 问题分析与任务建模 (15 分): 问题理解深度、任务定义清晰度、技术路线合理性
- 实验过程与阶段成果 (25 分): EDA 深度、Baseline 设计、实验完整性、优化逻辑性

项目成果 (60 分)

- 模型设计合理性 (30 分): 选择依据、结构设计、与问题特性匹配度
- 优化与评价分析 (30 分): 靶向优化有效性、指标业务映射、分析深度
- 工程规范与团队协作 (20 分): 代码规范、可复现性、Git 提交记录、分工明确
- 项目展示 (20 分): 技术表达清晰度、答辩表现、团队默契

Git 提交记录不活跃、依赖单人突击完成、团队进度停滞者——工程规范与团队协作项扣分。

五阶段里程碑框架

阶段	内容	核心交付物
M1 问题分析	理解背景、数据特点分析、任务抽象与定义	项目需求分析与任务建模报告
M2 初步结果	数据探索性分析、预处理、特征表示方案设计	EDA 报告 + 预处理代码
M3 中期结果	模型定制设计、Baseline 实现、初步实验验证	Baseline 代码库 + 实验记录（中期检查）
M4 完整实验	性能瓶颈分析、靶向优化、对比实验、深度分析	优化实验、对比图表、最终模型
M5 最终成果	报告撰写、PPT 制作、项目答辩	完整报告、代码仓库、答辩 PPT（最终答辩）

各阶段 deadline 由指导教师根据实际情况设定，后续发布。不同项目可有不同的内部路径——M3 不一定必须是 Baseline，M4 不一定必须是优化。

项目池总览

组织架构

- Track (方向) → Topic (专题) → 项目 (具体可选对象) → 团队实践

Track 概览

Track	名称	项目数	核心领域
Track 1	GV (气囊蛋白)	12	合成生物学 + 蛋白质序列建模
Track 2	Promoter (启动子)	8	合成生物学 + 基因调控序列建模
Track 3	XAI (可解释 AI)	6	可解释机器学习 + 归因方法
Track 4	Challenges (开放竞赛)	6	LLM 应用、RAG、多模态、医疗 NLP

总计: 32 个项目

任务类型覆盖

- 监督预测（分类/回归）
- 非监督模式发现（聚类/Motif 挖掘）
- 混合任务（预测 + 发现）
- 生成任务（序列生成）
- 优化任务（定向优化/贝叶斯优化）
- 模型解释（期望梯度/积分梯度）

Track 1: GV (气囊蛋白)

- **领域：**生物气囊——蛋白质纳米空腔结构，超声成像/药物递送应用
- **核心计算问题：**生物序列-结构-功能关联建模
- **三个专题：**
 - ▶ T01：蛋白识别与功能预测（3 个项目）
 - ▶ T02：序列设计与优化（6 个项目）——从生成到主动学习的完整链条
 - ▶ T03：基因线路建模与设计（3 个项目）
- **核心挑战：**数据稀缺、跨物种分布偏移、序列-功能非线性

Track 2: Promoter (启动子)

- **领域：** 基因转录调控核心元件
- **核心计算问题：** 启动子识别 → 强度预测 → 序列生成的完整链条
- **三个专题：**
 - ▶ T01: 启动子识别与跨物种表征 (3 个项目)
 - ▶ T02: 启动子强度预测与可解释分析 (2 个项目)
 - ▶ T03: 启动子序列生成与闭环验证 (3 个项目)

Track 3: XAI (可解释人工智能)

- **核心理念**: 给定已有深度模型, 选择并优化解释方法, 而非复现前沿论文
- **两个专题**:
 - ▶ T01: 特征归因方法选择与评价 (4 个项目) —— 梯度类、扰动类、博弈论类方法系统比较; 跨模型/跨数据集一致性分析; 条件-方法最优模式发现
 - ▶ T02: 先验信息融合的解释生成 (2 个项目) —— 反事实解释的设计与评价; 像素 Mask $\rightarrow$ 概念约束的融合机制比较
- **前沿方法 (选做扩展)**: FourierShap / MA-GIG / LeapFactual / CCR

Track 4: Challenges (开放竞赛)

六个竞赛任务

- CH01-01: Amazon Shopping MMLU (KDD Cup 2024) ——57 任务 LLM 评测
- CH01-02: Meta CRAG Challenge (KDD Cup 2024) ——RAG 智能体
- CH01-03: Deep Research Agent (天池 2026) ——自主研究 Agent
- CH02-01: Meta CRAG-MM (KDD Cup 2025) ——多模态 RAG
- CH02-02: Ariel Data Challenge (Kaggle) ——系外行星光谱
- CH02-03: 出院用药推荐 (天池/CHIP2025) ——医疗 NLP 多标签

特点：方法完全开放、真实噪声数据、竞赛官方指标 + 与报到性能对比

选题流程：随机—协商机制

第一步：自愿组队

- 每组 5 人，每组有唯一编号（如 G02）
- 组队完成后登记

第二步：随机分配

- 课堂现场由教师运行随机程序
- 为每组随机分配一个项目（如 PR03-02 → G10）

第三步：组间协商

- 各组了解自己的项目后，可与其他小组协商交换
- 项目交换必须经过相关小组共同同意

第四步：项目确认

- 每个项目原则上仅由一个小组完成
- 协商结束后项目原则上不再调整

研究问题 (RQ) 驱动方法

为什么引入 RQ

- 每个项目显式列出 2-4 个研究问题 (RQ)
- 学生的实验设计和分析应围绕回答 RQ 展开
- 避免”做出结果却不知道回答了什么问题”

RQ 驱动的实验设计

- RQ1 (核心问题) → 设计实验 1 → 数据支撑 → 得出结论
- RQ2 (进一步) → 设计实验 2 → 数据支撑 → 得出结论
- RQ3 (再进一步) → 设计实验 3 → 数据支撑 → 得出结论

| 学生须在最终报告中明确回答所有 RQ, 以实验数据支撑结论。

团队协作与工程规范

强制要求

- Git 版本控制：所有代码、实验记录通过 Git 管理
- 在线协作文档：团队分工、会议纪要、进度追踪
- 代码仓库规范：data/ preprocessing/ models/ experiments/ results/ + README.md

异步协作评分依据

- Git 提交记录活跃且合理
- 提交信息清晰（非”update” “fix”）
- 在线文档更新及时
- 团队分工明确、各司其职
- 依赖单人突击完成 → 扣分

实验可复现性要求

- README 含环境配置 (conda env / requirements.txt)
- 关键实验可通过命令行复现
- 随机种子固定, 结果可重复

今日任务

- 完成组队（5 人/组），确定组长
- 登记团队信息（组号、成员名单）
- 现场参与随机分配，获取项目编号
- 初步浏览自己的项目文档

组间协商（即日起 2 天内）

- 仔细阅读自己项目的完整描述
- 评估项目难度与团队匹配度
- 如有交换意愿，主动联系相关小组
- 协商完成后向教师确认

项目确认后立即启动 (M1 阶段)

- 细读项目文档：理解动机、RQ、任务目标
- 数据采集：按项目方案从公共数据库采集
- 文献调研：Gvp 蛋白/启动子/XAI 领域现有方法
- 撰写 M1 报告：项目需求分析与任务建模报告

常见问题

Q1: 5 人团队如何分工?

- 建议: 数据/模型/实验/分析/文档各有人负责, 但需交叉互审

Q2: Git/GitHub 不熟悉怎么办?

- 自学 + 团队内互助, 教师不讲授基础操作

Q3: 遇到技术瓶颈怎么办?

- Office Hour + 线上预约 + 团队讨论

Q4: 项目难度太大怎么办?

- 每个项目都有必做/选做/探索项, 优先保证必做
- 选做和探索项给有余力的团队深入

祝各组项目顺利!